Evaluación de Factibilidad del Proyecto Heart Disease

Gestión de Proyectos de Datos — EVA1

Lucas Moncada Ignacio Silva Fabián Leal Vicente Hormazábal
César Rojas

Noviembre de 2026

Índice

1. Resumen ejecutivo **1**

2. Introducción **1**
2.1. Estado y trazabilidad documental 2

3. Contexto del problema **3**
3.1. Objetivo general 3
3.2. Objetivos específicos 3
3.3. Usuarios y criterios de éxito 3

4. Descripción del dataset **4**
4.1. Diccionario de datos 5
4.2. Alcance de los datos 5

5. Metodología **5**
5.1. Ciclos de gestión propuestos 6

6. Preparación de datos **6**
6.1. Alcance de la automatización en la actividad 7
6.2. Validación de duplicados 7

7. Análisis exploratorio **8**
7.1. Efecto de la deduplicación 8
7.2. Representación y subgrupos 10

8. Análisis ético y de sesgos **11**
8.1. Evidencia, interpretación y límites 11
8.2. Impacto ético y técnico del uso futuro 12
8.3. Matriz de controles y criterios de aceptación 12
8.4. Gates propuestos antes de un piloto 14

9. Modelado experimental y resultados **14**
9.1. Explicabilidad comparativa de los XGBoost 20

10. Análisis D1 **26**
10.1. Alcance funcional 26
10.2. Fuera de alcance 26
10.3. Arquitectura lógica común 26

11. Arquitectura y herramientas cloud (antecedente D2) **27**

12. Alternativa local y estado implementado (antecedente D3) **27**

13. Alternativa híbrida (antecedente D4) **27**

14. Herramientas y stack implementado (D5) **28**

15. Análisis D6 **28**
15.1. Justificación de Scrum, PMBOK y CRISP-DM 28
15.2. Criterios completos de comparación 29

16. Estimación financiera de la ejecución académica (D7–D11) **30**
16.1. Trazabilidad del presupuesto de diez semanas 30

17. Planificación integrada, Gantt y recursos (D12–D14) **31**
17.1. Estructura de Desglose del Trabajo (D12) 31
17.2. Carta Gantt del piloto (D13) 31
17.3. Hitos, dependencias y continuidad (D14) 32

18. Organización y estado de ejecución **33**
18.1. Trabajo que consta en el repositorio 33
18.2. Elementos que no constan como ejecutados 33

19. Criterios de aceptación de la actividad **34**

20. Anexo de trazabilidad de decisiones y supuestos **34**

21. Anexo de planificación y evidencia técnica actual **35**
21.1. Cronograma vigente 35
21.2. Entregables de implementación observables 36

22. Anexo de riesgos del alcance vigente **36**

23. Discusión **37**
23.1. Límites del estado implementado 38

24. Conclusiones **38**

25. Recomendaciones **39**
25.1. Trazabilidad de responsabilidades y decisiones 39

26. Referencias **40**

1. Resumen ejecutivo

Este informe maestro integrado establece la línea base para una plataforma interna de apoyo a la prevención cardiovascular. La propuesta busca transformar datos disponibles en conocimiento sobre factores asociados a enfermedad cardíaca y, en una etapa posterior, apoyar la priorización de evaluaciones preventivas. No corresponde a un sistema de diagnóstico autónomo ni reemplaza la decisión de los profesionales de salud.

Se comparan tres alternativas técnicamente equivalentes: una implementación Cloud en Google Cloud Platform (GCP), una alternativa Local dentro de la infraestructura hospitalaria y una arquitectura Híbrida. Las tres conservan el mismo alcance funcional, el mismo horizonte de evaluación y los mismos supuestos operacionales; cambian principalmente la ubicación de los componentes, la responsabilidad de operación, el perfil de costos y los riesgos.

La línea base define un stack portable y predominantemente open source, formado por Python, Pandas, Scikit-learn, PostgreSQL, SHAP, FastAPI, Streamlit, Docker y Git. PMBOK organiza el gobierno, la documentación y el control de cambios; Scrum organiza el desarrollo en sprints; y CRISP-DM estructura el ciclo técnico de datos. Esta distribución permite iterar ante la incertidumbre sin omitir revisiones, hitos ni aprobaciones.

El dataset académico analizado contiene 1.025 filas y 14 variables; 723 filas son duplicados exactos y quedan 302 registros únicos. El trabajo actual incluye un prototipo de modelado reproducible: compara pipelines con codificación one-hot, entrena XGBoost con CUDA en una GPU local, genera gráficos de análisis y ejecuta inferencia batch sobre cinco casos sintéticos. El modelo es experimental y no tiene validación clínica ni representa un sistema desplegado.

La línea base vigente considera una ejecución académica de diez semanas, del 5 de octubre al 13 de diciembre de 2026, con presupuesto estimado de $10.506.069 CLP. Es una estimación de planificación para un prototipo de investigación y demostración, no una cotización ni una autorización de gasto. El alcance no contempla operación institucional posterior ni producción clínica. La propuesta sigue condicionada a autorización, gobierno de datos, controles de seguridad y validación local antes de cualquier uso con datos o flujos clínicos.

2. Introducción

El caso aborda la utilización de un dataset de enfermedad cardíaca como base académica y de prototipo para un proyecto de ciencia de datos en salud pública. El documento maestro integra las decisiones D1 a D14, los supuestos comunes, la evaluación financiera, la planificación, los riesgos y el análisis ético, preservando la autoría de cada bloque.

La estructura se apoya en los contenidos docentes de Gestión de Proyectos de Datos, la

pauta de la evaluación, el Plan Maestro del equipo y el caso Heart Disease. Para mantener la trazabilidad, se distingue entre contenido respaldado por estos documentos, evidencia externa de contexto, decisiones de diseño y supuestos de planificación. Las decisiones concretas de arquitectura y los valores de dimensionamiento son adaptaciones para el caso; no se presentan como hechos declarados por una institución hospitalaria real.

El alcance corresponde a un piloto institucional controlado y mantenible. No se dimensiona la infraestructura para las 1.025 filas del dataset académico ni se afirma que este represente la futura población productiva del hospital. El objetivo es disponer de una base seria y comparable para evaluar alternativas, sin simular un despliegue clínico definitivo.

2.1. Estado y trazabilidad documental

Lucas Moncada es responsable de la línea base técnica D1–D6; Ignacio Silva, de D7–D11; Fabián Leal, de D12–D14; Vicente Hormazábal, de la matriz de riesgos; y César Rojas, del dataset, la ética y la implementación técnica documentada en esta revisión. La línea base temporal vigente es de diez semanas (5 de octubre a 13 de diciembre de 2026). El alcance actual es académico: prototipo, evaluación técnica preliminar y documentación; no incluye operación institucional posterior ni despliegue clínico.

EA1 1.1

Aporta sesgos, ciclo de vida del dato, justicia, transparencia, privacidad, responsabilidad y mitigación.

EA1 1.2

Aporta viabilidad técnica, datos, seguridad, escalabilidad, riesgos, RBAC, Zero Trust, anonimización y explicabilidad.

EA1 1.3

Aporta costos cloud, licencias, RRHH, servicios, costo-beneficio, ROI, escenarios, riesgos y mitigaciones.

EA1 1.4

Aporta la integración técnica, financiera, ética y de riesgos, además de la comunicación de supuestos y limitaciones.

Rúbrica EP1

Exige ética 30 %, finanzas 30 %, riesgos 40 %, extensión de 4 a 6 páginas y referencias APA.

Plan Maestro

Define responsabilidades D1 a D22, criterios de aceptación, dependencias y handoffs.

Caso y dataset

Fundamentan la necesidad de comprender factores asociados al riesgo y priorizar prevención con un dataset académico de referencia.

3. Contexto del problema

Un hospital público dispone de información obtenida durante controles cardiovasculares preventivos, pero no cuenta con una solución analítica que transforme sistemáticamente esos datos en conocimiento sobre los factores asociados a enfermedad cardíaca ni que apoye la priorización de acciones preventivas.

La solución propuesta es una plataforma interna de apoyo analítico para prevención cardiovascular. Debe procesar información clínica, analizar factores asociados a enfermedad cardíaca y evolucionar hacia estimaciones de riesgo que ayuden a priorizar evaluaciones preventivas. La supervisión de profesionales de salud se mantiene durante todo el proceso.

3.1. Objetivo general

Diseñar y evaluar una solución de ciencia de datos mantenible, segura y explicable para analizar factores asociados a enfermedad cardíaca y apoyar la priorización de pacientes en controles cardiovasculares preventivos. La evaluación compara alternativas Cloud, Local e Híbrida, sin delegar la decisión clínica en el sistema.

3.2. Objetivos específicos

- Preparar y analizar los datos cardiovasculares para determinar su calidad, representatividad y utilidad analítica.
- Identificar variables y patrones asociados con la presencia de enfermedad cardíaca.
- Desarrollar y evaluar progresivamente modelos de apoyo a la estimación de riesgo cardiovascular.
- Incorporar explicabilidad, evaluación de sesgos, privacidad y supervisión humana en el ciclo de la solución.
- Diseñar una arquitectura mantenible que permita incorporar nuevos datos, monitorear la solución y evolucionarla.

3.3. Usuarios y criterios de éxito

Los profesionales clínicos y preventivos consultarán resultados como apoyo; coordinación y gestión cardiovascular utilizarán información agregada para planificar acciones; y los equipos de TI y datos administrarán operación, permisos, monitoreo y soporte bajo el

principio de mínimo privilegio. El paciente es un beneficiario indirecto y no se considera una interfaz pública de paciente para el piloto.

El éxito técnico requiere una arquitectura mantenible y trazable; el éxito clínico-operacional exige resultados comprensibles sin bloquear el flujo clínico si la plataforma no está disponible; el éxito ético requiere explicabilidad, supervisión humana, protección de datos y evaluación por subgrupos; y el éxito financiero y de gestión exige una alternativa sostenible, con alcance, costos, riesgos, recursos y decisiones coherentes.

4. Descripción del dataset

El archivo `heart.csv` utilizado en el caso contiene 1.025 registros y 14 variables, incluida la variable objetivo `target`. No presenta valores nulos y contiene 723 filas duplicadas exactas. La clase objetivo está relativamente equilibrada, con 526 registros cuyo `target` es 1 y 499 cuyo `target` es 0. La variable `sex` presenta 713 registros con valor 1 y 312 con valor 0; la edad observada se encuentra entre 29 y 77 años.

Cuadro 1: Caracterización inicial del dataset original

Indicador	Valor
Registros	1.025
Variables	14
Valores nulos	0
Filas duplicadas exactas	723 (70,54 %)
Registros únicos	302
`target`=0 / `target`=1	499 / 526
`sex`=0 / `sex`=1	312 / 713
Rango de edad	29–77 años

Estas características orientan la factibilidad inicial, pero no validan por sí mismas la representatividad del dataset ni la pertinencia de un uso clínico. El dataset de Kaggle se utiliza como referencia académica y de prototipo; no se asume que sea la base productiva definitiva del hospital. La codificación `sex`=0 como mujer y `sex`=1 como hombre está documentada para el conjunto original de UCI; la coincidencia de valores se registra con trazabilidad externa (Janosi et al., 1989).

4.1. Diccionario de datos

El archivo `heart.csv` contiene 14 variables: 13 predictores y la variable objetivo `target`. El diccionario documenta el significado, tipo, unidad o codificación y dominio observado de cada variable. Las definiciones conceptuales proceden de la documentación del repositorio UCI y de la versión publicada en Kaggle, mientras que dtype, rangos, nulos, valores únicos y categorías observadas se calculan directamente desde `heart.csv` (Janosi et al., 1989; JohnSmith88, s.f.).

Cuando la codificación original de UCI difiere del dominio presente en esta versión, se conservan los valores observados y se deja una advertencia explícita en el diccionario técnico. Esto afecta particularmente a `cp`, `slope`, `ca` y `thal`; no se asume una equivalencia que no esté documentada de forma concluyente.

Cuadro 2: Diccionario resumido de variables

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
age	Edad del paciente.	Numérica discreta	años	29–77
sex	Sexo del paciente.	Binaria	0=mujer; 1=hombre	0|1
cp	Tipo de dolor torácico.	Categórica	No verificada; ver CSV	0|1|2|3
trestbps	Presión arterial en reposo al ingreso.	Numérica discreta	mmHg	94–200
chol	Colesterol sérico.	Numérica discreta	mg/dL	126–564
fbs	Indicador de glucosa en ayunas superior a 120 mg/dL.	Binaria	0=no; 1=sí (>120 mg/dL)	0|1
restecg	Resultado del electrocardiograma en reposo.	Categórica	0=normal; 1=ST-T; 2=HVI	0|1|2

Cuadro 3: Diccionario resumido de variables (continuación)

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
thalach	Frecuencia cardíaca máxima alcanzada.	Numérica discreta	bpm	71–202
exang	Angina inducida por ejercicio.	Binaria	0=no; 1=sí	0|1
oldpeak	Depresión del segmento ST inducida por ejercicio respecto del reposo.	Numérica continua	desviación ST	0–6.2
slope	Pendiente del segmento ST durante ejercicio.	Categórica	No verificada; ver CSV	0|1|2
ca	Número de vasos principales coloreados por fluoroscopia.	Numérica discreta	UCI: 0–3; CSV: 0–4	0–4
thal	Resultado de la prueba de talio.	Categórica	No verificada; ver CSV	0|1|2|3
target	Variable objetivo binaria de la versión Kaggle, asociada a la presencia de enfermedad cardíaca.	Binaria	Binaria 0/1; ver CSV	0|1

4.2. Alcance de los datos

La preparación debe detectar faltantes, duplicados, valores inválidos y cambios de esquema. El análisis posterior debe evaluar calidad, estabilidad, representatividad, privacidad y posibles sesgos por subgrupos antes de que un modelo pueda considerarse para apoyo operativo.

5. Metodología

El proyecto usa marcos con responsabilidades explícitas. PMBOK organiza gobierno, documentación, alcance, costos, riesgos, comunicaciones y control de cambios. Scrum

organiza el desarrollo en sprints con backlog priorizado, revisiones y retrospectivas. CRISP-DM estructura el trabajo técnico de comprensión del negocio y los datos, preparación, modelado, evaluación y eventual despliegue. MLOps queda como una capacidad posterior, sólo si el piloto continúa con autorización y madurez operacional suficiente.

Esta división responde a la incertidumbre de requisitos, calidad y representatividad de los datos, desempeño de las alternativas y validaciones requeridas. Scrum permite revisar incrementos cortos; PMBOK conserva la línea base y exige que cambios de alcance, costo, calendario, riesgos o controles se documenten y aprueben; CRISP-DM permite volver a preparación de datos cuando la evidencia técnica lo requiera.

5.1. Ciclos de gestión propuestos

Sprint 1

Comprensión del problema, objetivos, actores, criterios de éxito y backlog inicial. Gate: H1, alcance revisado.

Sprint 2

Comprensión y preparación de datos: calidad, representatividad, privacidad y trazabilidad. Gate: H2, datos gobernados.

Sprint 3

Modelado y evidencia técnica: baseline, candidatos, explicabilidad y pruebas iniciales. Gates: H3–H4.

Sprint 4

Evaluación por subgrupos, revisión humana, seguridad, continuidad y preparación de piloto. Gate: H5 condicionado.

Sprint 5

Piloto controlado, indicadores, retrospectiva, lecciones y decisión documentada. Gate: H6, continuidad o cierre.

La ejecución académica se limita a diez semanas y cinco sprints de dos semanas. Los hitos de operación posterior, reentrenamiento periódico y mantenimiento institucional quedan fuera de esta línea base. Las revisiones de calidad, desempeño, riesgos y explicabilidad se realizan dentro del periodo y con los recursos de la actividad.

6. Preparación de datos

La preparación de datos de esta actividad es un flujo reproducible para el dataset académico disponible. Valida faltantes, duplicados, dominios y extremos antes de crear la matriz analítica. No se implementa una capacidad permanente de ingesta institucional.

La automatización desarrollada procesa un archivo CSV bajo demanda y produce predicción y score no calibrado. No se conecta a sistemas clínicos, no ingiere registros diarios y no ejecuta reentrenamiento ni publicación automática.

6.1. Alcance de la automatización en la actividad

Al ejecutar el comando

Validación de columnas, nulos y dominios categóricos del CSV de entrada.

Inferencia batch

Aplicación del pipeline versionado y escritura de clase y score no calibrado.

Fuera de alcance

Ingesta clínica periódica, dashboard institucional, monitoreo productivo y reentrenamiento automático.

Control de versiones

Cualquier nuevo artefacto requiere entrenamiento y revisión explícitos; el script de inferencia no modifica ni publica modelos.

6.2. Validación de duplicados

La revisión reproducible confirma que los 723 duplicados son coincidencias exactas al considerar las 14 columnas. El cuadro 4 muestra la frecuencia de repetición de las 302 observaciones distintas: no hay observaciones con una o dos apariciones, 187 se repiten tres veces, 114 cuatro veces y una observación aparece ocho veces. Esta evidencia no permite atribuir la causa a fraude, error de captura o sesgo; sí exige definir y documentar su tratamiento antes de cualquier modelamiento.

Cuadro 4: Frecuencia de repetición de observaciones exactas en el dataset original

Repeticiones	Observaciones distintas	Filas asociadas	% del original
1 vez	0	0	0,00 %
2 veces	0	0	0,00 %
3 veces	187	561	54,73 %
Más de 3 veces (4 u 8)	115	464	45,27 %
Total	302	1.025	100,00 %

Para garantizar trazabilidad, `data/raw/heart.csv` se conserva como fuente primaria inmutable. La versión `data/processed/heart_unique.csv` se deriva exclusivamente

mediante `drop_duplicates()` y se utiliza como análisis de sensibilidad; no reemplaza al archivo original.

7. Análisis exploratorio

El análisis exploratorio se orienta a comprender la calidad y utilidad de los datos para el problema, no a producir visualizaciones sin propósito. La línea base identifica ausencia de valores nulos, 723 duplicados exactos, balance relativo de `target`, distribución observada de `sex` y edad entre 29 y 77 años.

7.1. Efecto de la deduplicación

Se comparó el archivo original con la versión deduplicada de 302 registros. El cuadro 5 cuantifica las diferencias en puntos porcentuales, en lugar de asumir que la eliminación de duplicados no afecta las distribuciones. La proporción de `target`=1 aumenta 2,99 puntos porcentuales tras deduplicar; la distribución de `sex` cambia 1,35 puntos porcentuales por código.

Cuadro 5: Distribución de `target` y `sex`: original versus deduplicado

Categoría	Original (%)	Deduplicado (%)	Diferencia (pp)
`target`=0	48,68	45,70	-2,99
`target`=1	51,32	54,30	+2,99
`sex`=0	30,44	31,79	+1,35
`sex`=1	69,56	68,21	-1,35

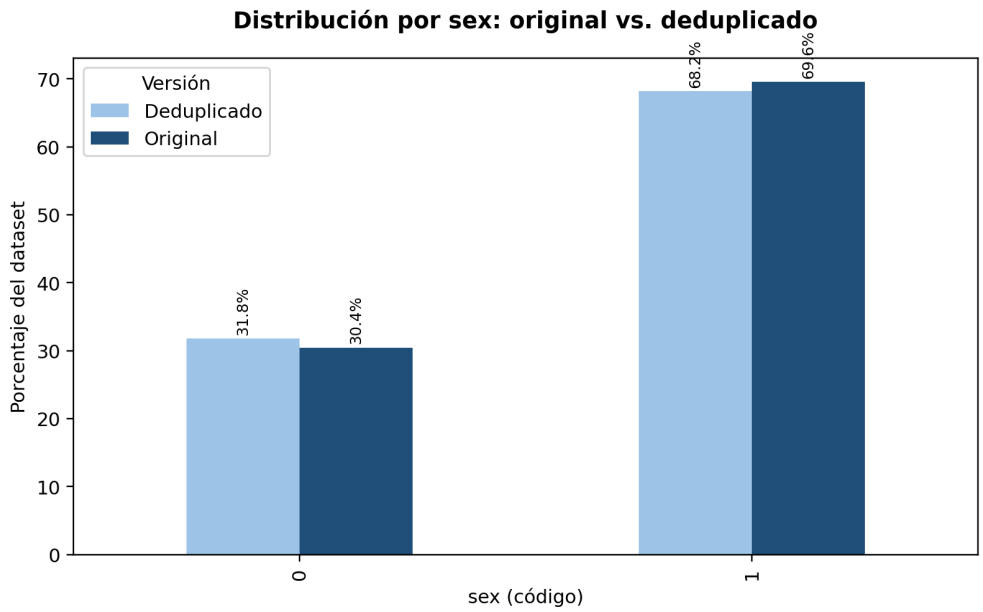


Figura 1: Comparación de la distribución de `sex` en el dataset original y deduplicado.

Cuadro 6: Distribución por rangos etarios: original versus deduplicado

Rango etario	Original (%)	Deduplicado (%)	Diferencia (pp)
< 40	5,56	4,97	-0,59
40–49	23,12	23,84	+0,72
50–59	41,17	41,39	+0,22
60–69	26,83	26,49	-0,34
70+	3,32	3,31	-0,01

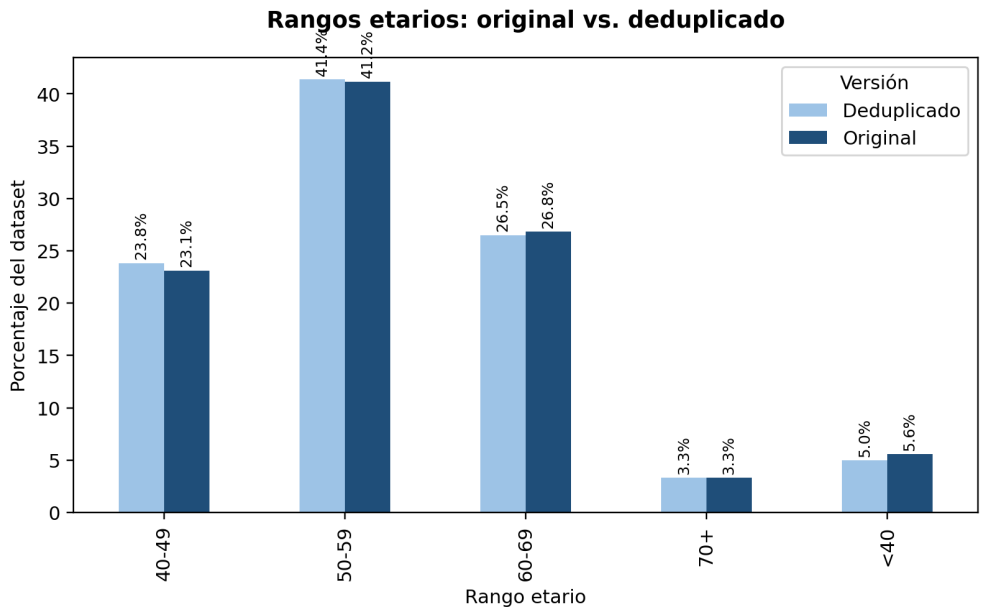


Figura 2: Comparación de los rangos etarios en el dataset original y deduplicado.

7.2. Representación y subgrupos

En la versión deduplicada, `sex`=0 (mujer) concentra 96 registros (31,79 %) y `sex`=1 (hombre) concentra 206 (68,21 %); esta codificación está documentada por UCI (Janosi et al., 1989). La diferencia de representación es una limitación de cobertura. El prototipo experimental descrito en la sección de modelado se evaluó en una partición pequeña; sus métricas globales no bastan para concluir desempeño confiable por subgrupos ni ausencia de sesgo. Los rangos < 40 (15 registros; 4,97 %) y 70+ (10; 3,31 %) disponen de poca evidencia. La figura 3 presenta los tamaños de las combinaciones `sex`×rango etario. Las intersecciones con cinco observaciones sólo permiten descripción exploratoria, no inferencia ni conclusión de equidad.

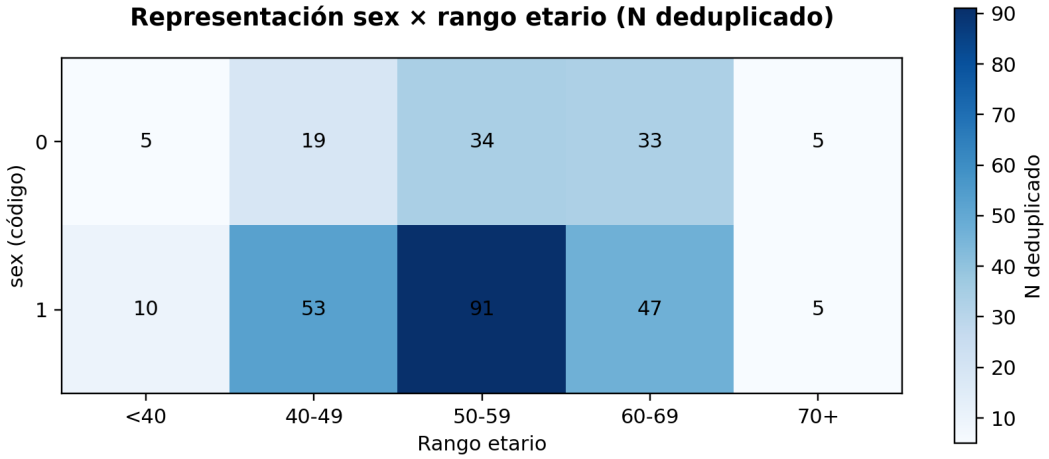


Figura 3: Tamaño deduplicado de los subgrupos `sex`×rango etario.

La evidencia sugiere posibles limitaciones de cobertura y generalización que deben validarse frente a la población objetivo. No permite afirmar discriminación ni extraer conclusiones sobre desempeño futuro por subgrupo.

8. Análisis ético y de sesgos

Este apartado convierte la evidencia de calidad, representatividad y evaluación experimental en controles para el proyecto académico. El repositorio incluye un prototipo de clasificación y métricas exploratorias; no existe validación clínica, evaluación suficiente por subgrupos ni autorización de uso asistencial. Por ello, las métricas no prueban utilidad clínica ni permiten atribuir o descartar discriminación algorítmica. La orientación es coherente con la necesidad de autonomía humana, transparencia, responsabilidad, inclusión y evaluación continua en sistemas de IA para salud (U.S. Food and Drug Administration, 2024; World Health Organization, 2021).

8.1. Evidencia, interpretación y límites

La fuente original contiene 1.025 filas, de las cuales 723 son duplicados exactos (70,54 %); la versión analítica deduplicada conserva 302 registros. Esto constituye un problema de calidad y de trazabilidad del muestreo: la coincidencia exacta no permite conocer su causa. Si más adelante se entrenara o evaluara un modelo sin controlar este punto, las observaciones repetidas podrían sobreponderar patrones e incluso contaminar una separación de entrenamiento y prueba. No se afirma que dicha contaminación haya ocurrido. La mitigación exigible es conservar el original, declarar el criterio de deduplicación y verificar que registros equivalentes no queden repartidos entre particiones; el criterio CA-E01 formaliza su aceptación.

En los 302 registros únicos hay 96 mujeres (`sex`=0; 31,79 %) y 206 hombres (`sex`=1; 68,21 %). La codificación está respaldada por la fuente UCI (Janosi et al., 1989). Esta diferencia describe cobertura desigual, no discriminación ni desempeño diferente. Su impacto técnico posible es que un modelo futuro disponga de menor evidencia para el grupo menos representado; por ello el eventual desempeño debe evaluarse por sexo con tamaño muestral suficiente y no se debe aprobar uso donde la evidencia no respalde la población objetivo.

La cobertura también es reducida en edades extremas: < 40 aporta 15 registros únicos (4,97 %), 50–59 concentra 125 (41,39 %) y 70+ sólo 10 (3,31 %). Las intersecciones mujeres $\times$ < 40 y mujeres $\times$70+ contienen cinco registros cada una. Estos tamaños hacen inestables los porcentajes descriptivos de `target`; no revelan prevalencia poblacional, causalidad ni discriminación. Las diferencias de `target` por sexo y edad ya registradas en `representatividad_subgrupos.csv` deben leerse sólo con esa cautela y con el N

correspondiente.

8.2. Impacto ético y técnico del uso futuro

El dataset de Kaggle sirve como evidencia académica inicial, pero no valida por sí mismo un uso en un hospital chileno. Pueden cambiar población, práctica clínica, medición y prevalencia; por ello la transferencia directa sería un riesgo de cambio de dominio. Cualquier paso hacia uso local requiere validación con datos y flujo clínico locales, además de monitoreo de deriva. Las guías para tecnologías clínicas de aprendizaje automático recomiendan comunicar límites de datos y poblaciones poco representadas, realizar validación específica del sitio y monitoreo continuo (U.S. Food and Drug Administration, 2024).

Un resultado automatizado no puede operar como diagnóstico ni decisión autónoma. Falsos negativos podrían omitir una revisión preventiva y falsos positivos podrían generar alertas o carga innecesarias; ambos efectos requieren un profesional que interprete el contexto, pueda discrepar y deje trazabilidad de la decisión. El esquema *Human in the Loop* es, por tanto, un requisito de control y no una característica opcional. SHAP puede apoyar explicaciones locales o globales, pero no prueba equidad ni reemplaza métricas por subgrupo, validación externa o supervisión clínica.

Privacidad y gobierno son igualmente éticos. El proyecto actual trabaja con el dataset académico local y no contiene datos de pacientes ni conexión institucional. Una eventual incorporación de datos clínicos requeriría propósito definido, autorización, minimización, pseudonimización, control de acceso, retención, auditoría y responsables; esos controles no se han implementado porque tal integración no existe.

8.3. Matriz de controles y criterios de aceptación

La cuadro 7 sintetiza la cadena evidencia–impacto–mitigación–aceptación. La versión completa y reutilizable se encuentra en `outputs/tables/matriz_etica.csv`; su generación desde los archivos original y deduplicado es reproducible mediante el script documentado en `src/`.

Cuadro 7: Matriz ética consolidada

ID	Hallazgo y evidencia	Impactos potenciales	Mitigación y aceptación
E01	Duplicación masiva y trazabilidad del tratamiento de datos. 1025 filas originales; 723 duplicadas exactas (70,54 %); 302 únicas.	Técnico: Sobreponderación de patrones y posible contaminación entre particiones si se modela sin control. Ético: Decisiones basadas en evidencia de calidad incierta.	Conservar el original, documentar deduplicación y verificar separación por registro único antes de modelar. CA-E01: tratamiento de duplicados documentado y verificable.
E02	Cobertura desigual por sexo. Únicos: mujeres (sex=0) 96 (31,79 %); hombres (sex=1) 206 (68,21 %).	Técnico: Menor evidencia para estimar desempeño futuro en el grupo menos representado. Ético: Riesgo de uso inequitativo si no se evalúa la cobertura y el desempeño posterior.	Reportar métricas por sexo sólo al existir modelo y tamaño suficiente; no extrapolar cobertura a población. CA-E02 y CA-E04.
E03	Cobertura limitada en extremos etarios. Únicos: <40=15 (4,97 %); 50–59=125 (41,39 %); 70+=10 (3,31 %).	Técnico: Estimaciones inestables y generalización incierta en grupos con N reducido. Ético: Posible inequidad si se usa fuera de los grupos respaldados.	Definir mínimo N, evaluar por edad cuando corresponda y restringir uso no respaldado. CA-E03 y CA-E04.
E04	Evidencia interseccional insuficiente. Mujeres <40=5; mujeres 70+=5 registros únicos.	Técnico: Porcentajes y métricas por intersección serían altamente inestables. Ético: Conclusiones aparentes podrían invisibilizar incertidumbre de grupos pequeños.	Informar N junto con porcentajes; no aprobar uso en combinaciones sin evidencia suficiente. CA-E03 y CA-E04.
E05	Diferencias descriptivas de target entre subgrupos. Las proporciones de target por sexo y edad están exportadas con N en representatividad_subgrupos.csv.	Técnico: No permiten inferir desempeño, prevalencia ni causalidad. Ético: Interpretación indebida como diferencia poblacional o discriminación.	Tratar resultados como descriptivos; contrastar con validación clínica/local posterior. CA-E05: validación con datos locales antes de uso.

Cuadro 8: Matriz ética consolidada (continuación)

ID	Hallazgo y evidencia	Impactos potenciales	Mitigación y aceptación
E06	Cambio de dominio Kaggle hacia hospital chileno. Dataset académico externo; no representa por sí mismo la población ni el flujo clínico local.	Técnico: Deriva de población, medición o práctica clínica; desempeño no transferible. Ético: Riesgo de daños o acceso inequitativo por generalización injustificada.	Validación local prospectiva, documentación de población objetivo y monitoreo de deriva. CA-E05 y CA-E09.
E07	Automatización y posibles falsos negativos o positivos. Existe un modelo experimental con métricas preliminares; no hay modelo ni métrica clínicamente validados.	Técnico: Alertas erróneas u omisiones si un resultado se interpreta como decisión clínica. Ético: Daño potencial, sesgo de automatización y dilución de responsabilidad.	Human in the Loop, protocolo de revisión, registro de decisión y uso exclusivamente preventivo. CA-E06 y CA-E10.
E08	Privacidad y gobierno del dato sensible. El prototipo usa un dataset académico y no procesa datos de pacientes ni se conecta a sistemas institucionales.	Técnico: Acceso indebido, retención excesiva o trazabilidad insuficiente. Ético: Afectación de confidencialidad y autonomía de las personas.	Mantener el uso local con datos académicos; exigir autorización y controles antes de una futura integración clínica. CA-E08.
E09	Transparencia y explicabilidad insuficientes. Existe un modelo experimental con métricas globales y explicaciones SHAP globales/-locales; la muestra es pequeña y no hay evaluación suficiente por subgrupos ni validación externa.	Técnico: No detectar límites o errores por subgrupo mediante explicaciones aisladas. Ético: Confianza injustificada y falta de rendición de cuentas.	Documentar transformaciones, versiones, métricas y límites; no presentar explicabilidad como prueba de equidad. CA-E07 y CA-E09.

8.4. Gates propuestos antes de un piloto

Los criterios de aceptación no autorizan el prototipo experimental para uso asistencial. Se proponen como condiciones pendientes para cualquier etapa clínica futura: CA-E01, tratamiento documentado de duplicados (aplicado en este flujo académico); CA-E02, desempeño por sexo cuando exista N suficiente; CA-E03, desempeño por rango etario cuando exista N suficiente; CA-E04, no aprobar uso en grupos sin cobertura respaldada; CA-E05, validación con datos locales; CA-E06, supervisión humana obligatoria; CA-E07, explicabilidad documentada; CA-E08, pseudonimización y control de acceso; CA-E09, monitoreo de deriva; y CA-E10, alcance limitado a apoyo preventivo, sin diagnóstico ni decisión automática. La aceptación final requiere evidencia y responsables institucionales.

9. Modelado experimental y resultados

La actividad técnica añade un prototipo local reproducible en `notebooks/04_implementacion_tecni` Se entrena sobre los 302 registros únicos, con partición estratificada de 226 observaciones para entrenamiento y 76 para prueba (semilla 42). Los modelos nuevos utilizan codificación one-hot para predictores categóricos; la regresión logística aplica `RobustScaler` a variables cuantitativas. El preprocesamiento se ajusta dentro del pipeline de validación cruzada para evitar fuga de información.

Se compararon cinco folds sobre el conjunto de entrenamiento. La regresión logística de referencia obtuvo ROC-AUC medio de 0,919 ± 0,052; XGBoost one-hot somero obtuvo 0,914 ± 0,055; XGBoost one-hot regularizado 0,913 ± 0,061; y el baseline XGBoost ordinal 0,917 ± 0,062. Como experimento de ingeniería se añadió la interacción `oldpeak` × `exang` al XGBoost one-hot somero (0,912 ± 0,056), y se probaron splines cuadráticas de tres nudos en las variables continuas de la logística (0,904 ± 0,043). El cambio medio pareado contra sus respectivas referencias fue $-0,002$ y $-0,015$ ROC-AUC; ninguno mostró mejora consistente. Por ello, ambas transformaciones quedan sólo como experimentos y no se incorporan al artefacto. Se eligió el XGBoost one-hot somero como artefacto final para cumplir el requisito de entrenamiento local con GPU, aunque no tuvo el mayor promedio de validación cruzada.

Para evaluar la sensibilidad a la partición se repitieron cinco folds diez veces usando sólo el conjunto de entrenamiento. La interacción XGBoost obtuvo ROC-AUC medio 0,91279 frente a 0,91262 de su referencia (delta $+0,00016$); mejoró en cuatro repeticiones y empeoró en seis, con mediana de delta $-0,00078$. La logística con splines obtuvo 0,90099 frente a 0,91897 y quedó por debajo en las diez repeticiones (delta medio $-0,01798$). Los folds repetidos comparten observaciones y no son muestras independientes; se reportan como diagnóstico de estabilidad, sin inferencia estadística. No hay evidencia consistente de mejora para conservar esas transformaciones.

Por esa razón no se implementan en el pipeline final. El XGBoost con profundidad máxima 2 ya puede representar interacciones simples con divisiones sucesivas, por lo que el producto explícito no añade una ventaja medida que compense más procesamiento. Las splines aumentan los grados de libertad de la logística en un entrenamiento de sólo 226 registros y empeoran en las diez repeticiones. La decisión evita complejidad adicional y posible ajuste a peculiaridades de la muestra sin una mejora reproducible; no implica que cualquier ingeniería de variables sea inútil.

En la prueba retenida, el baseline ordinal obtuvo accuracy 0,789, precisión de clase positiva 0,791, recall 0,829, F1 0,810 y ROC-AUC 0,875. El XGBoost one-hot seleccionado obtuvo 0,776, 0,786, 0,805, 0,795 y 0,875, respectivamente. Las matrices de confusión muestran exactamente 60/76 aciertos para el baseline y 59/76 para one-hot: ambos clasificaron correctamente los mismos 26 casos de clase 0 y cometieron 9 falsos positivos; el baseline acertó un caso positivo más (34 vs. 33) y tuvo un falso negativo menos (7 vs. 8). Por eso su accuracy fue 1,32 puntos porcentuales mayor en esta prueba. La diferencia depende de un solo caso; no demuestra superioridad estable. Las curvas ROC tienen el mismo AUC (0,875), por lo que la capacidad global de ordenar los scores fue igual en la prueba. El one-hot sigue siendo una representación metodológicamente más apropiada para códigos categóricos nominales; que el ordinal gane por un acierto no justifica imponer orden numérico ni descartar el tratamiento correcto. Con sólo 76 casos no se afirma diferencia estadística ni superioridad predictiva.

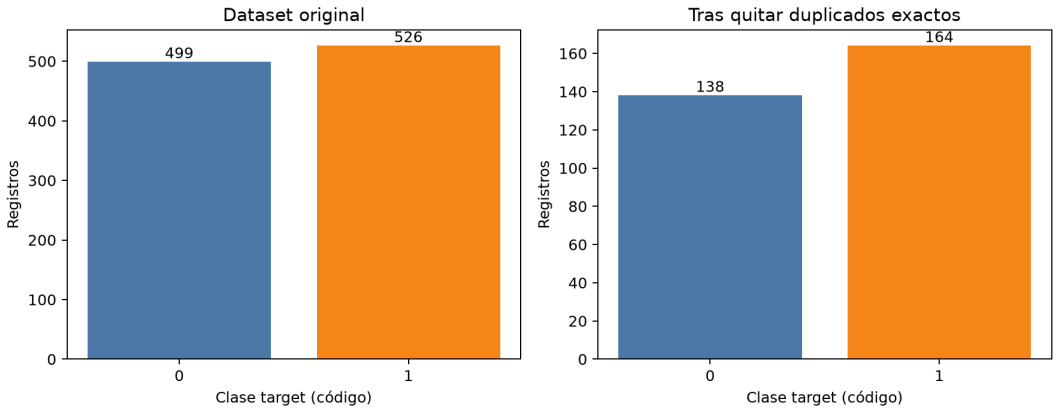


Figura 4: Distribución de clases antes y después de deduplicar. El cambio de proporciones respalda documentar el tratamiento de duplicados antes de particionar.

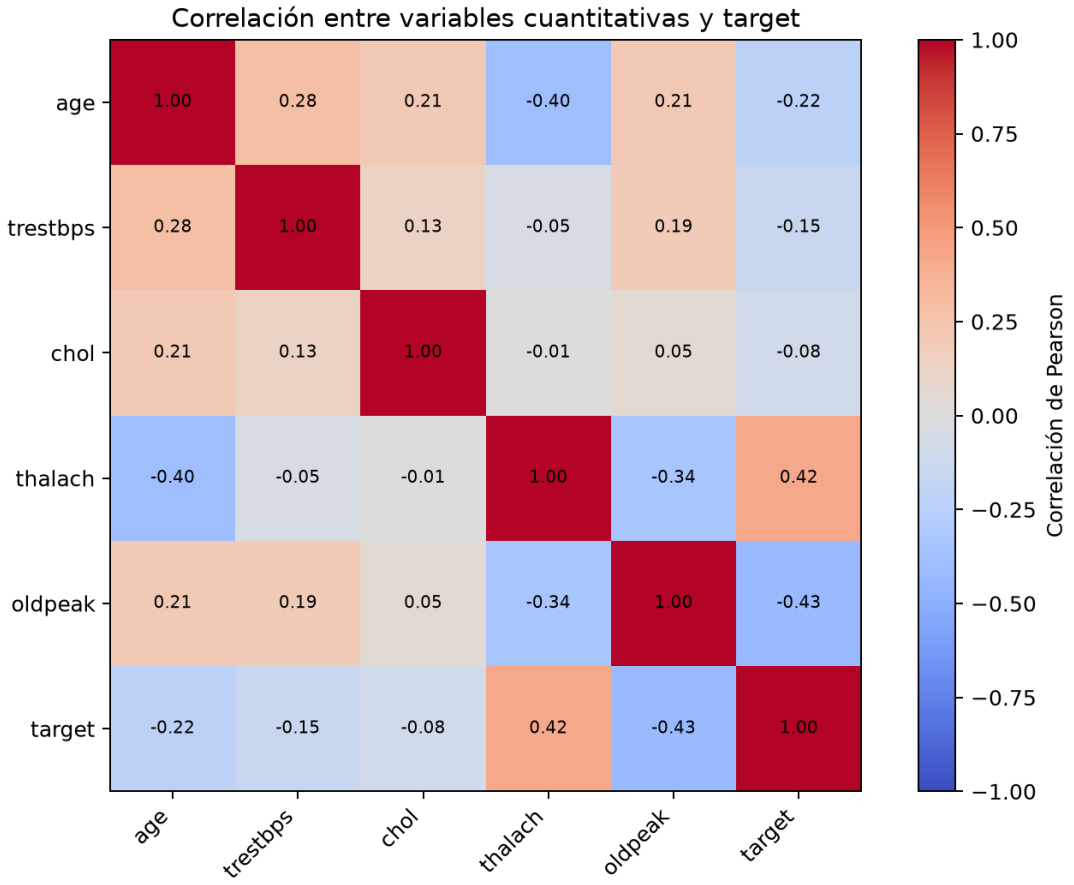


Figura 5: Correlación Pearson de variables cuantitativas con `target`. Es una asociación descriptiva, no evidencia causal.

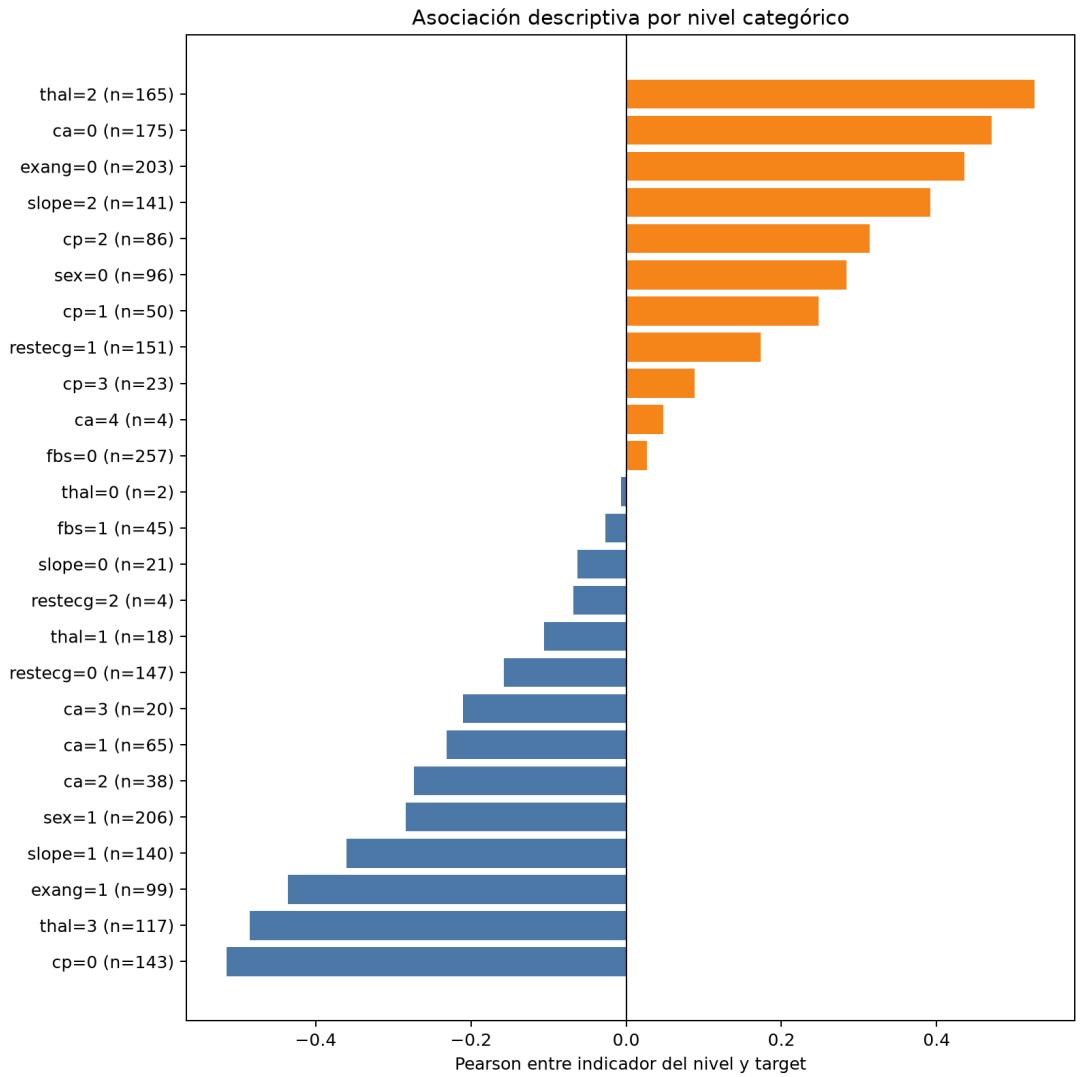


Figura 6: Asociación descriptiva entre niveles categóricos y `target`; los tamaños de muestra varían entre niveles.

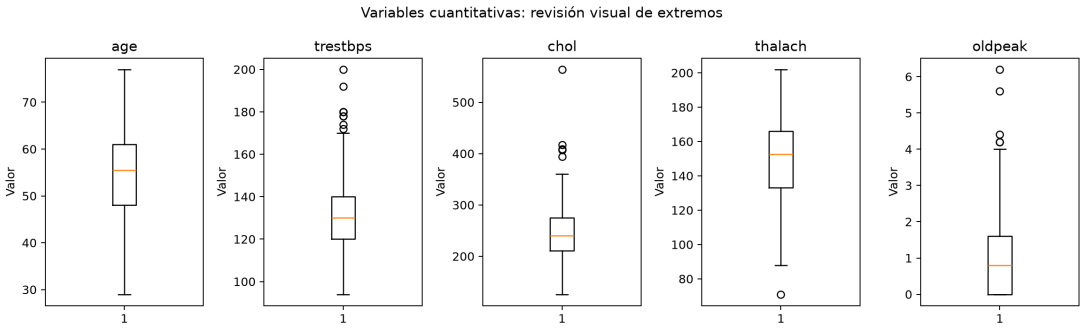


Figura 7: Distribuciones y valores candidatos a revisión por la regla de 1,5 IQR. Los extremos se conservaron porque no se confirmaron como errores.

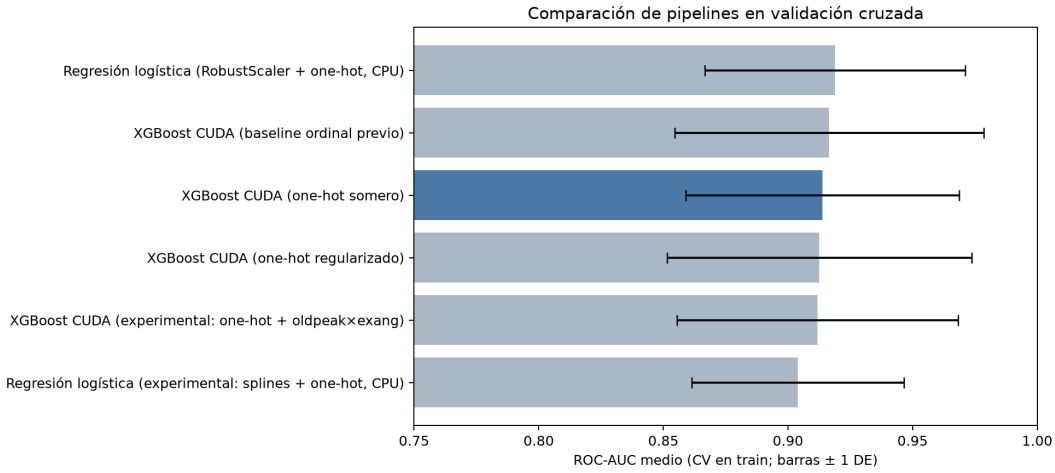


Figura 8: ROC-AUC medio y dispersión en validación cruzada para pipelines evaluados sobre los mismos folds.

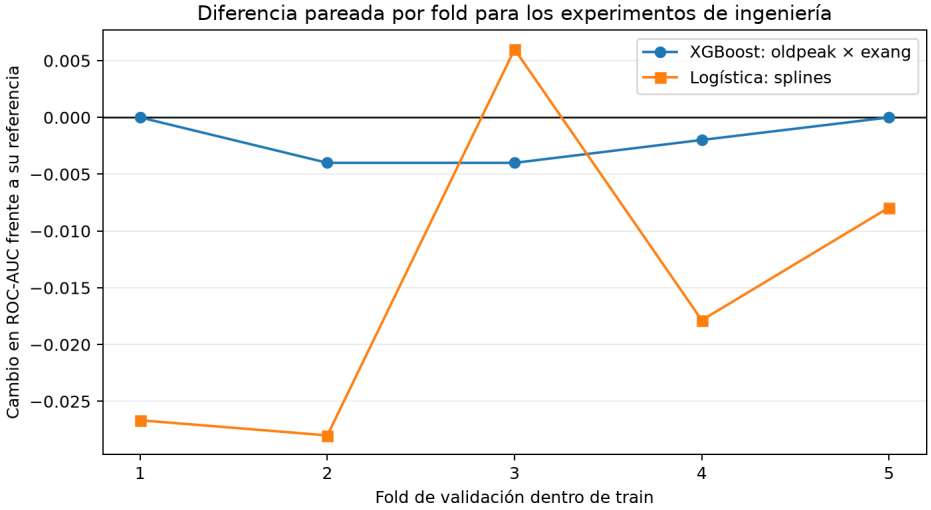


Figura 9: Cambio pareado de ROC-AUC por fold para la interacción XGBoost y las splines logísticas, cada una frente a su referencia. Ninguna transformación mejora de forma consistente.

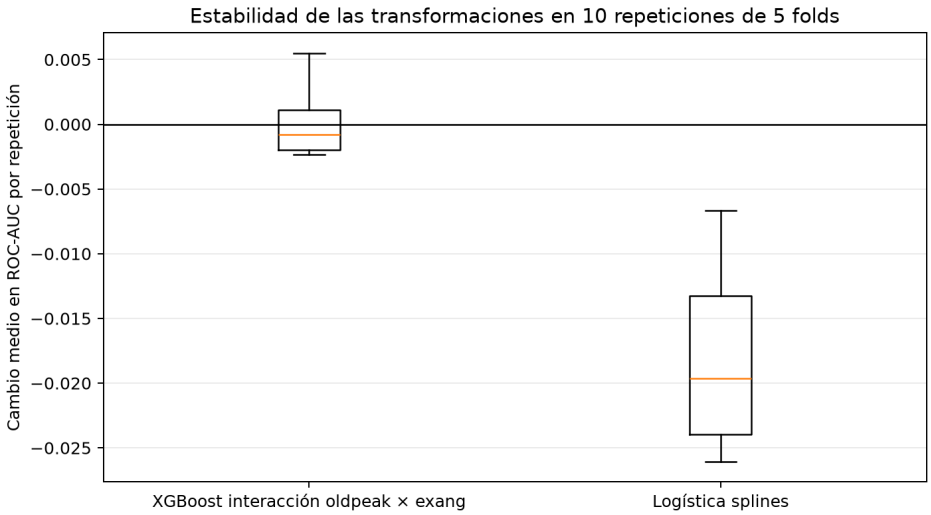


Figura 10: Distribución de diferencias medias por repetición de cinco folds. La interacción XGBoost queda centrada cerca de cero; las splines logísticas son inferiores en las diez repeticiones.

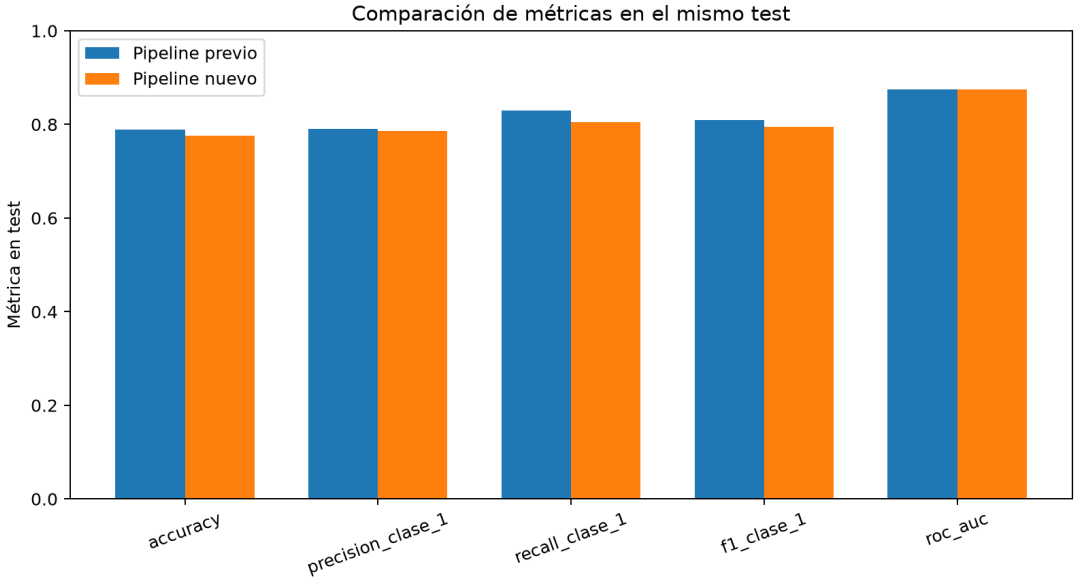


Figura 11: Métricas del baseline ordinal y del modelo one-hot en la misma partición de prueba. No se observa mejora general del modelo nuevo.

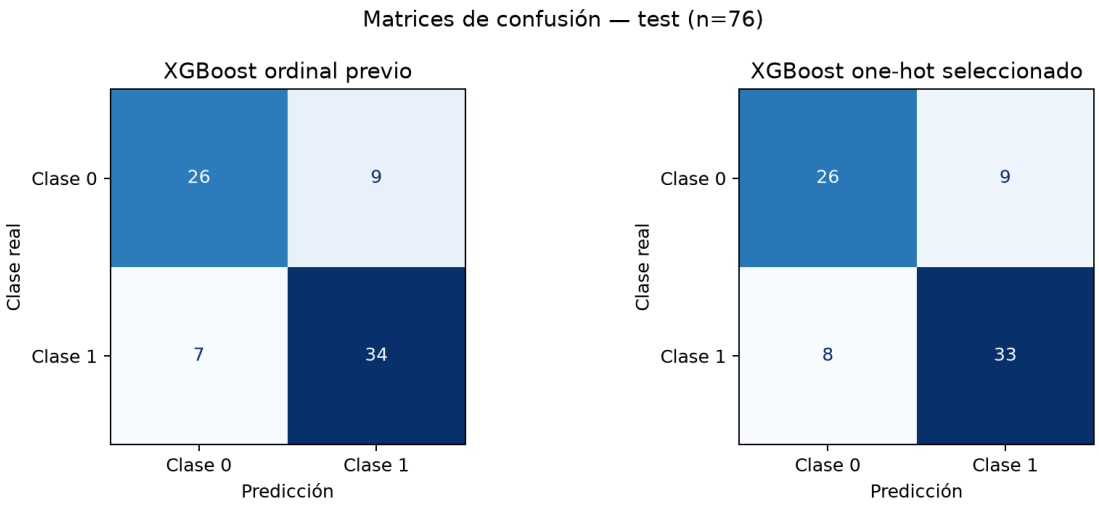


Figura 12: Conteos de clase real y predicción para los mismos 76 registros. La diferencia de accuracy corresponde a un único caso positivo adicional acertado por el baseline ordinal.

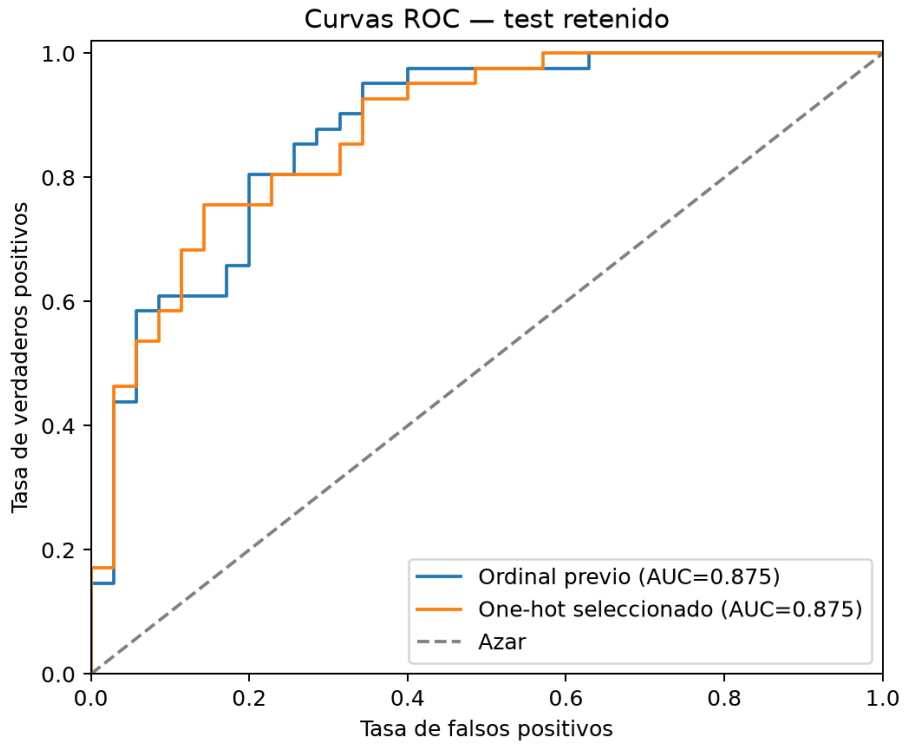


Figura 13: Curvas ROC sobre la prueba retenida. El área bajo ambas curvas es 0,875; el gráfico resume discriminación a distintos umbrales, no exactitud ni calibración.

9.1. Explicabilidad comparativa de los XGBoost

La matriz de confusión informa cuántos casos acierta o falla, pero no atribuye esos resultados a predictores. Se calcularon contribuciones TreeSHAP nativas de XGBoost (`pred_contribs`) para el pipeline one-hot seleccionado y para el baseline ordinal que obtuvo más accuracy. En el primero se agruparon los indicadores one-hot por variable fuente; en el

ordinal se explicaron las 13 columnas entregadas al árbol. La suma de contribuciones más el valor base reconstruye el margen log-odds; esta propiedad se verificó numéricamente. Las atribuciones describen el comportamiento del modelo, no causas clínicas (XGBoost developers, s.f.).

Ambos modelos destacan las mismas tres variables en promedio absoluto sobre las 302 observaciones únicas: `cp` (one-hot 0,971; ordinal 0,872 log-odds), `ca` (0,855; 0,643) y `thal` (0,599; 0,479). Después aparecen `oldpeak` (0,407; 0,362), `sex` (0,395; 0,248) y `thalach` (0,346; 0,210). Ambos asignan cero a `fbs` en estos registros; esto describe los artefactos, no la relevancia clínica de esa variable. La magnitud no es una unidad de probabilidad ni importancia causal. Los códigos categóricos del baseline se modelan como enteros ordenados; esa suposición puede influir en las atribuciones y es una razón para preferir one-hot al representar categorías nominales.

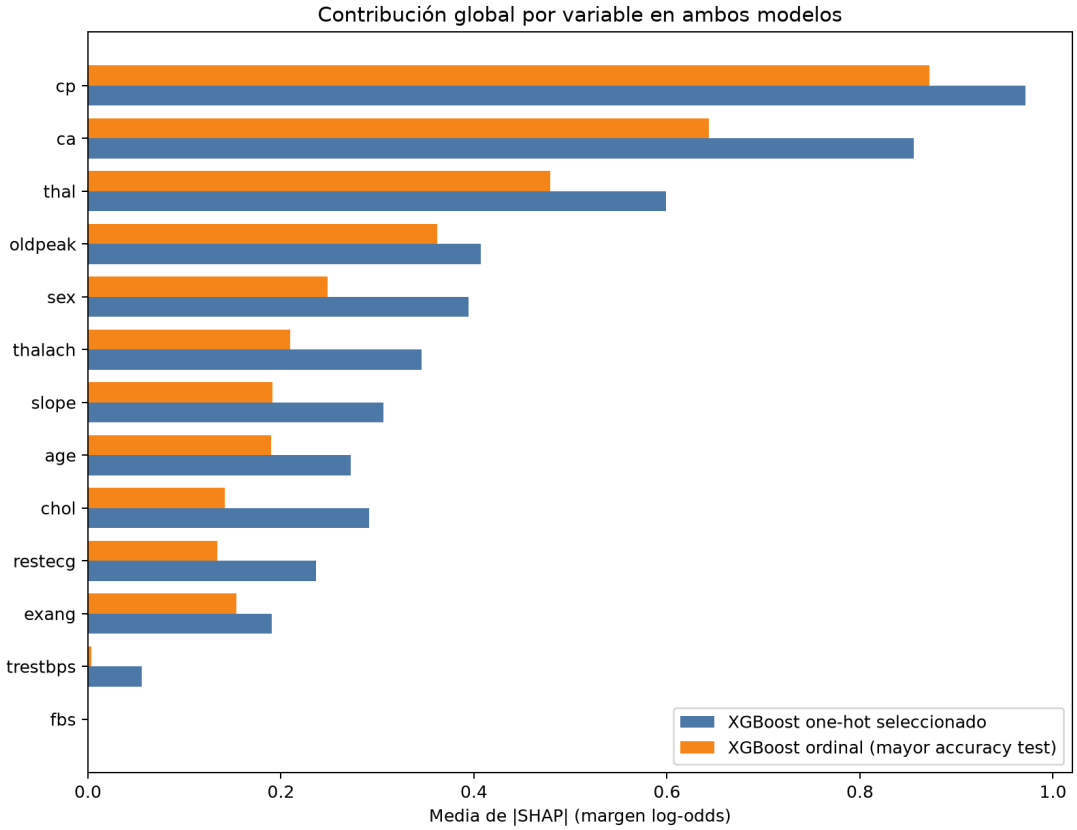


Figura 14: Media de contribuciones SHAP absolutas por variable en ambos modelos, sobre los 302 registros únicos.

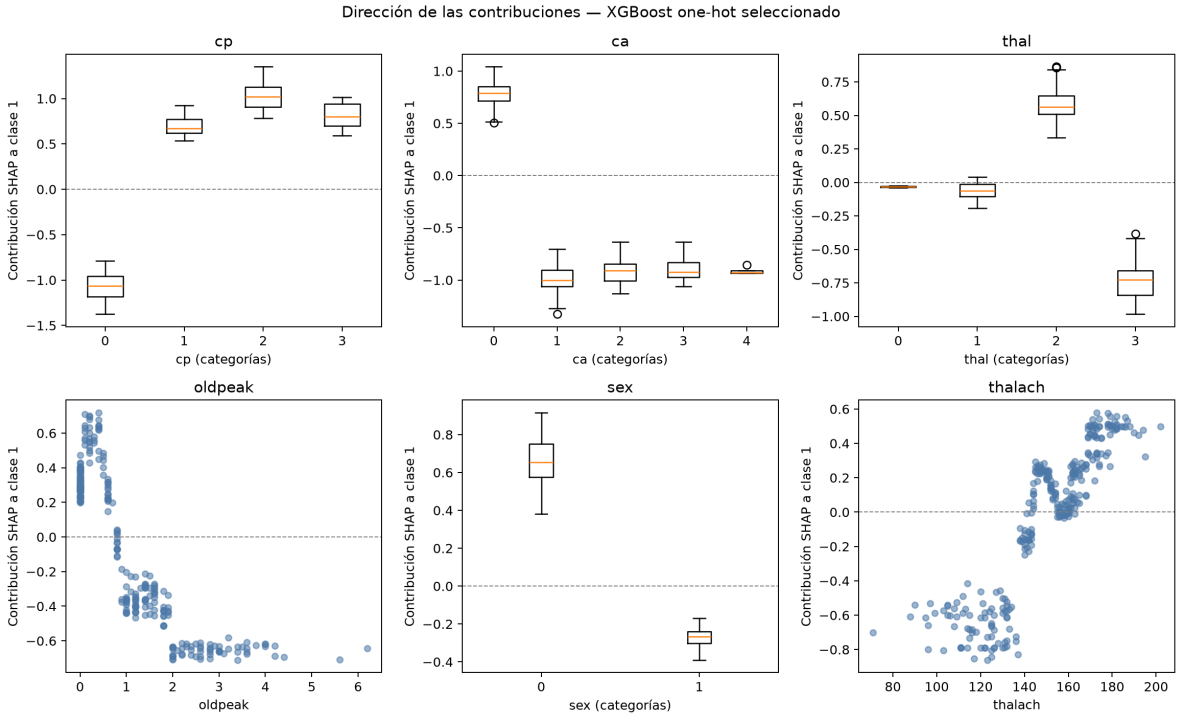


Figura 15: Dirección y dispersión de las atribuciones en los datos observados. En variables categóricas cada boxplot corresponde a un nivel separado; su eje no representa una escala ordinal.

Como explicación local se descompusieron un falso negativo (fila 5 del conjunto único: real 1, predicho 0) y un falso positivo (fila 33: real 0, predicho 1). El baseline ordinal, que obtuvo 60/76 aciertos, dio scores de clase 1 de 0,388 y 0,852; el one-hot, que obtuvo 59/76, dio 0,300 y 0,848 en esos mismos casos. Las etiquetas de fila son índices técnicos, no identificadores de pacientes. Las barras muestran cómo cada predictor empujó el margen de esos casos hacia una clase; no demuestran por qué ocurrió el resultado real.

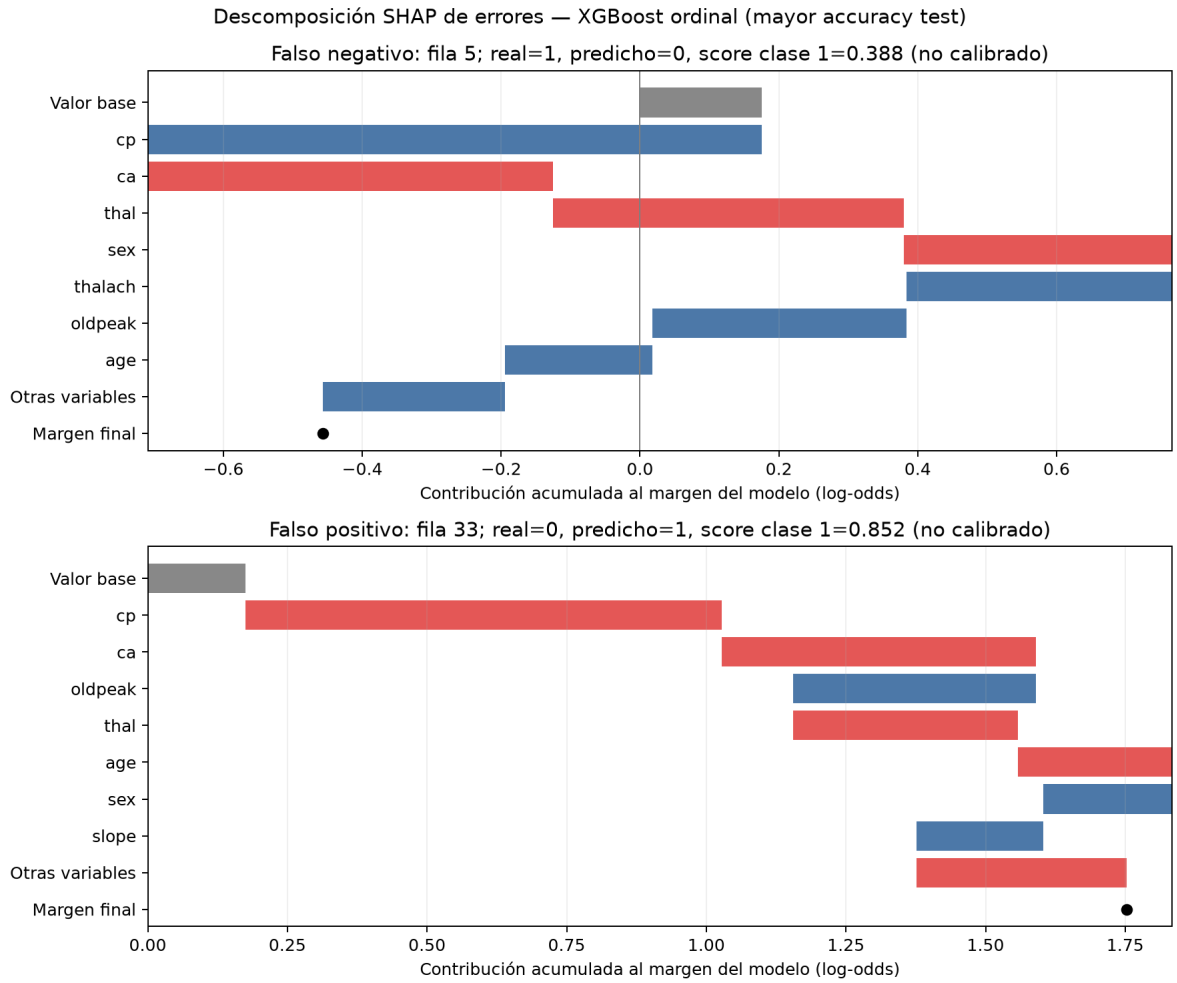


Figura 16: Descomposición TreeSHAP de dos errores del baseline ordinal, el XGBoost con mayor accuracy de prueba. Rojo empuja hacia clase 1 y azul hacia clase 0. Scores no calibrados.

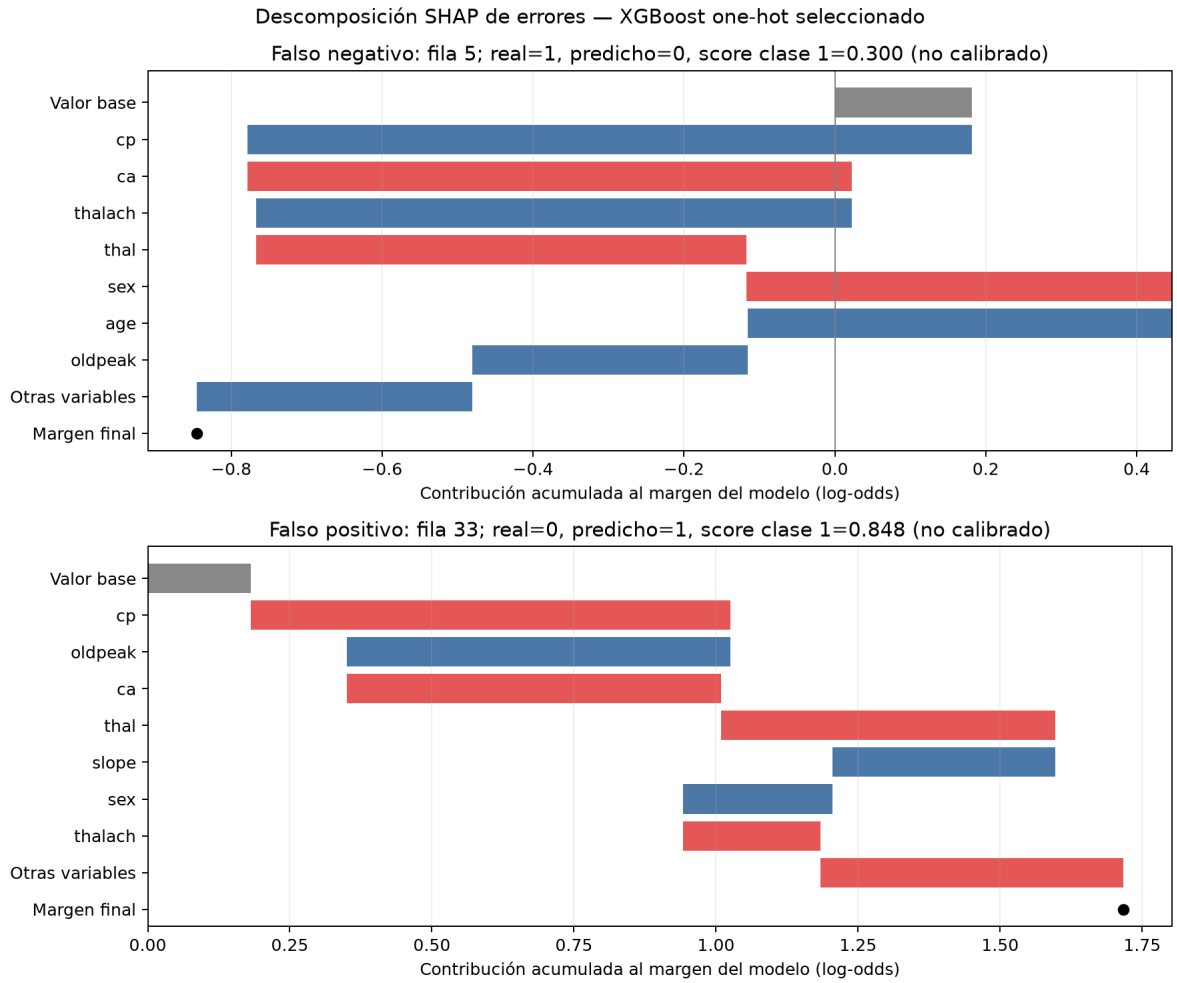


Figura 17: Los mismos casos explicados con el pipeline XGBoost one-hot seleccionado.

Se amplió el análisis a los 17 errores del test: 8 falsos negativos y 9 falsos positivos. En ambos grupos, `cp`, `ca` y `thal` tienen las mayores contribuciones SHAP absolutas medias. Para los falsos negativos, el SHAP firmado medio de `cp` fue $-0,565$ log-odds; entre falsos positivos, las mayores contribuciones firmadas medias fueron `cp` $(+0,558)$ y `ca` $(+0,566)$. Esas atribuciones explican el score del modelo en los errores observados, no su causa real.

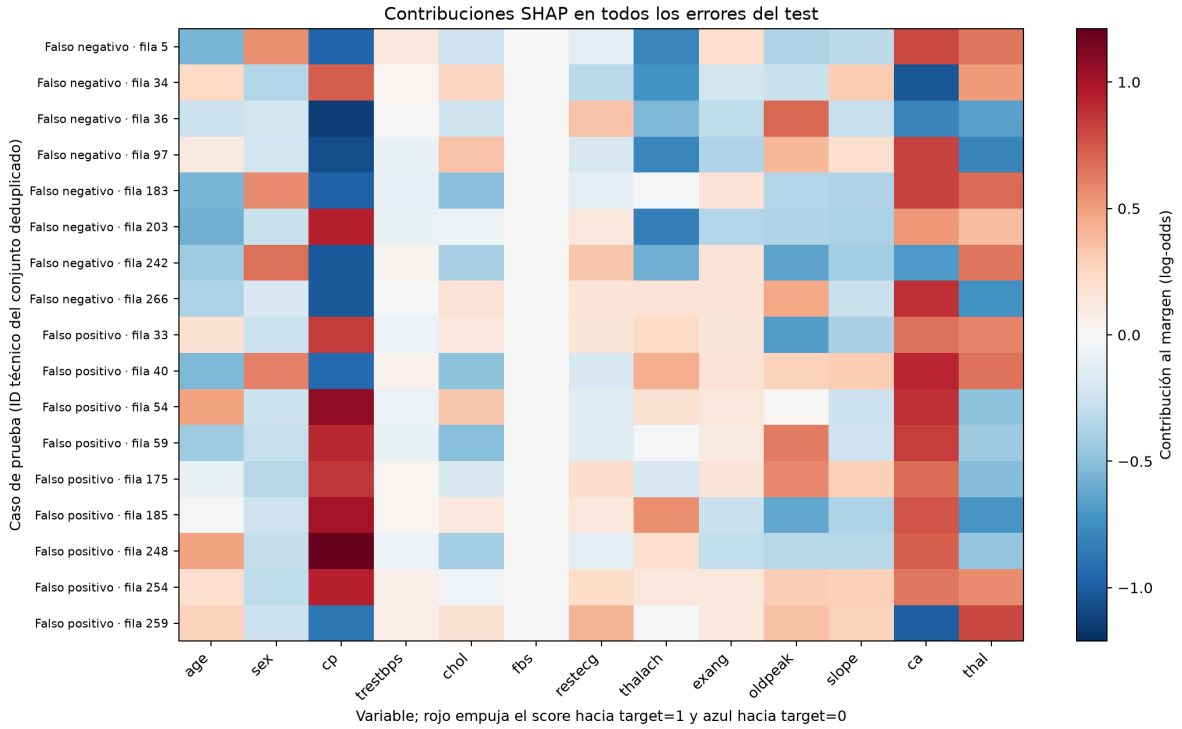


Figura 18: Mapa SHAP de todos los errores del test one-hot; azul empuja hacia target=0 y rojo hacia target=1.

Como revisión descriptiva de cobertura, se midieron recall y especificidad por código de `sex` y rango etario en la misma partición. Para `sex=0` (n=22), fueron 0,813 y 0,833; para `sex=1` (n=54), 0,800 y 0,724. Los intervalos Wilson son amplios y se solapan. Los grupos etarios menores de 40 y de 70 o más tienen tres casos cada uno; sus tasas no permiten comparaciones. No se concluye presencia ni ausencia de sesgo.

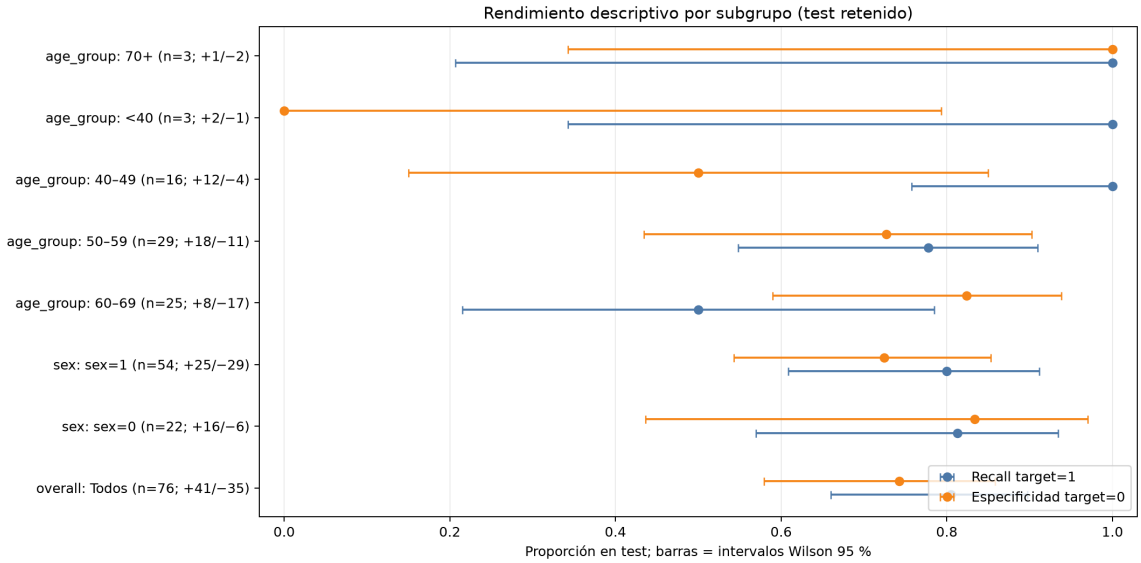


Figura 19: Recall y especificidad por subgrupo en el test, con intervalos Wilson del 95 % y tamaño/conteo de clases. Los grupos pequeños son inestables.

El artefacto `outputs/models/heart_disease_pipeline.joblib` registra entrenamiento con XGBoost 3.2.0 y `cuda:0` en una NVIDIA GeForce RTX 4060 Laptop GPU. La automatización `src/automatizacion_predicciones.py` procesa cinco filas sintéticas de ejemplo; sus scores no están calibrados y no son probabilidades clínicas. El modelo no está desplegado, no se evaluó en datos locales chilenos y no se autoriza para diagnóstico, tratamiento o priorización asistencial.

El análisis reproducible está en el notebook local de auditoría de errores y subgrupos; los gráficos, tablas, entorno `uv` y pasos de ejecución se describen en la documentación técnica. La guía solicita además guardar el notebook en Google Drive; este repositorio sólo acredita la copia local, por lo que no afirma que ese requisito externo se haya completado.

10. Análisis D1

10.1. Alcance funcional

La solución incluye: ingesta controlada de datasets cardiovasculares; validación de calidad; preparación para análisis y modelamiento; análisis exploratorio orientado al problema; comparación conceptual de modelos candidatos; métricas técnicas, estabilidad y evaluación por subgrupos; explicabilidad; una interfaz interna de referencia; versionado y trazabilidad del modelo; monitoreo de degradación, drift y fallos operacionales; y documentación de arquitectura, supuestos, riesgos, procedimientos y operación.

10.2. Fuera de alcance

Quedan expresamente fuera de alcance el diagnóstico médico automático, las recomendaciones automáticas de tratamiento, la negación o asignación automática de atención, la sustitución de personal sanitario, la integración productiva completa con HIS/EHR, el despliegue clínico definitivo y una plataforma nacional o multihospital desde el inicio. Estas exclusiones reducen el riesgo clínico y ético, respetan la información disponible y mantienen el proyecto dentro de un piloto institucional controlado.

10.3. Arquitectura lógica común

Para comparar las tres alternativas de manera justa, todas resuelven el mismo problema y mantienen el mismo alcance funcional. La cadena lógica es: fuente de datos hospitalaria, validación y control de calidad, almacenamiento estructurado o analítico, preparación y procesamiento, modelo o servicio de inferencia, API de aplicación, interfaz de usuario, y monitoreo, trazabilidad y respaldo.

Las diferencias de costo no deben provenir de comparar productos con funcionalidades distintas. Cambia dónde se ejecutan los componentes, quién los administra y cómo se

distribuyen los costos y riesgos.

11. Arquitectura y herramientas cloud (antecedente D2)

La comparación de plataformas Cloud de documentos anteriores pertenece a un alcance institucional que ya no está vigente. El repositorio actual no despliega el modelo en GCP ni requiere servicios gestionados para completar la actividad de diez semanas. El entrenamiento documentado se realiza localmente con XGBoost y CUDA; la inferencia de ejemplo corre mediante un script local sobre CSV.

Por trazabilidad se conserva el análisis conceptual previo de servicios y riesgos, pero no constituye arquitectura seleccionada, decisión de compra ni compromiso de implementación del alcance vigente. La nube, Vertex AI y cualquier plataforma MLOps quedan fuera del estado implementado.

12. Alternativa local y estado implementado (antecedente D3)

La ejecución comprobable del proyecto ocurre en entorno local. El entorno Python se fija mediante `uv`; el notebook entrena XGBoost con CUDA y registra el dispositivo `cuda:0`. La GPU utilizada fue una NVIDIA GeForce RTX 4060 Laptop GPU. Para el comando de inferencia, el modelo guardado se carga localmente y procesa un CSV; los datos de ejemplo son sintéticos.

Este entorno local es el utilizado para desarrollo y demostración, no una infraestructura hospitalaria on-premise. No se han documentado servidor institucional, red clínica, base de datos productiva, controles corporativos, respaldos, SLA ni continuidad. Las estimaciones de hardware y operación de versiones anteriores se consideran fuera del alcance actual.

13. Alternativa híbrida (antecedente D4)

La alternativa híbrida que se evaluó en documentos previos suponía identidad y registro clínico locales, con analítica en nube. Esa arquitectura no está implementada ni forma parte de la línea base vigente de diez semanas. No existe sincronización de datos, transferencia a GCP, interfaz clínica o integración con sistemas institucionales en el repositorio.

Se conserva el análisis anterior únicamente como antecedente de planificación. Cualquier futura transferencia de datos de salud requeriría autorización, minimización, pseudonimización y controles institucionales aplicables; este prototipo y sus predicciones sintéticas no

satisfacen por sí mismos dichos requisitos.

14. Herramientas y stack implementado (D5)

El stack comprobable en la actividad 3.1.2 se centra en Python y herramientas de ciencia de datos para un prototipo local reproducible.

Python y uv
Entorno del proyecto declarado en `pyproject.toml`, fijado en `uv.lock` y reproducible mediante `uv sync`.

Pandas y NumPy
Lectura, auditoría y preparación de datos tabulares.

Scikit-learn
Pipelines, codificación, escalado, regresión logística comparativa, partición y validación cruzada.

XGBoost con CUDA
Clasificador basado en árboles y candidato final ejecutado localmente en GPU NVIDIA.

Joblib
Serialización del pipeline entrenado, incluyendo transformaciones y modelo.

Jupyter
Registro ejecutable del flujo de análisis, gráficos, evaluación y cinco predicciones sintéticas.

PostgreSQL, SHAP, FastAPI, Streamlit, Docker, GCP, Vertex AI y MLOps aparecen en propuestas o versiones anteriores; no están implementados en la actividad actual. El script de inferencia es una automatización batch local, no un servicio API ni una aplicación institucional.

15. Análisis D6

15.1. Justificación de Scrum, PMBOK y CRISP-DM

El desarrollo necesita feedback frecuente porque los requisitos, los datos, los riesgos y la solución pueden cambiar al generar evidencia. Scrum es apropiado para esa parte del trabajo: ordena el backlog, define objetivos de sprint y exige un incremento revisable.

No se usa Scrum para reemplazar las responsabilidades institucionales de aprobación, presupuesto, riesgos o protección de datos.

PMBOK conserva la línea base de alcance, objetivos, costos, calendario, riesgos, comunicaciones y cambios. CRISP-DM estructura las actividades técnicas de datos dentro de los sprints. La combinación de responsabilidades permite ajustar el trabajo técnico ante evidencia de calidad, desempeño, privacidad, sesgos y factibilidad, sin cambiar la línea base sin una decisión documentada.

15.2. Criterios completos de comparación

Desarrollo

Scrum permite priorizar requerimientos, revisar incrementos y tratar impedimentos cada sprint.

Incertidumbre

CRISP-DM permite repetir comprensión, preparación y evaluación cuando los datos o resultados lo exijan.

Cambios

PMBOK exige registrar impacto en alcance, costo, calendario, riesgos y controles antes de actualizar la línea base.

Retroalimentación

Las revisiones de sprint hacen visible la evidencia al Product Owner propuesto y al equipo; los gates conservan la aprobación institucional.

Datos y modelos

El trabajo técnico conserva trazabilidad entre dataset, baseline, candidatos, explicabilidad y evaluación por subgrupos.

Riesgos

Los riesgos se revisan durante sprints y gates, con mitigación, responsable y evidencia de control.

Adecuación

Scrum, PMBOK y CRISP-DM cubren necesidades distintas y complementarias, sin sustituirse entre sí.

El efecto transversal es claro: la EDT y la carta Gantt deben considerar sprints, revisiones y gates; finanzas debe presupuestar iteración y contingencia; riesgos debe actualizarse al aparecer nueva evidencia; y la evaluación ética debe acompañar el ciclo completo.

16. Estimación financiera de la ejecución académica (D7–D11)

La línea base financiera vigente corresponde al informe EP3 corregido y cubre exclusivamente diez semanas, del 5 de octubre al 13 de diciembre de 2026. El presupuesto estimado es **$10.506.069 CLP**: $9.040.972 para tres perfiles con dedicación parcial, $100.000 para asesoría legal/seguridad puntual, $250.000 de infraestructura demostrativa y una reserva de $955.097 (10 % del subtotal directo de $9.550.972). Las duraciones se expresan en semanas calendario y las dedicaciones parciales no equivalen a tres jornadas completas durante todo el periodo.

La cifra es una estimación académica de planificación, no una factura, cotización vinculante, presupuesto aprobado ni costo de operación institucional. No incorpora mantenimiento posterior a las diez semanas, certificaciones sanitarias, integración hospitalaria ni despliegue clínico. La ejecución depende de autorización, gobierno de datos, revisión de seguridad y validación local cuando corresponda.

Cuadro 9: Presupuesto de referencia para diez semanas

Componente	CLP
Profesionales: coordinación/negocio, ciencia de datos/ML y Full Stack	$9.040.972
Asesoría legal y seguridad puntual	$100.000
Infraestructura demostrativa	$250.000
Subtotal directo	$9.550.972
Reserva de contingencia (10 %)	$955.097
Total estimado de diez semanas	**$10.506.069**

Los modelos de costo y operación Cloud/Local/Híbrida pertenecen a una versión previa del alcance y quedan **retirados como línea base financiera del proyecto actual**. No se prorratean para diez semanas: los supuestos institucionales fueron retirados. Cualquier presupuesto adicional requerirá una definición y respaldo nuevos.

El informe de monitoreo 3.2.2 contiene una planificación didáctica con tareas, horas y estados de seguimiento. Se conserva como evidencia de actividad académica y no se suma al presupuesto EP3 ni se presenta como ejecución técnica o gasto real.

16.1. Trazabilidad del presupuesto de diez semanas

El presupuesto vigente y su distribución por concepto se presentan en la sección financiera. El detalle por semana y rol corresponde al informe EP3 corregido; esta integración

no duplica ni recalcula sus horas. El gasto de infraestructura de $250.000 se estima para demostración durante las diez semanas. No se presupuestan costos recurrentes posteriores ni ciclos de reentrenamiento.

La planificación de monitoreo 3.2.2 es un artefacto académico separado, con su propia simulación de tareas y horas. No debe agregarse al presupuesto de EP3 ni interpretarse como comprobante de trabajo realizado. El presupuesto vigente no representa desembolsos observados ni una autorización institucional.

17. Planificación integrada, Gantt y recursos (D12–D14)

Esta sección integra la planificación de diez semanas del informe EP3 corregido (5 de octubre–13 de diciembre de 2026) con el estado que hoy muestran los artefactos locales. El cronograma es una línea base académica. El alcance verificable en el repositorio incluye preparación de datos, análisis exploratorio, entrenamiento experimental, comparación de modelos, inferencia batch de ejemplo y documentación. No incluye despliegue Cloud, producto clínico ni operación posterior. El informe de monitoreo 3.2.2 se conserva como ejercicio de seguimiento y no sustituye la línea base EP3 ni prueba que las tareas simuladas se ejecutaron.

17.1. Estructura de Desglose del Trabajo (D12)

La EDT se organiza en paquetes acotados al prototipo de diez semanas: (1) alcance y línea base; (2) preparación y análisis del dataset académico; (3) entrenamiento y comparación de modelos; (4) evaluación técnica y límites éticos; y (5) automatización de inferencia de ejemplo, documentación y cierre. Los entregables de infraestructura institucional, continuidad productiva, monitoreo prolongado y reentrenamiento periódico no pertenecen al alcance vigente.

17.2. Carta Gantt del piloto (D13)

La Carta Gantt detallada del informe EP3 corregido es la referencia del calendario. La tabla siguiente resume las fases de la ejecución académica, sin añadir fechas ni hitos fuera de ese informe.

Cuadro 10: Fases de la ejecución académica de diez semanas

Fase	Trabajo	Ventana de referencia
Inicio y alcance	Definición de problema, objetivos y plan	Según Carta Gantt EP3
Datos	Auditoría, preparación y análisis exploratorio	Según Carta Gantt EP3
Modelado	Entrenamiento, comparación y evaluación	Según Carta Gantt EP3
Demostración	Automatización de inferencia y revisión de ejemplos	Según Carta Gantt EP3
Cierre	Resultados, límites, documentación y retrospectiva	Hasta semana 10

La secuencia técnica observable es: alcance y datos disponibles → auditoría/preparación → modelo candidato → evaluación y comparación → inferencia demostrativa → documentación y cierre. No se incluye servicio productivo ni piloto clínico.

El presupuesto por perfil, conceptos y reserva se resume en la sección financiera. La planificación de diez semanas no incluye una bolsa de horas ni costos de mantenimiento posteriores.

17.3. Hitos, dependencias y continuidad (D14)

Los hitos del trabajo se distribuyen dentro de las diez semanas: alcance; auditoría/-preparación de datos; entrenamiento y comparación; evaluación de límites y resultados; automatización demostrativa; y cierre/documentación. No hay hitos posteriores de monitoreo o reentrenamiento en la línea base vigente.

Cuadro 11: Perfiles considerados en el informe EP3

Rol	Dedicación según EP3	Alcance
Coordinación / negocio	Según EDT EP3	Planificación y seguimiento
Ciencia de datos / ML	Según EDT EP3	Preparación, modelado y evaluación
Desarrollador Full Stack	Según EDT EP3	Componentes de demostración considerados en el informe
Equipo principal	**Tres perfiles parciales**	**Sin operación posterior**

Las tareas analíticas dependen de disponer del dataset; la comparación requiere pipelines evaluados bajo una partición común; y la documentación de cierre requiere registrar resultados, decisiones y limitaciones. La simulación de monitoreo 3.2.2 no modifica estas dependencias ni acredita la ejecución de tickets.

La aceptación académica se basa en reproducibilidad, tratamiento documentado de duplicados y nulos, comparación de pipelines en la misma partición, reporte de métricas y

límites, cinco predicciones sintéticas y ejecución de la automatización batch. No se declaran cumplidos SLA, RTO/RPO, controles de un despliegue cloud ni validación clínica. El monto de referencia es $10.506.069 CLP para las diez semanas, como estimación académica.

18. Organización y estado de ejecución

La actividad se organiza con los marcos académicos indicados en los informes: PMBOK para documentar alcance, decisiones y riesgos; Scrum para ordenar el trabajo en periodos breves; y CRISP-DM para estructurar el análisis de datos y modelado. La documentación de estos marcos describe el método; no acredita que exista un equipo clínico, patrocinador institucional ni ceremonias formales ejecutadas.

18.1. Trabajo que consta en el repositorio

Cuadro 12: Estado verificable de los componentes

Componente	Evidencia disponible	Estado verificable
Datos	`heart.csv`, notebook y salidas de auditoría	Analizados; 1.025 filas originales, 302 observaciones únicas
Modelado	Notebook, tablas comparativas y artefacto Joblib	Prototipo XGBoost entrenado con CUDA; comparación documentada
Gráficos	PNG en `outputs/figures/`	Generados desde el notebook y referenciados en el informe
Inferencia	`src/automatizacion_predicciones.py` y ejemplos sintéticos	Ejecución local por lotes; no servicio desplegado
Entorno	`pyproject.toml` y `uv.lock`	Dependencias fijadas para reproducción local

18.2. Elementos que no constan como ejecutados

No se encontró evidencia en el repositorio de aplicación web, API, base de datos institucional, integración con ficha clínica, carga de datos desde hospital, despliegue cloud, revisión clínica, aprobación institucional, validación con población local, monitoreo en producción o reentrenamiento posterior. Las menciones a esos componentes en entregas académicas antiguas describen propuestas; no deben leerse como avances.

El informe 3.2.2 incluye una simulación didáctica de seguimiento. Sus estados, horas y cambios no se contabilizan como trabajo ejecutado salvo que exista evidencia independiente en el repositorio. El estado actual se limita a los archivos, resultados y artefactos identificados en esta documentación.

19. Criterios de aceptación de la actividad

Esta sección registra comprobaciones académicas sobre los archivos y resultados existentes. No define requisitos de un producto clínico ni marca como realizados controles que no cuentan con evidencia.

Cuadro 13: Criterios verificables y estado en el repositorio

Criterio	Evidencia requerida	Estado
Limpieza	Duplicados, nulos, dominios y valores extremos auditados	Documentado en notebook
Partición	División estratificada después de deduplicar; misma partición para comparación	226 train / 76 test
Evaluación	Validación cruzada en entrenamiento y métricas en prueba retenida	Resultados registrados; sin afirmación de mejora
Gráficos	Archivos de correlación, asociaciones categóricas, extremos, clases y comparación de modelos	En `outputs/figures/`
Cinco predicciones	Entradas nuevas para demostración y salida del pipeline	Ejemplos sintéticos; no pacientes
Automatización	Comando por lotes que valida el CSV y genera clase y score	Implementada localmente; score no calibrado
Uso clínico	Validación local, aprobación y controles institucionales	No realizado; fuera del alcance actual

El score del clasificador no está calibrado como probabilidad clínica. Los resultados describen únicamente la partición evaluada sobre este dataset académico. No se presentan indicadores de producción, uso por profesionales, ahorro, disponibilidad, RTO/RPO ni evaluación clínica porque no existe evidencia de tales actividades.

20. Anexo de trazabilidad de decisiones y supuestos

Este anexo conserva la trazabilidad académica de D1–D11 sin mantener como vigentes los supuestos del alcance anterior. La línea base que rige duración y presupuesto es el informe EP3 corregido: diez semanas y estimación de $10.506.069 CLP para un prototipo de investigación y demostración.

Cuadro 14: Separación entre evidencia del repositorio y propuestas fuera de alcance

Componente	Estado evidenciado localmente	Límite
Datos	1.025 filas originales, 723 duplicados exactos y 302 registros únicos; sin nulos detectados	Dataset académico; no representa por sí solo una institución clínica
Preparación	Deduplicación, auditoría de dominios/extremos, one-hot y escalado selectivo en pipelines	No hay ingesta desde sistemas clínicos
Modelado	Baseline ordinal, XGBoost one-hot y regresión logística comparados; artefacto GPU guardado	Sin validación externa/local ni calibración clínica
Automatización	Inferencia por lotes para cinco filas sintéticas	Sin API/UI institucional, despliegue o publicación automática
Gestión	Línea base de diez semanas y presupuesto estimado en EP3	No se presupuesta operación posterior

Las alternativas Cloud, Local e Híbrida, el dimensionamiento institucional, las ventanas recurrentes y los SLA/RTO/RPO provienen de documentos de una versión anterior. No constituyen decisiones ni compromisos del alcance actual.

El informe de monitoreo 3.2.2 conserva un ejercicio de control con tareas, fechas y estados simulados. Es útil como material didáctico, pero no debe leerse como evidencia de gasto o ejecución de producto.

21. Anexo de planificación y evidencia técnica actual

21.1. Cronograma vigente

El horizonte vigente es de diez semanas, del 5 de octubre al 13 de diciembre de 2026, conforme al informe EP3 corregido. La EDT y la Carta Gantt del informe EP3 son la referencia de calendario y asignación de trabajo. El informe 3.2.2 contiene una simulación didáctica de monitoreo con otra ventana de fechas; no se usa para reemplazar el calendario EP3 ni como evidencia de avance ejecutado.

21.2. Entregables de implementación observables

Cuadro 15: Entregables locales y evidencia asociada

Fase	Evidencia en el repositorio	Estado y límite
Preparación	Notebook 04, auditorías y CSV de resultados	Ejecutable sobre dataset académico
Análisis	Figuras de correlación, asociaciones categóricas, extremos y duplicados	Descriptivo; no causal
Modelado	Tablas de CV y test; pipeline joblib	Prototipo experimental sin validación clínica
Automatización	Script batch y cinco filas de ejemplo sintéticas	Inferencia local; score no calibrado
Reproducción	`pyproject.toml`, `uv.lock` y documentación técnica	Requiere entorno local con dependencias y GPU compatible para repetir CUDA

La aceptación del trabajo académico requiere que el notebook y el flujo batch sean reproducibles, que el tratamiento de datos y las decisiones estén explicados, que se presenten resultados y límites sin sobreafirmar su alcance, y que las cinco entradas de ejemplo no se confundan con pacientes. El informe 3.1.2 solicita guardar una copia en Google Drive; el repositorio sólo acredita la copia local.

22. Anexo de riesgos del alcance vigente

Los riesgos se refieren al prototipo académico de diez semanas y a sus límites de datos y evaluación. La escala cualitativa es orientativa; no sustituye la aceptación de riesgos institucional para un eventual uso asistencial.

Cuadro 16: Riesgos principales del prototipo y controles

ID	Riesgo	Consecuencia posible	Control o límite
R01	Dataset pequeño y procedencia académica	Baja generalización a población distinta	No afirmar validez externa; exigir validación local para cualquier uso posterior
R02	Duplicados exactos	Sobreponderación y fuga entre particiones	Deduplicar antes de dividir y preservar la fuente original
R03	Dominios/codificaciones inconsistentes	Interpretación incorrecta de variables	Documentar discrepancias; no recodificar sin fuente verificable
R04	Desbalance de cobertura por sexo/edad	Métricas globales ocultan errores en grupos pequeños	Reportar tamaños; no inferir equidad con subgrupos insuficientes
R05	Scores sin calibración	Lectura errónea como probabilidad clínica	Etiquetar score como no calibrado; no usar para decisiones asistenciales
R06	Sobreinterpretación de métricas	Afirmar mejora o utilidad clínica no demostrada	Informar que AUC test es 0,875 en ambos modelos y test N=76
R07	Uso indebido de predicciones sintéticas	Confusión con registros reales	Mantener ejemplos sintéticos identificados como tales
R08	Automatización sin controles clínicos/institucionales	Daño si se conecta a un flujo asistencial sin validar	No desplegar ni integrar; mantener inferencia local demostrativa
R09	Desviación del alcance/cronograma	Retraso del cierre de diez semanas	Gestionar cambios según EP3 y separar simulaciones 3.2.2 de evidencia de ejecución

El trabajo actual no afirma que estos riesgos estén resueltos para un producto clínico. Las mitigaciones describen controles de investigación y comunicación de límites. Se excluyen de esta matriz las estimaciones financieras, de continuidad Cloud y operación de la línea base anterior.

23. Discusión

La línea base actual abarca diez semanas y un prototipo académico de investigación y demostración. El informe EP3 estima un presupuesto de $10.506.069 CLP para tres perfiles parciales, asesoría puntual, infraestructura demostrativa y contingencia. No es una

cotización vinculante ni cubre operación posterior. Las cifras previas de dimensionamiento institucional y costos Cloud/Local/Híbrido pertenecen a un alcance sustituido y no se usan para decisiones vigentes.

El repositorio muestra avance técnico concreto: un dataset académico deduplicado, análisis exploratorio, selección de transformaciones, pipelines comparables, evaluación de cinco folds, una prueba retenida, un artefacto XGBoost entrenado con CUDA y un comando de inferencia sobre datos sintéticos. El nuevo tratamiento one-hot es más adecuado para los códigos categóricos, pero las métricas de prueba no muestran mejora predictiva frente al baseline ordinal. El mejor ROC-AUC promedio CV fue de la regresión logística CPU (0,919); la selección de XGBoost one-hot responde al requerimiento acordado de entrenamiento GPU, no a una superioridad estadística.

La muestra deduplicada contiene sólo 302 filas, el test tiene 76 casos y hay baja representación de algunos subgrupos. Además, existen discrepancias de dominio respecto de la referencia UCI y no se ha verificado el significado clínico exacto del target en esta copia. Por tanto, los resultados caracterizan un ejercicio técnico; no acreditan utilidad clínica, generalización a población chilena, calibración de scores ni ausencia de sesgo.

El informe 3.2.2 documenta un ejercicio de monitoreo con fechas, tareas, estimaciones y estados simulados distintos al calendario EP3. Se conserva como evidencia didáctica de seguimiento y control de cambios, sin tratar sus tickets como ejecución real, gasto observado o cambio de la línea base de diez semanas.

23.1. Límites del estado implementado

No se encontró en el repositorio una aplicación clínica, API/UI operativa, conexión con ficha electrónica, despliegue GCP, validación con datos institucionales ni aprobación clínica. La automatización valida un CSV y produce una clase y un score no calibrado; no reentrena ni publica modelos. La RTX 4060 local acredita uso de GPU durante el entrenamiento registrado en el artefacto, no una infraestructura de producción.

24. Conclusiones

La línea base vigente es una ejecución académica de diez semanas, del 5 de octubre al 13 de diciembre de 2026. El presupuesto de referencia es $10.506.069 CLP según el informe EP3 corregido; se trata de una estimación para prototipo, no de gasto ejecutado ni autorización de compra. No hay presupuesto aprobado ni plan de operación posterior en los documentos vigentes.

El repositorio ya contiene un modelo experimental. XGBoost one-hot se entrenó en CUDA con una RTX 4060 local y se entrega como pipeline reproducible. Su ROC-AUC de prueba fue 0,875, igual al baseline ordinal; otras métricas del test fueron algo menores. Por

tanto, el cambio mejora la representación metodológica de variables categóricas, pero no demuestra una mejora de rendimiento. La logística obtuvo el mayor promedio CV (0,919), en CPU.

El notebook, los gráficos, el entorno `uv`, el artefacto y la automatización batch documentan un prototipo reproducible. El tamaño y procedencia de los datos, las limitaciones de cobertura y la falta de validación local impiden concluir que el modelo sea apto para uso clínico. No hay despliegue, integración institucional ni aprobación asistencial en el estado del repositorio.

La recomendación es mantener el alcance de diez semanas, presentar los resultados como evidencia académica preliminar y conservar explícitamente las condiciones éticas, de seguridad, validación local y supervisión humana para cualquier trabajo futuro.

25. Recomendaciones

- Mantener como alcance vigente las diez semanas y el presupuesto estimado EP3 de $10.506.069 CLP, separando claramente estimaciones de ejecución observada.
- Preservar los datos originales; repetir entrenamiento y validación sólo mediante los pipelines reproducibles, sin ajustar transformaciones con datos de prueba.
- Reportar la igualdad de ROC-AUC en test entre baseline y XGBoost one-hot, junto con el mayor promedio CV de la logística CPU. No presentar la selección GPU como mejora predictiva.
- Mantener los scores como no calibrados y las cinco filas de ejemplo como sintéticas.
- Antes de cualquier aplicación clínica, verificar target y dominios, obtener datos representativos y autorizados, validar localmente y evaluar subgrupos con tamaño suficiente; acordar métricas y umbrales con responsables clínicos.
- Mantener revisión humana y trazabilidad. No diagnosticar, tratar, priorizar ni automatizar decisiones con este prototipo.
- Conservar las tareas, horas y estados del informe 3.2.2 bajo la etiqueta de ejercicio simulado; no sumarlos al presupuesto ni tratarlos como avance ejecutado sin evidencia independiente.

25.1. Trazabilidad de responsabilidades y decisiones

Los entregables D1–D14 y sus responsables se conservan como trazabilidad académica. El informe EP3 corregido es la fuente de referencia para duración y presupuesto; el informe 3.2.2 aporta un ejercicio de monitoreo/control. Los resultados actuales del modelo y la descripción de implementación se documentan en la sección 9 y en `docs/implementacion_tecnica_3_1_2.md`.

26. Referencias

Equipo de proyecto. (2026). Plan Maestro del Encargo Heart Disease Dataset equipo de 5 [Documento interno].

Google Cloud. (2026a). *Resource location restrictions*. Consultado el 10 de septiembre de 2026, desde https://docs.cloud.google.com/organization-policy/restrict-locations?hl=es

Google Cloud. (2026b). *What is Cloud Run*. Consultado el 10 de septiembre de 2026, desde https://docs.cloud.google.com/run/docs/overview/what-is-cloud-run

Hormazábal, V. (2026). *Matriz de Riesgos, Priorización y Mitigaciones* (Documento interno de proyecto, versión 2).

Hospital Dr. Sótero del Río. (2017). *El valioso trabajo de la Unidad de Cardiología Infantil*. Consultado el 10 de septiembre de 2026, desde https://www.hospitalsoterodelrio.cl/web/el-valioso-trabajo-de-la-unidad-de-cardiologia-infantil/

Hospital Dr. Sótero del Río. (s.f.). *Quiénes somos*. Consultado el 10 de septiembre de 2026, desde https://www.hospitalsoterodelrio.cl/web/quienessomos/

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). *Heart Disease*. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

JohnSmith88. (s.f.). *Heart Disease Dataset*. Consultado el 10 de septiembre de 2026, desde https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset

Lagos Barrios, R. (2024). Método para medir brechas de consultas médicas de especialidad en la programación de hospitales públicos. *Revista Médica de Chile*, *152*(10), 1049-1059. https://www.scielo.cl/scielo.php?pid=S0034-98872024001001049&script=sci_arttext

Leal, F. (2026). *Planificación del proyecto: Entregables D12 a D14* (Documento interno de proyecto).

Ministerio de Salud de Chile. (s.f.-a). *Orientaciones para la planificación Programa de Salud Cardiovascular*. Consultado el 10 de septiembre de 2026, desde https://www.minsal.cl/orientaciones-para-la-planificacion/

Ministerio de Salud de Chile. (s.f.-b). *Plan Director Hoja de Ruta de Ciberseguridad y Seguridad de la Información para el Sector Salud*. Consultado el 10 de septiembre de 2026, desde https://www.minsal.cl/wp-content/uploads/2015/08/PLAN-DE-CIBERSEGURIDAD-Y-SEGURIDAD-DE-LA-INFORMACION-SECTOR-SALUD-2024-2025-ITS-NC-03-V1.1.pdf

Ministerio de Salud de Chile. (s.f.-c). *Seguridad de la Información y Ciberseguridad del MINSAL*. Consultado el 10 de septiembre de 2026, desde https://www.minsal.cl/seguridad_de_la_informacion/

Moncada, L. (2026). *Informe Maestro D1 a D6 Heart Disease* (Documento interno de proyecto).

scikit-learn developers. (s.f.). *Common pitfalls and recommended practices*. Consultado el 3 de noviembre de 2026, desde https://scikit-learn.org/stable/common_pitfalls.html

SCY1102 Gestión de Proyectos de Datos. (2025a). Evaluación de Factibilidad Financiera y de Riesgos de Proyectos de Ciencia de Datos [Presentación].

SCY1102 Gestión de Proyectos de Datos. (2025b). Evaluación de Factibilidad Técnica y Ética de un Proyecto de Ciencia de Datos [Presentación].

SCY1102 Gestión de Proyectos de Datos. (2025c). Evaluación de Proyectos de Ciencia de Datos [Material docente].

SCY1102 Gestión de Proyectos de Datos. (2025d). Evaluación Parcial N 1 Instrucciones y pauta de evaluación Estudiante [Documento de evaluación].

SCY1102 Gestión de Proyectos de Datos. (2025e). Integración y Comunicación de los Resultados de un Proyecto de Ciencia de Datos [Presentación].

Silva, I. (2026). *Evaluación financiera Cloud, Local e Híbrida: Entregables D7 a D11* (Documento interno de proyecto).

U.S. Food and Drug Administration. (2024). *Transparency for Machine Learning-Enabled Medical Devices: Guiding Principles*. Consultado el 10 de septiembre de 2026, desde https://www.fda.gov/medical-devices/software-medical-device-samd/transparency-machine-learning-enabled-medical-devices-guiding-principles

World Health Organization. (2021). *Ethics and Governance of Artificial Intelligence for Health: WHO Guidance*. Consultado el 10 de septiembre de 2026, desde https://www.who.int/publications/i/item/9789240029200

XGBoost developers. (s.f.). *Python API Reference: Booster prediction contributions*. Consultado el 3 de noviembre de 2026, desde https://xgboost.readthedocs.io/en/stable/python/python_api.html