

Análisis del Dataset Heart Disease

Línea base conceptual D1 a D6 para gestión de proyectos de datos

Lucas Moncada

Septiembre de 2026

Índice

1. Resumen ejecutivo	1
2. Introducción	1
2.1. Estado y trazabilidad documental	2
3. Contexto del problema	3
3.1. Objetivo general	3
3.2. Objetivos específicos	3
3.3. Usuarios y criterios de éxito	3
4. Descripción del dataset	4
4.1. Diccionario de datos	4
4.2. Alcance de los datos	5
5. Metodología	5
5.1. Ciclos de gestión propuestos	6
6. Preparación de datos	6
6.1. Frecuencia operacional de datos y modelo	7
6.2. Validación de duplicados	7
7. Análisis exploratorio	8
7.1. Efecto de la deduplicación	8
7.2. Representación y subgrupos	10
8. Análisis ético y de sesgos	11
8.1. Evidencia, interpretación y límites	11
8.2. Impacto ético y técnico del uso futuro	12
8.3. Matriz de controles y criterios de aceptación	12
8.4. Gates propuestos antes de un piloto	14
9. Análisis D1	14
9.1. Alcance funcional	14
9.2. Fuera de alcance	14
9.3. Arquitectura lógica común	14
10. Análisis D2	15
10.1. Alternativa Cloud	15
10.2. Decisión sobre Vertex AI	15

10.3. Beneficios, riesgos y componentes costables	15
11.Análisis D3	16
11.1. Alternativa Local u on-premise	16
11.2. Seguridad y continuidad	16
12.Análisis D4	16
12.1. Alternativa Híbrida	16
12.2. Distribución explícita de responsabilidades	17
13.Análisis D5	17
13.1. Herramientas y stack tecnológico	17
13.2. Stack base común	18
14.Análisis D6	19
14.1. Justificación del enfoque adaptativo	19
14.2. Criterios completos de comparación	19
15.Evaluación financiera Cloud, Local e Híbrida (D7–D11)	20
15.1. Modelo de costos y supuestos comunes (D7)	20
15.2. Alternativa Cloud (D8)	21
15.3. Alternativas Local e Híbrida (D9–D10)	22
15.4. Costo-beneficio, sensibilidad y recomendación (D11)	23
16.Planificación integrada, Gantt y recursos (D12–D14)	24
16.1. Estructura de Desglose del Trabajo (D12)	24
16.2. Carta Gantt del piloto (D13)	24
16.3. Hitos, dependencias y continuidad (D14)	25
17.Anexo de trazabilidad técnica y financiera (D1–D11)	25
17.1. Trazabilidad del informe maestro D1–D6	26
17.2. Alcance, actores y criterios de D1	26
17.3. Arquitecturas, componentes y trade-offs (D2–D4)	27
17.4. Herramientas, metodología y supuestos comunes (D5–D6)	27
17.5. Handoffs, aceptación y elementos abiertos	28
17.6. Desglose financiero reproducible	28
18.Anexo de planificación detallada (D12–D14)	29
18.1. Operación recurrente a 36 meses	29
18.2. Hitos y criterios de salida	30
18.3. Dependencias, recursos y riesgos de planificación	30
18.4. Criterios de aceptación y cierre	31

19. Anexo de matriz de riesgos integrada	31
19.1. Criterios de aceptación de riesgos	32
19.2. Consistencia financiera pendiente de validación	32
20. Discusión	33
20.1. Supuestos comunes para las tres alternativas	33
20.2. Detalle de supuestos y sensibilidad	33
20.3. Comparación consolidada	34
20.4. Riesgos y elementos pendientes	34
21. Conclusiones	35
22. Recomendaciones	35
22.1. Handoff para evaluación financiera	35
22.2. Fórmula y reglas de costeo	36
22.3. Handoff para planificación, riesgos e integración	36
22.4. Handoffs nominales y matriz de riesgos semilla	36
22.5. Matriz de trazabilidad de decisiones	37
22.6. Auditoría de aceptación D1 a D6	38
22.7. Checklist de integración	38
23. Referencias	39

1. Resumen ejecutivo

Este documento establece la línea base conceptual para una plataforma interna de apoyo a la prevención cardiovascular. La propuesta busca transformar datos disponibles en conocimiento sobre factores asociados a enfermedad cardíaca y, en una etapa posterior, apoyar la priorización de evaluaciones preventivas. No corresponde a un sistema de diagnóstico autónomo ni reemplaza la decisión de los profesionales de salud.

Se comparan tres alternativas técnicamente equivalentes: una implementación Cloud en Google Cloud Platform (GCP), una alternativa Local dentro de la infraestructura hospitalaria y una arquitectura Híbrida. Las tres conservan el mismo alcance funcional, el mismo horizonte de evaluación y los mismos supuestos operacionales; cambian principalmente la ubicación de los componentes, la responsabilidad de operación, el perfil de costos y los riesgos.

La línea base define un stack portable y predominantemente open source, formado por Python, Pandas, Scikit-learn, PostgreSQL, SHAP, FastAPI, Streamlit, Docker y Git. La gestión propuesta es adaptativa, con ciclos incrementales, revisiones, hitos y capacidad de ajuste ante la incertidumbre propia de los datos, el modelamiento, los riesgos y la validación.

El piloto se evalúa a 36 meses, con 20 usuarios autorizados en el primer año, crecimiento a 25 y 30 usuarios, y concurrencia de 5, 6 y 8 usuarios respectivamente. Se asume una carga histórica inicial de 10.000 registros analíticos, 5.000 registros nuevos o actualizados durante el primer año y crecimiento anual de 10 %. La carga se actualiza mediante un proceso batch diario y la inferencia se solicita bajo demanda. La plataforma debe mantener una disponibilidad objetivo de 99 % durante el horario operacional, con RTO máximo de 8 horas, RPO máximo de 24 horas, respaldos diarios y pruebas mensuales de restauración.

La alternativa final no se declara en esta etapa. La recomendación deberá integrar la evaluación financiera, el análisis de riesgos, las restricciones éticas y legales, y la factibilidad técnica.

2. Introducción

El caso aborda la utilización de un dataset de enfermedad cardíaca como base académica y de prototipo para un proyecto de ciencia de datos en salud pública. El documento organiza las decisiones de D1 a D6 y los supuestos comunes que permiten al resto del equipo desarrollar los análisis de finanzas, planificación, riesgos e integración final.

La estructura se apoya en los contenidos docentes de Gestión de Proyectos de Datos, la pauta de la evaluación, el Plan Maestro del equipo y el caso Heart Disease. Para mantener la trazabilidad, se distingue entre contenido respaldado por estos documentos, evidencia externa de contexto, decisiones de diseño y supuestos de planificación. Las decisiones

concretas de arquitectura y los valores de dimensionamiento son adaptaciones para el caso; no se presentan como hechos declarados por una institución hospitalaria real.

El alcance corresponde a un piloto institucional controlado y mantenible. No se dimensiona la infraestructura para las 1.025 filas del dataset académico ni se afirma que este represente la futura población productiva del hospital. El objetivo es disponer de una base seria y comparable para evaluar alternativas, sin simular un despliegue clínico definitivo.

2.1. Estado y trazabilidad documental

El informe maestro identifica a Lucas Moncada como responsable del bloque, declara la línea base conceptual D1 a D6 como cerrada en su versión 1.0 y sitúa la evaluación en septiembre de 2026. Su propósito es habilitar los análisis de finanzas, planificación, riesgos e integración final; se evalúa un piloto institucional controlado y mantenible durante un horizonte de 36 meses.

EA1 1.1

Aporta sesgos, ciclo de vida del dato, justicia, transparencia, privacidad, responsabilidad y mitigación.

EA1 1.2

Aporta viabilidad técnica, datos, seguridad, escalabilidad, riesgos, RBAC, Zero Trust, anonimización y explicabilidad.

EA1 1.3

Aporta costos cloud, licencias, RRHH, servicios, costo-beneficio, ROI, escenarios, riesgos y mitigaciones.

EA1 1.4

Aporta la integración técnica, financiera, ética y de riesgos, además de la comunicación de supuestos y limitaciones.

Rúbrica EP1

Exige ética 30 %, finanzas 30 %, riesgos 40 %, extensión de 4 a 6 páginas y referencias APA.

Plan Maestro

Define responsabilidades D1 a D22, criterios de aceptación, dependencias y handoffs.

Caso y dataset

Fundamentan la necesidad de comprender factores asociados al riesgo y priorizar prevención con un dataset académico de referencia.

3. Contexto del problema

Un hospital público dispone de información obtenida durante controles cardiovasculares preventivos, pero no cuenta con una solución analítica que transforme sistemáticamente esos datos en conocimiento sobre los factores asociados a enfermedad cardíaca ni que apoye la priorización de acciones preventivas.

La solución propuesta es una plataforma interna de apoyo analítico para prevención cardiovascular. Debe procesar información clínica, analizar factores asociados a enfermedad cardíaca y evolucionar hacia estimaciones de riesgo que ayuden a priorizar evaluaciones preventivas. La supervisión de profesionales de salud se mantiene durante todo el proceso.

3.1. Objetivo general

Diseñar y evaluar una solución de ciencia de datos mantenible, segura y explicable para analizar factores asociados a enfermedad cardíaca y apoyar la priorización de pacientes en controles cardiovasculares preventivos. La evaluación compara alternativas Cloud, Local e Híbrida, sin delegar la decisión clínica en el sistema.

3.2. Objetivos específicos

- Preparar y analizar los datos cardiovasculares para determinar su calidad, representatividad y utilidad analítica.
- Identificar variables y patrones asociados con la presencia de enfermedad cardíaca.
- Desarrollar y evaluar progresivamente modelos de apoyo a la estimación de riesgo cardiovascular.
- Incorporar explicabilidad, evaluación de sesgos, privacidad y supervisión humana en el ciclo de la solución.
- Diseñar una arquitectura mantenible que permita incorporar nuevos datos, monitorear la solución y evolucionarla.

3.3. Usuarios y criterios de éxito

Los profesionales clínicos y preventivos consultarán resultados como apoyo; coordinación y gestión cardiovascular utilizarán información agregada para planificar acciones; y los equipos de TI y datos administrarán operación, permisos, monitoreo y soporte bajo el principio de mínimo privilegio. El paciente es un beneficiario indirecto y no se considera una interfaz pública de paciente para el piloto.

El éxito técnico requiere una arquitectura mantenible y trazable; el éxito clínico-operacional exige resultados comprensibles sin bloquear el flujo clínico si la plataforma no está disponible; el éxito ético requiere explicabilidad, supervisión humana, protección de

datos y evaluación por subgrupos; y el éxito financiero y de gestión exige una alternativa sostenible, con alcance, costos, riesgos, recursos y decisiones coherentes.

4. Descripción del dataset

El archivo `heart.csv` utilizado en el caso contiene 1.025 registros y 14 variables, incluida la variable objetivo `target`. No presenta valores nulos y contiene 723 filas duplicadas exactas. La clase objetivo está relativamente equilibrada, con 526 registros cuyo `target` es 1 y 499 cuyo `target` es 0. La variable `sex` presenta 713 registros con valor 1 y 312 con valor 0; la edad observada se encuentra entre 29 y 77 años.

Cuadro 1: Caracterización inicial del dataset original

Indicador	Valor
Registros	1.025
Variables	14
Valores nulos	0
Filas duplicadas exactas	723 (70,54 %)
Registros únicos	302
<code>target=0</code> / <code>target=1</code>	499 / 526
<code>sex=0</code> / <code>sex=1</code>	312 / 713
Rango de edad	29–77 años

Estas características orientan la factibilidad inicial, pero no validan por sí mismas la representatividad del dataset ni la pertinencia de un uso clínico. El dataset de Kaggle se utiliza como referencia académica y de prototipo; no se asume que sea la base productiva definitiva del hospital. La codificación `sex=0` como mujer y `sex=1` como hombre está documentada para el conjunto original de UCI; la coincidencia de valores se registra con trazabilidad externa (Janosi et al., 1989).

4.1. Diccionario de datos

El archivo `heart.csv` contiene 14 variables: 13 predictores y la variable objetivo `target`. El diccionario documenta el significado, tipo, unidad o codificación y dominio observado de cada variable. Las definiciones conceptuales proceden de la documentación del repositorio UCI y de la versión publicada en Kaggle, mientras que dtype, rangos, nulos, valores únicos y categorías observadas se calculan directamente desde `heart.csv` (Janosi et al., 1989; JohnSmith88, s.f.).

Cuando la codificación original de UCI difiere del dominio presente en esta versión, se conservan los valores observados y se deja una advertencia explícita en el diccionario técnico. Esto afecta particularmente a `cp`, `slope`, `ca` y `thal`; no se asume una equivalencia que no esté documentada de forma concluyente.

Cuadro 2: Diccionario resumido de variables

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
age	Edad del paciente.	Numérica discreta	años	29–77
sex	Sexo del paciente.	Binaria	0=mujer; 1=hombre	0 1
cp	Tipo de dolor torácico.	Catégorica	No verificada; ver CSV	0 1 2 3
trestbps	Presión arterial en reposo al ingreso.	Numérica discreta	mmHg	94–200
chol	Colesterol sérico.	Numérica discreta	mg/dL	126–564
fbs	Indicador de glucosa en ayunas superior a 120 mg/dL.	Binaria	0=no; 1=sí (>120 mg/dL)	0 1
restecg	Resultado del electrocardiograma en reposo.	Catégorica	0=normal; 1=ST-T; 2=HVI	0 1 2

Cuadro 3: Diccionario resumido de variables (continuación)

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
thalach	Frecuencia cardíaca máxima alcanzada.	Numérica discreta	bpm	71–202
exang	Angina inducida por ejercicio.	Binaria	0=no; 1=sí	0 1
oldpeak	Depresión del segmento ST inducida por ejercicio respecto del reposo.	Numérica continua	desviación ST	0–6.2
slope	Pendiente del segmento ST durante ejercicio.	Catégorica	No verificada; ver CSV	0 1 2
ca	Número de vasos principales coloreados por fluoroscopia.	Numérica discreta	UCI: 0–3; CSV: 0–4	0–4
thal	Resultado de la prueba de talio.	Catégorica	No verificada; ver CSV	0 1 2 3
target	Variable objetivo binaria de la versión Kaggle, asociada a la presencia de enfermedad cardíaca.	Binaria	Binaria 0/1; ver CSV	0 1

4.2. Alcance de los datos

La preparación debe detectar faltantes, duplicados, valores inválidos y cambios de esquema. El análisis posterior debe evaluar calidad, estabilidad, representatividad, privacidad y posibles sesgos por subgrupos antes de que un modelo pueda considerarse para apoyo operativo.

5. Metodología

La gestión se basa en un enfoque adaptativo. Esta denominación describe la forma de gestionar el proyecto y no un tipo de modelo predictivo. Se elige porque los requisitos, la calidad y representatividad de los datos, el desempeño de las alternativas, los riesgos y las necesidades de validación pueden evolucionar durante el proyecto.

En lugar de asumir una planificación completamente estable, el enfoque adaptativo organiza ciclos incrementales de planificación, análisis, evaluación y ajuste. Cada ciclo mantiene entregables, responsables e hitos definidos, pero permite incorporar evidencia antes de decidir las etapas siguientes.

5.1. Ciclos de gestión propuestos

Ciclo 1

Comprensión del problema, objetivos, actores y criterios de éxito. Hito: alcance inicial aprobado.

Ciclo 2

Comprensión y evaluación de datos: calidad, representatividad y privacidad. Hito: factibilidad inicial de datos validada.

Ciclo 3

Diseño y evaluación de Cloud, Local e Híbrida, herramientas, costos preliminares y riesgos. Hito: alternativas técnicamente viables.

Ciclo 4

Evaluación integral técnica, ética, financiera, legal y de riesgos. Hito: alternativa preferida seleccionada.

Ciclo 5

Planificación de un eventual piloto: recursos, seguridad, operación y mantenimiento. Hito: plan de ejecución aprobado.

Ciclo 6

Evaluación, retroalimentación, ajustes y lecciones aprendidas. Hito: decisión de continuidad o escalamiento.

La planificación debe incluir revisiones, hitos y capacidad de ajuste; las finanzas deben incorporar horas de revisión e iteración; los riesgos deben reevaluarse durante los ciclos; y la ética debe considerar sesgos y explicabilidad de forma continua, no solo al cierre.

6. Preparación de datos

La preparación de datos constituye una capacidad permanente de la plataforma. La ingesta debe ser controlada, con validación de faltantes, duplicados, valores inválidos y cambios de esquema antes de actualizar las vistas analíticas o habilitar nuevos datos para análisis y modelamiento.

Los registros nuevos o modificados se incorporarán mediante un proceso batch incremental diario, preferentemente al cierre de la jornada clínica. No se requiere streaming ni ingestión continua para el piloto. La inferencia se ejecuta bajo demanda y se mantiene separada del proceso de incorporación de datos.

6.1. Frecuencia operacional de datos y modelo

Cada jornada operacional

Validación e incorporación de nuevos registros mediante batch diario.

Posterior a la carga diaria

Actualización de dashboard y estadísticas.

Bajo demanda

Inferencia de riesgo solicitada por el profesional.

Mensual

Revisión de cambios de distribución.

Trimestral

Revisión formal de desempeño, estabilidad, sesgos y explicabilidad.

Semestral

Ventana planificada de reentrenamiento y evaluación, dos veces al año.

Siempre

La sustitución del modelo requiere validación y aprobación; nunca es automática.

6.2. Validación de duplicados

La revisión reproducible confirma que los 723 duplicados son coincidencias exactas al considerar las 14 columnas. El [cuadro 4](#) muestra la frecuencia de repetición de las 302 observaciones distintas: no hay observaciones con una o dos apariciones, 187 se repiten tres veces, 114 cuatro veces y una observación aparece ocho veces. Esta evidencia no permite atribuir la causa a fraude, error de captura o sesgo; sí exige definir y documentar su tratamiento antes de cualquier modelamiento.

Cuadro 4: Frecuencia de repetición de observaciones exactas en el dataset original

Repeticiones	Observaciones distintas	Filas asociadas	% del original
1 vez	0	0	0,00 %
2 veces	0	0	0,00 %
3 veces	187	561	54,73 %
Más de 3 veces (4 u 8)	115	464	45,27 %
Total	302	1.025	100,00 %

Para garantizar trazabilidad, `data/raw/heart.csv` se conserva como fuente primaria inmutable. La versión `data/processed/heart_unique.csv` se deriva exclusivamente mediante `drop_duplicates()` y se utiliza como análisis de sensibilidad; no reemplaza al archivo original.

7. Análisis exploratorio

El análisis exploratorio se orienta a comprender la calidad y utilidad de los datos para el problema, no a producir visualizaciones sin propósito. La línea base identifica ausencia de valores nulos, 723 duplicados exactos, balance relativo de `target`, distribución observada de `sex` y edad entre 29 y 77 años.

7.1. Efecto de la deduplicación

Se comparó el archivo original con la versión deduplicada de 302 registros. El [cuadro 5](#) cuantifica las diferencias en puntos porcentuales, en lugar de asumir que la eliminación de duplicados no afecta las distribuciones. La proporción de `target=1` aumenta 2,99 puntos porcentuales tras deduplicar; la distribución de `sex` cambia 1,35 puntos porcentuales por código.

Cuadro 5: Distribución de `target` y `sex`: original versus deduplicado

Categoría	Original (%)	Deduplicado (%)	Diferencia (pp)
<code>target=0</code>	48,68	45,70	-2,99
<code>target=1</code>	51,32	54,30	+2,99
<code>sex=0</code>	30,44	31,79	+1,35
<code>sex=1</code>	69,56	68,21	-1,35




Figura 1: Comparación de la distribución de **sex** en el dataset original y deduplicado.

Cuadro 6: Distribución por rangos etarios: original versus deduplicado

Rango etario	Original (%)	Deduplicado (%)	Diferencia (pp)
< 40	5,56	4,97	-0,59
40–49	23,12	23,84	+0,72
50–59	41,17	41,39	+0,22
60–69	26,83	26,49	-0,34
70+	3,32	3,31	-0,01




Figura 2: Comparación de los rangos etarios en el dataset original y deduplicado.

7.2. Representación y subgrupos

En la versión deduplicada, **sex**=0 (mujer) concentra 96 registros (31,79 %) y **sex**=1 (hombre) concentra 206 (68,21 %); esta codificación está documentada por UCI (Janosi et al., 1989). La diferencia de representación es una limitación de cobertura de la muestra, no evidencia de discriminación ni de desempeño de un modelo, que todavía no existe. Los rangos < 40 (15 registros; 4,97 %) y 70+ (10; 3,31 %) disponen de menos evidencia que los rangos centrales. La [figura 3](#) presenta los tamaños de las combinaciones **sex**×**rango etario**. Los subgrupos **sex**=0 con < 40 y con 70+ tienen cinco registros únicos cada uno; por ello, sus porcentajes de **target** son descriptivos y no constituyen evidencia de diferencias ni de sesgo demostrado.




Figura 3: Tamaño deduplicado de los subgrupos **sex**×**rango etario**.

La evidencia sugiere posibles limitaciones de cobertura y generalización que deben validarse frente a la población objetivo. No permite afirmar discriminación ni extraer conclusiones sobre desempeño futuro por subgrupo.

8. Análisis ético y de sesgos

Este apartado convierte la evidencia de calidad y representatividad del análisis exploratorio en controles para un eventual piloto. No entrena modelos, no estima desempeño ni atribuye discriminación algorítmica: esos resultados no existen todavía. La orientación es coherente con la necesidad de autonomía humana, transparencia, responsabilidad, inclusión y evaluación continua en sistemas de IA para salud (U.S. Food and Drug Administration, 2024; World Health Organization, 2021).

8.1. Evidencia, interpretación y límites

La fuente original contiene 1.025 filas, de las cuales 723 son duplicados exactos (70,54 %); la versión analítica deduplicada conserva 302 registros. Esto constituye un problema de calidad y de trazabilidad del muestreo: la coincidencia exacta no permite conocer su causa. Si más adelante se entrenara o evaluara un modelo sin controlar este punto, las observaciones repetidas podrían sobreponderar patrones e incluso contaminar una separación de entrenamiento y prueba. No se afirma que dicha contaminación haya ocurrido. La mitigación exigible es conservar el original, declarar el criterio de deduplicación y verificar que registros equivalentes no queden repartidos entre particiones; el criterio CA-E01 formaliza su aceptación.

En los 302 registros únicos hay 96 mujeres (`sex=0`; 31,79 %) y 206 hombres (`sex=1`; 68,21 %). La codificación está respaldada por la fuente UCI (Janosi et al., 1989). Esta diferencia describe cobertura desigual, no discriminación ni desempeño diferente. Su impacto técnico posible es que un modelo futuro disponga de menor evidencia para el grupo menos representado; por ello el eventual desempeño debe evaluarse por sexo con tamaño muestral suficiente y no se debe aprobar uso donde la evidencia no respalde la población objetivo.

La cobertura también es reducida en edades extremas: < 40 aporta 15 registros únicos (4,97 %), 50–59 concentra 125 (41,39 %) y 70+ sólo 10 (3,31 %). Las intersecciones mujeres $\times$ < 40 y mujeres $\times$ 70+ contienen cinco registros cada una. Estos tamaños hacen inestables los porcentajes descriptivos de `target`; no revelan prevalencia poblacional, causalidad ni discriminación. Las diferencias de `target` por sexo y edad ya registradas en `representatividad_subgrupos.csv` deben leerse sólo con esa cautela y con el N correspondiente.

8.2. Impacto ético y técnico del uso futuro

El dataset de Kaggle sirve como evidencia académica inicial, pero no valida por sí mismo un uso en un hospital chileno. Pueden cambiar población, práctica clínica, medición y prevalencia; por ello la transferencia directa sería un riesgo de cambio de dominio. Cualquier paso hacia uso local requiere validación con datos y flujo clínico locales, además de monitoreo de deriva. Las guías para tecnologías clínicas de aprendizaje automático recomiendan comunicar límites de datos y poblaciones poco representadas, realizar validación específica del sitio y monitoreo continuo (U.S. Food and Drug Administration, 2024).

Un resultado automatizado no puede operar como diagnóstico ni decisión autónoma. Falsos negativos podrían omitir una revisión preventiva y falsos positivos podrían generar alertas o carga innecesarias; ambos efectos requieren un profesional que interprete el contexto, pueda discrepar y deje trazabilidad de la decisión. El esquema *Human in the Loop* es, por tanto, un requisito de control y no una característica opcional. SHAP puede apoyar explicaciones locales o globales, pero no prueba equidad ni reemplaza métricas por subgrupo, validación externa o supervisión clínica.

Privacidad y gobierno son igualmente éticos: antes de cualquier dato clínico deben definirse propósito, minimización, pseudonimización, control de acceso de mínimo privilegio, retención, auditoría y responsables. Cloud, Local e Híbrida presentan superficies operacionales distintas: la nube puede añadir transferencia y dependencia de proveedor; lo local concentra el control y la carga de operación; lo híbrido agrega sincronización y doble administración. Ninguna alternativa es intrínsecamente más ética; la aceptación depende de controles verificables y de la autorización que corresponda.

8.3. Matriz de controles y criterios de aceptación

La [cuadro 7](#) sintetiza la cadena evidencia–impacto–mitigación–aceptación. La versión completa y reutilizable se encuentra en `outputs/tables/matriz_etica.csv`; su generación desde los archivos original y deduplicado es reproducible mediante el script documentado en `src/`.

Cuadro 7: Matriz ética consolidada

ID	Hallazgo y evidencia	Impactos potenciales	Mitigación y aceptación
E01	Duplicación masiva y trazabilidad del tratamiento de datos. 1025 filas originales; 723 duplicadas exactas (70,54 %); 302 únicas.	Técnico: Sobreponderación de patrones y posible contaminación entre particiones si se modela sin control. Ético: Decisiones basadas en evidencia de calidad incierta.	Conservar el original, documentar duplicación y verificar separación por registro único antes de modelar. CA-E01: tratamiento de duplicados documentado y verificable.
E02	Cobertura desigual por sexo. Únicos: mujeres (sex=0) 96 (31,79 %); hombres (sex=1) 206 (68,21 %).	Técnico: Menor evidencia para estimar desempeño futuro en el grupo menos representado. Ético: Riesgo de uso inequitativo si no se evalúa la cobertura y el desempeño posterior.	Reportar métricas por sexo sólo al existir modelo y tamaño suficiente; no extrapolar cobertura a población. CA-E02 y CA-E04.
E03	Cobertura limitada en extremos etarios. Únicos: <40=15 (4,97 %); 50-59=125 (41,39 %); 70+=10 (3,31 %).	Técnico: Estimaciones inestables y generalización incierta en grupos con N reducido. Ético: Posible inequidad si se usa fuera de los grupos respaldados.	Definir mínimo N, evaluar por edad cuando corresponda y restringir uso no respaldado. CA-E03 y CA-E04.
E04	Evidencia interseccional insuficiente. Mujeres <40=5; mujeres 70+=5 registros únicos.	Técnico: Porcentajes y métricas por intersección serían altamente inestables. Ético: Conclusiones aparentes podrían invisibilizar incertidumbre de grupos pequeños.	Informar N junto con porcentajes; no aprobar uso en combinaciones sin evidencia suficiente. CA-E03 y CA-E04.
E05	Diferencias descriptivas de target entre subgrupos. Las proporciones de target por sexo y edad están exportadas con N en representatividad_subgrupos.csv.	Técnico: No permiten inferir desempeño, prevalencia ni causalidad. Ético: Interpretación indebida como diferencia poblacional o discriminación.	Tratar resultados como descriptivos; contrastar con validación clínica/local posterior. CA-E05: validación con datos locales antes de uso.

Cuadro 8: Matriz ética consolidada (continuación)

ID	Hallazgo y evidencia	Impactos potenciales	Mitigación y aceptación
E06	Cambio de dominio Kaggle hacia hospital chileno. Dataset académico externo; no representa por sí mismo la población ni el flujo clínico local.	Técnico: Deriva de población, medición o práctica clínica; desempeño no transferible. Ético: Riesgo de daños o acceso inequitativo por generalización injustificada.	Validación local prospectiva, documentación de población objetivo y monitoreo de deriva. CA-E05 y CA-E09.
E07	Automatización y posibles falsos negativos o positivos. El alcance define apoyo preventivo y revisión humana; no existe modelo ni métrica clínica validada.	Técnico: Alertas erróneas u omisiones si un resultado se interpreta como decisión clínica. Ético: Daño potencial, sesgo de automatización y dilución de responsabilidad.	Human in the Loop, protocolo de revisión, registro de decisión y uso exclusivamente preventivo. CA-E06 y CA-E10.
E08	Privacidad y gobierno del dato sensible. Las alternativas Cloud, Local e Híbrida procesan datos de salud con exposiciones operacionales distintas.	Técnico: Acceso indebido, retención excesiva o trazabilidad insuficiente. Ético: Afectación de confidencialidad y autonomía de las personas.	Minimización, pseudonimización, mínimos privilegios, propósito definido, retención y auditoría. CA-E08.
E09	Transparencia y explicabilidad insuficientes. SHAP está contemplado como apoyo explicativo; no hay modelo entrenado ni auditoría de desempeño.	Técnico: No detectar límites o errores por subgrupo mediante explicaciones aisladas. Ético: Confianza injustificada y falta de rendición de cuentas.	Documentar datos, límites, versiones y auditorías; SHAP complementa, no sustituye, pruebas de equidad. CA-E07 y CA-E09.

8.4. Gates propuestos antes de un piloto

Los criterios de aceptación no fijan umbrales inventados ni autorizan un modelo inexistente. Se proponen como condiciones de avance: CA-E01, tratamiento documentado de duplicados; CA-E02, desempeño por sexo cuando exista N suficiente; CA-E03, desempeño por rango etario cuando exista N suficiente; CA-E04, no aprobar uso en grupos sin cobertura respaldada; CA-E05, validación con datos locales; CA-E06, supervisión humana obligatoria; CA-E07, explicabilidad documentada; CA-E08, pseudonimización y control de acceso; CA-E09, monitoreo de deriva; y CA-E10, alcance limitado a apoyo preventivo, sin diagnóstico ni decisión automática. La aceptación final debe ser resuelta por la contraparte clínica y el gobierno del proyecto, con evidencia posterior.

9. Análisis D1

9.1. Alcance funcional

La solución incluye: ingesta controlada de datasets cardiovasculares; validación de calidad; preparación para análisis y modelamiento; análisis exploratorio orientado al problema; comparación conceptual de modelos candidatos; métricas técnicas, estabilidad y evaluación por subgrupos; explicabilidad; una interfaz interna de referencia; versionado y trazabilidad del modelo; monitoreo de degradación, drift y fallos operacionales; y documentación de arquitectura, supuestos, riesgos, procedimientos y operación.

9.2. Fuera de alcance

Quedan expresamente fuera de alcance el diagnóstico médico automático, las recomendaciones automáticas de tratamiento, la negación o asignación automática de atención, la sustitución de personal sanitario, la integración productiva completa con HIS/EHR, el despliegue clínico definitivo y una plataforma nacional o multihospital desde el inicio. Estas exclusiones reducen el riesgo clínico y ético, respetan la información disponible y mantienen el proyecto dentro de un piloto institucional controlado.

9.3. Arquitectura lógica común

Para comparar las tres alternativas de manera justa, todas resuelven el mismo problema y mantienen el mismo alcance funcional. La cadena lógica es: fuente de datos hospitalaria, validación y control de calidad, almacenamiento estructurado o analítico, preparación y procesamiento, modelo o servicio de inferencia, API de aplicación, interfaz de usuario, y monitoreo, trazabilidad y respaldo.

Las diferencias de costo no deben provenir de comparar productos con funcionalidades distintas. Cambia dónde se ejecutan los componentes, quién los administra y cómo se distribuyen los costos y riesgos.

10. Análisis D2

10.1. Alternativa Cloud

La alternativa Cloud utiliza Google Cloud Platform (GCP) como proveedor de referencia. Esta elección no implica que GCP sea un ganador universal frente a AWS o Azure: la pauta exige evaluar infraestructura, almacenamiento, cómputo, redes, costos, escalabilidad y riesgos. GCP se selecciona para contar con un escenario reproducible, por su región en Santiago (`southamerica-west1`), la posibilidad de restringir ubicaciones de recursos, y la simplicidad de una arquitectura gestionada y portable (Google Cloud, 2026a, 2026b).

La aplicación se ejecuta en Cloud Run mediante contenedores Docker; Cloud SQL for PostgreSQL mantiene la persistencia estructurada; Cloud Storage almacena datasets, respaldos y artefactos; IAM, Secret Manager y Cloud Logging/Monitoring administran permisos, secretos y observabilidad. Python, Scikit-learn y SHAP conservan un stack portable y evitan una dependencia obligatoria de servicios propietarios de ML.

10.2. Decisión sobre Vertex AI

Vertex AI queda como capacidad futura y no como componente obligatorio del piloto. Una plataforma gestionada no sustituye la definición del problema, la validación de datos, la evaluación de sesgos, las métricas ni la operación. Su incorporación se evaluará si aumentan el volumen de datos, la cantidad de modelos, la frecuencia de reentrenamiento, la necesidad de pipelines administrados o el número de equipos trabajando sobre modelos.

10.3. Beneficios, riesgos y componentes costables

Los beneficios principales son elasticidad y pago por uso, menor inversión física inicial, servicios gestionados, escalamiento sin compra de hardware y una ruta de evolución hacia MLOps. Los trade-offs son dependencia de proveedor y conectividad, costos variables si no se controla el consumo, exposición por configuraciones IAM incorrectas, lock-in parcial y la necesidad de gobierno de datos y revisión legal.

Para la evaluación financiera deben considerarse la configuración inicial de GCP, seguridad y despliegue; Cloud Run; Cloud SQL; Cloud Storage y respaldos; red o egress cuando corresponda; monitoreo y logging; Secret Manager e IAM si tienen costo aplicable; RRHH de operación y seguridad; y seis ventanas de evaluación o reentrenamiento durante los 36 meses.

11. Análisis D3

11.1. Alternativa Local u on-premise

En la alternativa Local, los datos, el almacenamiento, el procesamiento, la inferencia y la aplicación permanecen dentro de la infraestructura hospitalaria. Los usuarios acceden por la red institucional a una aplicación interna, compuesta por Streamlit, FastAPI y Docker; PostgreSQL local persiste los datos; y el almacenamiento institucional mantiene los respaldos. El modelo utiliza Scikit-learn y SHAP, sin requerir GPU en la fase inicial.

El dimensionamiento exacto queda para costeo, pero se requiere un servidor físico o virtualizado con CPU multinúcleo, memoria y SSD suficientes; almacenamiento de respaldo segregado; segmentación de red; RBAC; MFA para administración; cifrado; EDR o antimalware; parcheo; logs y monitoreo; UPS; y un procedimiento probado de recuperación.

11.2. Seguridad y continuidad

Local no equivale a seguro por definición. Una infraestructura local mal mantenida puede exponerse a ransomware, credenciales comprometidas, software legado, ausencia de segmentación o respaldos inutilizables. El control directo de los datos implica transferir gran parte de la responsabilidad operacional al hospital. El contexto de ciberseguridad sectorial debe evaluarse conforme a los lineamientos del MINSAL (Ministerio de Salud de Chile, [s.f.-b](#), [s.f.-c](#)).

Sus beneficios son el control directo de datos e infraestructura, menor dependencia de Internet para uso interno e integración natural con la red institucional. Sus riesgos son mayor CAPEX, mantenimiento y parcheo a cargo de TI, costos de electricidad y respaldo, escalamiento menos elástico y una postura de ciberseguridad deficiente que puede anular la ventaja de control.

La evaluación financiera debe incorporar servidor o virtualización, almacenamiento y medios de respaldo, UPS y red cuando corresponda, implementación y hardening, electricidad, mantenimiento, repuestos o renovación, seguridad y licencias si la institución no las posee, RRHH TI y seguridad, pruebas de recuperación y las seis ventanas de evaluación o reentrenamiento.

12. Análisis D4

12.1. Alternativa Híbrida

La alternativa Híbrida conserva localmente la identidad, el registro maestro y la interfaz clínica; GCP concentra la capacidad analítica, el entrenamiento y la inferencia. Antes

de transferir información, se aplican validación, minimización y pseudonimización. El resultado retorna a la aplicación clínica local y es utilizado por el profesional de salud.

La minimización restringe la transferencia a las variables necesarias para el propósito analítico. La pseudonimización mantiene el vínculo con la identidad real dentro del hospital. La solución además requiere TLS en tránsito, cifrado en reposo, IAM de mínimo privilegio, MFA, Secret Manager, auditoría en ambos ambientes y segregación de funciones. Pseudonimizar no convierte automáticamente la información clínica en datos no sensibles; se mantienen controles reforzados.

La inferencia se ejecuta en GCP para diferenciar la alternativa de la modalidad Local y reducir la infraestructura ML que debe operar el hospital. Si GCP o la conectividad no están disponibles, la atención clínica debe continuar sin el módulo predictivo, porque la plataforma es de apoyo y no es crítica.

12.2. Distribución explícita de responsabilidades

Permanece local

Identificadores directos del paciente, vínculo con la identidad, registro maestro clínico, aplicación o interfaz clínica interna, controles de acceso e integración interna.

Se ejecuta en GCP

Dataset analítico minimizado o pseudonimizado cuando corresponda, procesamiento y entrenamiento seleccionados, servicio de inferencia en Cloud Run, almacenamiento de artefactos y observabilidad cloud.

Los beneficios son el equilibrio entre control de identidad y elasticidad analítica, menor necesidad de comprar capacidad ML local anticipadamente, escalamiento gradual y una ruta futura hacia MLOps gestionado. Los trade-offs incluyen integración y operación dual, dependencia de conectividad para inferencia, riesgos de sincronización y transferencia, y costos operacionales distribuidos entre ambos entornos.

El costeo debe incluir infraestructura local mínima para registro maestro, interfaz e integración; configuración y seguridad de GCP; Cloud Storage y Cloud Run; cómputo temporal de entrenamiento; conectividad; monitoreo y respaldos en ambos ambientes; RRHH de integración, seguridad y operación; y seis ventanas de evaluación o reentrenamiento.

13. Análisis D5

13.1. Herramientas y stack tecnológico

La tecnología se define para evaluar factibilidad, costos, recursos y riesgos; el proyecto no exige construir todos los componentes. Se evita sobrearquitectura y se prioriza la portabilidad.

13.2. Stack base común

Python

Lenguaje principal por su ecosistema amplio de ciencia de datos, su carácter open source y su portabilidad.

Pandas y NumPy

Preparación y transformación de datos tabulares.

Scikit-learn

Modelamiento tradicional de clasificación tabular, sin sobredimensionar la plataforma ML.

PostgreSQL

Persistencia estructurada open source, disponible localmente o como servicio gestionado en GCP.

SHAP

Explicabilidad y análisis de influencia de variables.

FastAPI

Capa de servicio que desacopla el modelo de la interfaz.

Streamlit

Interfaz y dashboard de referencia para un prototipo interno sin licencias comerciales obligatorias.

Docker

Empaquetado consistente entre las tres alternativas.

Git Versionado y trazabilidad de código, configuración y documentación.

Las tecnologías necesarias son Python, Pandas, Scikit-learn y PostgreSQL. Como capacidades operacionales se incorporan SHAP, FastAPI, Streamlit, Docker y Git cuando el proyecto se materializa como aplicación mantenible. MLflow, Vertex AI, orquestación u otros servicios avanzados quedan para una etapa de mayor volumen, más modelos, reentrenamiento frecuente o complejidad operacional.

Para GCP se consideran como servicios mínimos Cloud Run, Cloud SQL for PostgreSQL, Cloud Storage, IAM, Secret Manager y Cloud Logging/Monitoring. No se incorpora inicialmente Vertex AI, BigQuery, GKE/Kubernetes, Dataflow, Dataproc, GPU dedicada ni Cloud Healthcare API.

14. Análisis D6

14.1. Justificación del enfoque adaptativo

Un enfoque predictivo presupone requisitos tempranamente estables, menor incertidumbre, cambios controlados y retroalimentación más tardía. En este caso, los requisitos pueden evolucionar, existe incertidumbre en los datos, riesgos y solución, y se requieren experimentación y revisión continua. Por ello, la adecuación del enfoque predictivo es media y la del enfoque adaptativo es alta.

El enfoque adaptativo no significa improvisación. Conserva una línea base de alcance y objetivos, pero permite ciclos incrementales con entregables, responsables, revisiones y puntos de decisión. Esta modalidad permite ajustar la planificación frente a la evidencia de calidad de datos, desempeño, riesgos, privacidad, sesgos y factibilidad de las alternativas.

14.2. Criterios completos de comparación

Requisitos

En un enfoque predictivo son estables tempranamente; en uno adaptativo pueden evolucionar. En este caso, pueden evolucionar.

Incertidumbre

Es baja en el enfoque predictivo y media o alta en el adaptativo. El caso presenta incertidumbre alta en datos, riesgos y solución.

Cambios

El enfoque predictivo los minimiza o controla; el adaptativo los incorpora de forma planificada. En este proyecto son probables.

Retroalimentación

Es más tardía en el enfoque predictivo y frecuente en el adaptativo. El caso necesita retroalimentación frecuente.

Datos y modelos

El enfoque predictivo requiere mayor previsibilidad; el adaptativo permite experimentar. El caso presenta incertidumbre en esta materia.

Riesgos

En el enfoque predictivo se planifican principalmente al inicio; en el adaptativo se revisan durante los ciclos. El caso requiere revisión continua.

Adecuación

La adecuación predictiva es media y la adaptativa es alta; por ello se selecciona el enfoque adaptativo.

El efecto transversal es claro: la EDT y la carta Gantt deben considerar revisiones y capacidad de ajuste; finanzas debe presupuestar iteración y contingencia; riesgos debe actualizarse al aparecer nueva evidencia; y la evaluación ética debe acompañar el ciclo completo.

15. Evaluación financiera Cloud, Local e Híbrida (D7–D11)

Esta sección incorpora la evaluación financiera preparada por Ignacio Silva para el piloto institucional de apoyo a la prevención cardiovascular. Se comparan las alternativas Cloud, Local e Híbrida bajo las mismas condiciones operacionales durante 36 meses. Los montos están expresados en pesos chilenos (CLP), incluyen una contingencia de 10 % y corresponden a estimaciones de planificación, no a cotizaciones vinculantes (Silva, 2026).

15.1. Modelo de costos y supuestos comunes (D7)

Se utiliza el Costo Total de Propiedad (TCO) a 36 meses: CAPEX, implementación y RRHH, OPEX recurrente, mantención y contingencia. El horizonte permite comparar alternativas con inversión inicial y alternativas de pago mensual sin extender la proyección a un plazo excesivamente incierto. El [cuadro 9](#) resume los supuestos comunes que aseguran comparabilidad.

Cuadro 9: Supuestos financieros comunes para las tres alternativas

Supuesto	Valor utilizado
Horizonte	36 meses
Escenario	Piloto institucional controlado
Usuarios y concurrencia	A1: 20/5; A2: 25/6; A3: 30/8
Datos de planificación	10.000 iniciales; 5.000 nuevos en A1; crecimiento 10 % anual
Mantenimiento del modelo	Seis ventanas en 36 meses
Continuidad	99 % horario operacional; RTO 8 h; RPO 24 h
Moneda y tipo de cambio	CLP; \$930 por USD
Licencias base	\$0; stack open source
Contingencia	10 % del subtotal

El modelo de RRHH considera 220 h de Data/ML, 120 h de Desarrollo/Data Engineering y 72 h de Seguridad y Gobierno. La operación específica agrega 120 h de Cloud/DevOps, 300 h de SysAdmin Local o 280 h de Integración/DevOps Híbrida. En consecuencia, los

totales son 532 h para Cloud, 712 h para Local y 692 h para Híbrida. Las tarifas y horas son supuestos de planificación y cualquier variación debe recalcular el TCO.

15.2. Alternativa Cloud (D8)

Cloud utiliza GCP en la región de Santiago, con Cloud Run, Cloud SQL para PostgreSQL, Cloud Storage, respaldo, monitoreo y gestión de secretos. Se excluyen Vertex AI, BigQuery, GKE, Dataflow, Dataproc y GPU dedicada porque el volumen y la frecuencia de reentrenamiento del piloto no los justifican. La fórmula de reproducción de las partidas GCP es: $\text{USD/mes} \times 36 \text{ meses} \times \930 CLP/USD . Los consumos son bolsas de planificación y deben contrastarse con una exportación fechada de Google Cloud Pricing Calculator antes de contratar.

Cuadro 10: TCO Cloud a 36 meses

Partida	CLP
Cloud SQL	\$768.024
Cloud Run	\$96.720
Storage y respaldo	\$111.600
Logging, monitoreo, secretos y red	\$279.000
Cómputo temporal de reentrenamiento	\$55.800
IVA GCP	\$249.117
RRHH Cloud	\$8.272.000
Subtotal Cloud	\$9.832.261
Contingencia 10 %	\$983.226
TCO Cloud 36 meses	\$10.815.487

El componente predominante es RRHH: \$8.272.000, equivalente al 76,5 % del TCO Cloud corregido. Por ello, una discusión centrada solamente en Cloud Run u hosting no representa el principal impulsor de costo.

Cuadro 11: Base mensual de planificación para servicios GCP

Servicio	USD/mes	Meses	CLP/USD	Total 36 meses CLP
Cloud SQL	22,9398	36	930	\$768.024
Cloud Run	2,8889	36	930	\$96.720
Cloud Storage y respaldo	3,3333	36	930	\$111.600
Observabilidad, secretos y red	8,3333	36	930	\$279.000
Cómputo temporal	1,6667	36	930	\$55.800
Cloud neto	39,1613	36	930	\$1.311.144

15.3. Alternativas Local e Híbrida (D9–D10)

Local conserva aplicación, procesamiento y PostgreSQL dentro del hospital. Aporta control directo del entorno, pero transfiere al hospital la responsabilidad de parches, respaldos, recuperación, monitoreo, energía y renovación de componentes. Híbrida conserva registro maestro, identidad, interfaz e integración en el hospital, mientras entrenamiento e inferencia se realizan en GCP con datos necesarios y pseudonimizados. Reduce infraestructura local, pero exige integración, seguridad y soporte en dos ambientes.

Cuadro 12: Resumen de TCO por alternativa a 36 meses

Alternativa	CAPEX estimado	RRHH	TCO 36 meses
Cloud	Muy bajo	\$8.272.000	\$10.815.487
Local	Alto	\$9.952.000	\$16.893.013
Híbrida	Medio	\$10.832.000	\$15.696.956

Los valores de hardware Local e Híbrido son referencias pendientes de respaldo documental: proveedor, URL o cotización, fecha, especificación comparable y precio con o sin IVA. Por ello se mantienen para comparación, pero deben actualizarse antes de una contratación. En Híbrida, el mayor esfuerzo de RRHH responde a sincronización, seguridad y soporte de dos entornos.

Cuadro 13: Desglose reproducible del TCO Local a 36 meses

Partida	CLP
Servidor Dell PowerEdge T160	\$1.922.010
SSD empresarial	\$697.450
UPS	\$334.350
Medios de respaldo	\$277.720
Red, hardening y accesorios	\$350.000
Energía, mantención y repuestos	\$1.823.755
RRHH Local	\$9.952.000
Subtotal Local	\$15.357.285
Contingencia 10 %	\$1.535.728
TCO Local 36 meses	\$16.893.013

Cuadro 14: Desglose reproducible del TCO Híbrido a 36 meses

Partida	CLP
Equipo local mínimo	\$1.241.850
UPS y respaldo local	\$473.210
Servicios GCP	\$910.000
Conectividad, logs y doble monitoreo	\$640.000
IVA de servicios GCP	\$172.900
RRHH Híbrido	\$10.832.000
Subtotal Híbrido	\$14.269.960
Contingencia 10 %	\$1.426.996
TCO Híbrido 36 meses	\$15.696.956

15.4. Costo-beneficio, sensibilidad y recomendación (D11)

Cloud presenta el menor TCO: ahorra \$6.077.526 frente a Local (36,0 % del TCO Local) y \$4.881.469 frente a Híbrida (31,1 % del TCO Híbrido). Esta recomendación es exclusivamente financiera. Solo se mantiene si la evaluación ética, legal y de riesgos autoriza el tratamiento de datos sensibles en GCP Chile bajo las medidas definidas; si no se satisface esa condición, Híbrida se mantiene como alternativa de respaldo para evaluación integral.

Cuadro 15: Escenarios de sensibilidad financiera

Escenario	Cloud	Local	Híbrida
Tipo de cambio +15 %	+\$234 mil	Sin efecto relevante	+\$162 mil
Cuatro reentrenamientos/año	+\$434 mil	+\$384 mil	+\$530 mil
Usuarios 50 % sobre el plan	+\$291 mil	+\$180 mil	+\$350 mil
Falla de hardware local	Sin efecto directo	+\$1,2 a \$2,0 millones	+\$500 a \$900 mil

Los riesgos financieros a integrar en la matriz de riesgos son variación USD/CLP y consumo cloud, servicios no previstos, falla o renovación de hardware, subestimación de horas, tratamiento tributario distinto e integración más compleja en Híbrida. Las medidas propuestas incluyen contingencia, alertas y límites de gasto, etiquetado por servicio, inventario y garantía de hardware, control de horas en la Gantt y validación tributaria previa a contratación.

16. Planificación integrada, Gantt y recursos (D12–D14)

Esta sección incorpora la planificación integrada elaborada por Fabián Leal. Traduce la línea base técnica D1–D6 y el TCO D7–D11 en un plan ejecutable y trazable (Leal, 2026). Distingue dos horizontes: un piloto de implementación de 10 semanas y una operación financiera y de gobierno de 36 meses. El piloto de 10 semanas es un supuesto de planificación; el horizonte de 36 meses incluye ingesta batch diaria, RTO de 8 h, RPO de 24 h y seis ventanas semestrales de evaluación y eventual reentrenamiento.

16.1. Estructura de Desglose del Trabajo (D12)

La EDT se organiza en seis paquetes de trabajo: (1) gobierno, alcance y línea base; (2) dataset gobernado y pipeline batch; (3) modelos candidatos, explicabilidad y servicio de inferencia; (4) validación técnica, ética y de sesgos; (5) plataforma Cloud segura y piloto; y (6) continuidad operacional y seis ventanas de evaluación. Los entregables de segundo nivel incluyen alcance aprobado, recursos y control TCO, dataset pseudonimizado, almacenamiento seguro, modelos y explicabilidad, auditoría por subgrupos, protocolo Human in the Loop, monitoreo de deriva, entorno GCP, continuidad y reportes semestrales.

16.2. Carta Gantt del piloto (D13)

El [cuadro 16](#) muestra la planificación de 10 semanas. Los solapamientos corresponden a actividades preparatorias compatibles con un enfoque adaptativo; ningún entregable atraviesa su punto de control sin evidencia del predecesor.

Cuadro 16: Carta Gantt resumida del piloto de 10 semanas

EDT	Entregable	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10
1.1	Alcance y requerimientos aprobados	•	•								
1.2–1.4	Recursos y control TCO		•	•	•	•	•	•	•	•	•
2.1–2.3	Dataset inicial, gobierno e ingesta batch		•	•	•						
2.4–2.5	Dataset analítico y almacenamiento seguro			•	•						
3.1–3.2	Modelos candidatos y explicabilidad				•	•					
3.3–3.4	Servicio de inferencia y pruebas					•	•				
4.1–4.2	Validación técnica y por subgrupos					•	•				
4.3–4.4	Human in the Loop y deriva						•				
5.1–5.2	Cloud, IAM y secretos						•	•			
5.3–5.4	Observabilidad, costos, backups y RTO/RPO							•	•		
5.5	Piloto controlado								•		
1.5	Cierre del piloto									•	•

La ruta crítica es: alcance aprobado → dataset analítico → modelo candidato → servicio de inferencia → validación técnica y por subgrupos → gate Human in the Loop → piloto → cierre.

16.3. Hitos, dependencias y continuidad (D14)

Los hitos H1 a H6 ocurren en las semanas 2, 4, 5, 6, 8 y 10, respectivamente: aprobación de alcance y TCO; dataset limpio y pseudonimizado; baseline y explicabilidad; certificación ética, SLA y continuidad; puesta en marcha; y cierre del piloto. H7 se repite en los meses 6, 12, 18, 24, 30 y 36. En cada H7 se evalúan deriva, desempeño, equidad y explicabilidad; un nuevo modelo solo se publica con validación y aprobación clínica.

Cuadro 17: Asignación de recursos de RRHH para la alternativa Cloud

Rol	Implementación	Mantenición	Total
Data Scientist	100 h	120 h	220 h
Desarrollo / Data Engineering	80 h	40 h	120 h
Seguridad y Gobierno	32 h	40 h	72 h
DevOps / Cloud Ops	60 h	60 h	120 h
Total Cloud	272 h	260 h	532 h

Las dependencias principales son de fin a inicio: los modelos requieren el dataset analítico; el servicio requiere un modelo candidato; la validación requiere resultados y pruebas; el piloto exige el gate ético, seguridad, observabilidad y continuidad; y el cierre depende del piloto. Los riesgos de planificación entregados para consolidación incluyen desviación de horas de RRHH, retraso ético/legal, fallas de ingesta batch y volatilidad cambiaria.

Los criterios de aceptación establecen: comparación del modelo candidato con el baseline usando criterios acordados con la contraparte clínica; explicabilidad y supervisión humana; $RTO \leq 8$ h y $RPO \leq 24$ h verificados mediante restauración; pseudonimización, Secret Manager e IAM de mínimo privilegio; y control contra TCO Cloud de \$10.815.487, 532 h de RRHH y contingencia de \$983.226.

17. Anexo de trazabilidad técnica y financiera (D1–D11)

Este anexo conserva el detalle operativo que fundamenta las secciones D1–D11. Distin- gue entre decisiones del equipo, supuestos de planificación, evidencia externa y elementos

que requieren validación posterior. No reemplaza los documentos fuente de Lucas Moncada e Ignacio Silva, que permanecen como respaldo documental (Moncada, 2026; Silva, 2026).

17.1. Trazabilidad del informe maestro D1–D6

Cuadro 18: Cobertura de decisiones del informe maestro de Lucas

Bloque fuente	Decisiones preservadas	Secciones de
D1	Problema, objetivos, alcance, actores y criterios de éxito	Contexto, D1
D2	GCP, componentes, Vertex AI y trade-offs Cloud	D2 y este anexo
D3–D4	Alternativas Local e Híbrida, controles y responsabilidades	D3, D4 y este anexo
D5	Stack base, capas tecnológicas y servicios mínimos	D5 y este anexo
D6	Enfoque adaptativo, ciclos y efecto sobre los demás bloques	Metodología
Supuestos y handoffs	Horizonte, demanda, continuidad, costos, riesgos y elementos abiertos	D7–D14, recordatorio

17.2. Alcance, actores y criterios de D1

El alcance incluye una plataforma interna de apoyo analítico a la prevención cardiovascular, preparación de datos, análisis descriptivo, modelos candidatos, explicabilidad, servicio de inferencia, monitoreo y revisión humana. Quedan fuera de alcance el diagnóstico autónomo, decisiones clínicas automáticas, acceso público de pacientes, integración productiva sin validación, uso de datos identificables fuera de los controles definidos y promesas de precisión clínica no verificadas.

Cuadro 19: Actores, responsabilidades y acceso esperado

Perfil	Rol esperado	Acceso
Profesional clínico	Consulta resultados y explicaciones	Solo pacientes autorizados
Coordinación clínica	Revisa indicadores agregados	Información agregada
Equipo de datos	Prepara, valida y monitorea	Datos pseudonimizados
TI y seguridad	Opera controles y continuidad	Administración con mínimo privilegio
Dirección / gobierno	Aprueba alcance y gates	Reportes consolidados

Los criterios de éxito incluyen trazabilidad de datos y decisiones, funcionamiento bajo supervisión humana, explicabilidad adecuada para revisión clínica, continuidad operacional, seguridad de información y evaluación por subgrupos antes de cualquier publicación de un modelo.

17.3. Arquitecturas, componentes y trade-offs (D2–D4)

Cuadro 20: Matriz consolidada de alternativas de arquitectura

Criterio	Cloud (GCP)	Local	Híbrida
Datos e identidad	Servicios gestionados con controles	Hospital	Identidad y registro maestro local
Procesamiento e inferencia	Cloud Run y cómputo temporal	Infraestructura hospitalaria	GCP con datos minimizados
Persistencia	Cloud SQL y Cloud Storage	PostgreSQL y almacenamiento local	Local más servicios GCP reducidos
Escalabilidad	Alta, pago por uso	Limitada por hardware comprado	Alta para analítica
Riesgo dominante	Proveedor y datos sensibles	Falla, parches y renovación	Sincronización y operación dual

Cloud usa GCP como proveedor de referencia por su región en Santiago, servicios gestionados y portabilidad. Incluye Cloud Run, Cloud SQL, Cloud Storage, IAM, Secret Manager y Logging/Monitoring. Vertex AI no es obligatorio en el piloto. Local conserva datos, procesamiento, inferencia y aplicación en infraestructura del hospital; no se considera seguro por definición, pues depende de controles, mantenimiento y capacidad operacional. Híbrida mantiene identidad, registro maestro e interfaz clínica localmente y ejecuta analítica, entrenamiento e inferencia en GCP después de minimización y pseudonimización. En las tres alternativas se exige la misma funcionalidad base para evitar comparaciones de costo entre productos distintos.

17.4. Herramientas, metodología y supuestos comunes (D5–D6)

Cuadro 21: Stack tecnológico base y criterio de uso

Tecnología	Función
Python, Pandas y NumPy	Preparación y análisis tabular
Scikit-learn	Modelos candidatos de clasificación
PostgreSQL	Persistencia estructurada
SHAP	Explicabilidad local y global
FastAPI y Streamlit	Servicio e interfaz de referencia
Docker y Git	Empaquetado, versionado y trazabilidad

La gestión es adaptativa: conserva alcance y objetivos, pero incorpora ciclos de planificación, análisis, evaluación y ajuste. Frente a una modalidad predictiva, el caso presenta mayor incertidumbre en datos, riesgos, requisitos y solución, por lo que requiere retroalimentación frecuente y revisión continua de sesgos, privacidad y factibilidad.

Cuadro 22: Supuestos comunes cerrados para la evaluación

Parámetro	Decisión
Horizonte	36 meses
Etapas	Piloto institucional controlado
Usuarios iniciales	20 autorizados; hasta 5 concurrentes
Crecimiento	25 y 30 autorizados en años 2 y 3
Volumen	10.000 iniciales; 5.000 nuevos en año 1; 10 % anual
Actualización	Batch incremental diario
Monitoreo y modelo	Revisión mensual y seis ventanas semestrales
Continuidad	99 % operacional; RTO 8 h; RPO 24 h

17.5. Handoffs, aceptación y elementos abiertos

Los handoffs de Lucas entregan a Finanzas la fórmula TCO a 36 meses y las partidas por alternativa; a Planificación, componentes, ciclos, recursos y gates; a Riesgos, semillas de riesgo de proveedor, continuidad, seguridad, datos y operación; y a Ética, supuestos, limitaciones de representatividad, supervisión humana y mitigaciones. La aceptación D1–D6 exige que las tres alternativas compartan alcance funcional, que los componentes costables sean trazables y que los supuestos estén explícitos.

Los elementos deliberadamente abiertos son: cotizaciones y precios finales, definición de población objetivo, umbrales de desempeño, autorización ética/legal, elección definitiva de arquitectura, responsables finales de operación y riesgo residual. Ninguno puede declararse cerrado sin evidencia posterior.

17.6. Desglose financiero reproducible

El costo Cloud neto a 36 meses se compone de Cloud SQL (\$768.024), Cloud Run (\$96.720), Storage y respaldo (\$111.600), observabilidad, secretos y red (\$279.000) y cómputo temporal (\$55.800), antes de IVA. La base GCP de \$1.311.144 recibe IVA de 19 % (\$249.117). Los costos Local consideran servidor \$1.922.010, SSD empresarial \$697.450, UPS \$334.350, medios de respaldo \$277.720, red/hardening \$350.000 y energía, mantención y repuestos \$1.823.755. Híbrida considera equipo local mínimo \$1.241.850, UPS y respaldo \$473.210, servicios GCP \$910.000, conectividad/logs/doble monitoreo \$640.000 e IVA GCP \$172.900.

Cuadro 23: Tarifas y horas de planificación por alternativa

Rol	Cloud	Local	Híbrida
Data Scientist / ML (\$16.000/h)	220 h	220 h	220 h
Desarrollo / Data Engineering (\$14.000/h)	120 h	120 h	120 h
Seguridad y Gobierno (\$16.000/h)	72 h	72 h	72 h
Operación específica	120 h Cloud/DevOps	300 h SysAdmin	280 h Integración/DevOps
Total y costo RRHH	532 h; \$8.272.000	712 h; \$9.952.000	692 h; \$10.832.000

La evidencia de precios de hardware debe completarse con proveedor, enlace o cotización, fecha, especificación comparable y precio con/sin IVA. Hasta entonces, los montos son referencias de planificación y no cotizaciones vinculantes.

18. Anexo de planificación detallada (D12–D14)

Este anexo completa la trazabilidad de planificación de Fabián Leal para la EDT, la Carta Gantt, los gates, dependencias, recursos y riesgos (Leal, 2026).

18.1. Operación recurrente a 36 meses

Cuadro 24: Plan de operación, mantenimiento y evidencia a 36 meses

Entregable recurrente	Frecuencia	Evidencia
Pipeline batch incremental	Diaria	Registro de cargas
Observabilidad y control de costos	Continua	Logs y alertas
Backups diario y semanal	Continua	Bitácora de respaldos
Pruebas de restauración	Mensual	Resultado RTO y RPO
Auditoría de calidad, equidad y gobierno	Semestral	Informe semestral
Evaluación y eventual reentrenamiento	Meses 6, 12, 18, 24, 30 y 36	Acta H7

18.2. Hitos y criterios de salida

Cuadro 25: Gates verificables del proyecto

Hito	Momento	Evidencia de aprobación
H1: Alcance y TCO base	Semana 2	Acta con TCO Cloud y 532 h validados
H2: Dataset validado	Semana 4	Dataset pseudonimizado y pipeline verificado
H3: Baseline y SHAP	Semana 5	Reporte de desempeño y explicabilidad
H4: Ética, SLA y DRP	Semana 6	Auditoría por subgrupos y restauración
H5: Piloto controlado	Semana 8	Servicios GCP y 20 usuarios habilitados
H6: Cierre del piloto	Semana 10	Informe de cierre y decisiones
H7: Evaluación semestral	Meses 6–36	Acta de comité médico

H2 requiere identificadores directos eliminados o pseudonimizados y controles de acceso. H3 exige comparación con el baseline y criterios técnicos acordados durante la validación. H4 exige riesgos documentados, mitigados o aceptados, además de continuidad verificada. En H7 se evalúan deriva, desempeño, equidad y explicabilidad; una nueva versión de modelo solo se publica después de validación y aprobación clínica.

18.3. Dependencias, recursos y riesgos de planificación

Cuadro 26: Dependencias de fin a inicio relevantes

Sucesor	Predecesor que lo habilita
Plan de equipo y recursos	Alcance aprobado
Dataset inicial y pipeline	Alcance aprobado
Dataset analítico	Dataset inicial y controles aplicados
Modelos candidatos	Dataset analítico preparado
Servicio de inferencia	Modelo candidato disponible
Validación técnica	Modelos y pruebas del servicio
Human in the Loop	Validación técnica y auditoría por subgrupos
Piloto controlado	Gate ético, secretos, observabilidad y continuidad
Informe de cierre	Piloto controlado
Ventanas de evaluación	Operación con datos nuevos

Cuadro 27: Recursos y costo de RRHH base Cloud

Rol	Tarifa	Horas totales	Costo CLP
Data Scientist	\$16.000/h	220 h	\$3.520.000
Desarrollo / Data Engineering	\$14.000/h	120 h	\$1.680.000
Seguridad y Gobierno	\$16.000/h	72 h	\$1.152.000
DevOps / Cloud Ops	\$16.000/h	120 h	\$1.920.000
Total Cloud	–	532 h	\$8.272.000

Los riesgos de planificación candidatos son: desviación de horas de RRHH (probabilidad media, impacto alto); retraso ético/legal por uso de GCP y datos de salud (media, alto); fallas de ingesta batch (baja, medio); y volatilidad USD/CLP y sobre costo Cloud (alta, medio). Estos riesgos deben consolidarse en la matriz integral con causa, consecuencia, responsable, mitigación y riesgo residual.

18.4. Criterios de aceptación y cierre

El piloto requiere que el modelo candidato se compare con el baseline y satisfaga criterios de sensibilidad, especificidad, estabilidad y utilidad acordados con la contraparte clínica. Las predicciones deben incluir explicación y revisión humana. La continuidad requiere $RTO \leq 8$ h y $RPO \leq 24$ h comprobados mediante restauración. La seguridad exige pseudonimización, datos de salud tratados como sensibles, Secret Manager e IAM de mínimo privilegio. El control presupuestario se mide contra TCO Cloud de \$10.815.487, 532 h de RRHH y contingencia de 10 % (\$983.226).

19. Anexo de matriz de riesgos integrada

La matriz consolidada identifica riesgos técnicos, legales, financieros, de proyecto y éticos asociados a los entregables D7–D14. La escala empleada es de 1 a 3 para probabilidad e impacto; la prioridad corresponde al producto de ambas dimensiones (Hormazábal, 2026).

Cuadro 28: Matriz de riesgos priorizada: R01–R05

ID	Categoría	P×I	Causa y consecuencia	Mitigación y responsable
R01	Proyecto / financiero	$2 \times 3 = 6$ (Crítico)	Mayor complejidad técnica incrementa horas de RRHH e impacta el 69,7 % del TCO base.	Validar horas en EDT/Gantt, registrar cambios de alcance y monitorear semanalmente. <i>Fabián / Ignacio.</i>
R02	Legal	$2 \times 3 = 6$ (Crítico)	La aprobación para integrar datos de salud en GCP puede retrasar el cronograma de diez semanas.	Aprobación formal temprana y pseudonimización estricta antes de cargar datos. <i>Vicente.</i>
R03	Financiero	$3 \times 2 = 6$ (Crítico)	La variación USD/CLP puede desviar el OPEX planificado.	Contingencia de 10 %, alertas de gasto y revisión mensual. <i>Ignacio.</i>
R04	Financiero	$2 \times 2 = 4$ (Medio)	Egress, logs o servicios administrados no previstos pueden producir cobros adicionales.	Etiquetar costos, asignar presupuesto por servicio y aprobar activaciones. <i>Ignacio.</i>
R05	Técnico / proyecto	$1 \times 2 = 2$ (Bajo)	Descalces de la ingesta batch pueden generar inconsistencia de datos al cierre de jornada.	Monitorear pipeline y cumplir RTO menor a 8 horas. <i>Lucas / Fabián.</i>

Cuadro 29: Matriz de riesgos priorizada: R06–R10

ID	Categoría	P×I	Causa y consecuencia	Mitigación y responsable
R06	Financiero / legal	$2 \times 1 = 2$ (Bajo)	El tratamiento tributario de servicios Cloud podría diferir del 19 % estimado.	Validar el tratamiento con administración institucional antes de contratar. <i>Ignacio / Vicente.</i>
R07	Técnico	$2 \times 3 = 6$ (Crítico)	Si no se aprueba nube pura, la sincronización entre entorno local y GCP puede fallar.	Probar sincronización tempranamente y asignar un responsable técnico único. <i>Lucas.</i>
R08	Legal	$1 \times 3 = 3$ (Medio)	Una brecha de seguridad podría exponer registros clínicos identificables.	Aplicar IAM de mínimo privilegio, Secret Manager y pseudonimización previa. <i>Vicente.</i>
R09	Técnico / ético	$2 \times 2 = 4$ (Medio)	La deriva de datos puede degradar la precisión durante los 36 meses de operación.	Realizar seis ventanas semestrales de reentrenamiento y aprobación médica obligatoria. <i>César / Lucas.</i>
R10	Ético	$2 \times 3 = 6$ (Crítico)	El desbalance de los 10.000 registros iniciales puede generar resultados inequitativos por subgrupos.	Auditar éticamente cada ventana semestral y aplicar explicabilidad local con SHAP. <i>César.</i>

19.1. Criterios de aceptación de riesgos

La matriz satisface los criterios definidos por su fuente: diferencia riesgos técnicos, legales, financieros y éticos; mantiene una escala consistente de probabilidad e impacto; y vincula cada riesgo con una mitigación y un responsable. Las mitigaciones se alinean con la arquitectura Cloud propuesta, el TCO base indicado por la fuente y el plan de RRHH. Los riesgos críticos R01, R02, R03, R07 y R10 deben revisarse en los gates correspondientes antes de avanzar al piloto o a una nueva versión del modelo.

19.2. Consistencia financiera pendiente de validación

La fuente de riesgos menciona un TCO base Cloud de \$11.866.338, mientras que el anexo financiero documenta un TCO Cloud de \$10.815.487. Esta diferencia se conserva

explícitamente como elemento abierto: antes de la aprobación financiera se debe conciliar la base de cálculo, el IVA, la contingencia y las partidas de RRHH para que la matriz de riesgos y el presupuesto usen la misma línea base.

20. Discusión

20.1. Supuestos comunes para las tres alternativas

Las tres alternativas se evalúan durante 36 meses. El horizonte permite comparar CAPEX y OPEX sin castigar artificialmente la inversión inicial de la alternativa Local ni proyectar precios y tecnología a un plazo excesivamente incierto. El TCO debe incluir costos iniciales, implementación, OPEX recurrente, costos periódicos, RRHH y contingencia, respetando la periodicidad de cada partida y evitando doble conteo.

La etapa evaluada es un piloto institucional funcional y mantenible. Incluye infraestructura, aplicación, datos, seguridad, respaldo, monitoreo, RRHH y operación; no incluye integración total con los sistemas del hospital, disponibilidad crítica 24/7 ni despliegue nacional. El cronograma de implementación es independiente del horizonte financiero.

Se consideran 20 usuarios autorizados y hasta 5 concurrentes en el año 1; 25 y 6 en el año 2; y 30 y 8 en el año 3. La curva representa adopción gradual del área cardiovascular y preventiva, no crecimiento de la dotación hospitalaria. Se asume una carga histórica de 10.000 registros, 5.000 nuevos o actualizados durante el primer año, crecimiento de 10 % anual y un acumulado aproximado de 15.000, 20.500 y 26.550 registros en los años 1, 2 y 3. Para sensibilidad se proponen escenarios de 2.500, 5.000 y 10.000 registros anuales iniciales. La referencia de demanda de cardiología en hospitales públicos de Santiago se utiliza solo como orden de magnitud, no como dato del hospital ficticio (Hospital Dr. Sótero del Río, 2017, s.f.; Lagos Barrios, 2024).

La continuidad común exige disponibilidad objetivo de 99 % en horario operacional, RTO máximo de 8 horas, RPO máximo de 24 horas, backup operativo diario, backup completo semanal, retención mínima de 30 días y prueba mensual de restauración. La atención debe continuar si la plataforma no está disponible.

20.2. Detalle de supuestos y sensibilidad

La estimación de 20 usuarios autorizados se distribuye aproximadamente entre 15 profesionales del proceso cardiovascular o preventivo, 3 personas de coordinación o gestión y 2 perfiles técnicos. Es un supuesto de dimensionamiento, no una estadística del hospital ficticio. La referencia histórica de una unidad de cardiología infantil con 14 integrantes y el dato institucional de más de 5.000 funcionarios se usan solo para contextualizar el orden de magnitud (Hospital Dr. Sótero del Río, 2017, s.f.).

El escenario de volumen utiliza 10.000 registros históricos al inicio; 5.000 registros nuevos o actualizados en el año 1; 5.500 en el año 2; y 6.050 en el año 3. Los acumulados estimados son 10.000 al inicio, 15.000, 20.500 y 26.550 respectivamente. Los escenarios de sensibilidad son bajo, con 2.500 registros anuales iniciales; base, con 5.000; y alto, con 10.000.

Para la sensibilidad financiera también puede analizarse un escenario de cuatro ciclos de reentrenamiento por año, frente a los dos ciclos semestrales de la línea base. Las alternativas deben costearse para el mismo nivel de continuidad; ninguna puede parecer más barata por ofrecer menor respaldo o recuperación.

20.3. Comparación consolidada

Cloud GCP

Los datos, entrenamiento e inferencia se ejecutan en GCP y Cloud Run; la interfaz es cloud autenticada. Tiene CAPEX bajo, OPEX variable y RRHH, escalabilidad alta y rápida, alta dependencia de Internet, menor control físico y complejidad media. El MLOps avanzado queda para una etapa futura si se justifica.

Local

Los datos, entrenamiento e inferencia permanecen en el hospital y la interfaz opera en la red interna. Tiene CAPEX mayor y costos de operación y mantenimiento local, escalabilidad posible pero menos elástica, baja dependencia de Internet, mayor control físico y complejidad media. El MLOps avanzado es posible, con mayor esfuerzo local.

Híbrida

La identidad, el registro maestro y la interfaz permanecen locales; el dataset analítico controlado, el entrenamiento y la inferencia se ejecutan en GCP. Tiene CAPEX intermedio, operación dual, costos cloud y RRHH, alta escalabilidad analítica, dependencia media o alta de Internet para inferencia, mayor control de identidad y complejidad alta. El MLOps avanzado queda para cloud si se justifica.

20.4. Riesgos y elementos pendientes

Los riesgos transversales incluyen calidad de datos, duplicados, cambios de esquema, retrasos, fallos de pipeline, drift, degradación del modelo, baja explicabilidad y fallos de respaldo. Cloud agrega dependencia de GCP, conectividad, costos variables, errores IAM, exposición y lock-in; Local incorpora ransomware, software desactualizado, fallos de servidor o UPS, respaldo comprometido, falta de personal especializado y segmentación deficiente; Híbrida añade fallos de sincronización, inconsistencias, exposición durante transferencia y doble operación.

No se cierran aún el precio y sizing final de GCP, el hardware local exacto, las horas por rol y duración de implementación, la alternativa financiera preferida, la matriz de riesgos residual, el análisis legal vigente, los sesgos e impactos éticos finales ni la alternativa recomendada. Estas decisiones requieren la integración de los responsables correspondientes.

La auditoría de aceptación concluye que las alternativas comparten problema y alcance, las herramientas tienen función justificada y la metodología está argumentada. Finanzas y planificación pueden trabajar con los supuestos y handoffs definidos, aunque los precios, dimensionamientos y análisis integrales quedan pendientes.

21. Conclusiones

La línea base conceptual D1 a D6 define una plataforma de apoyo a la prevención cardiovascular, no un sistema de diagnóstico autónomo. La comparación entre Cloud, Local e Híbrida es válida porque las tres alternativas conservan el mismo alcance, los mismos supuestos de usuarios, registros, operación, reentrenamiento y continuidad.

El stack propuesto es portable, mantenible y predominantemente open source. GCP se usa como escenario Cloud concreto, sin imponer servicios avanzados de ML antes de que su necesidad esté demostrada. La alternativa Local ofrece control directo, pero exige una operación y postura de seguridad sostenida. La alternativa Híbrida equilibra control de identidad local con elasticidad analítica en cloud, a costa de mayor integración y operación dual.

El enfoque adaptativo es consistente con la incertidumbre de los datos y del proyecto. La elección definitiva entre arquitecturas no puede establecerse con seriedad antes de integrar costos, riesgos, aspectos éticos y restricciones legales.

22. Recomendaciones

22.1. Handoff para evaluación financiera

La evaluación financiera debe costear Cloud, Local e Híbrida con los mismos supuestos de horizonte, piloto, usuarios, volumen, actualización, mantenimiento de modelo y continuidad. Cloud debe considerar configuración, seguridad, despliegue, Cloud Run, Cloud SQL, Storage, red, monitoreo, soporte, RRHH y cómputo temporal; no debe suponer entrenamiento 24/7 ni Vertex AI obligatorio. Local debe incluir CAPEX de infraestructura, hardening, electricidad, mantenimiento, seguridad, backup, soporte y RRHH, dimensionado al menos para el escenario del año 3. Híbrida debe sumar infraestructura local mínima, costos cloud e integración, conectividad, monitoreo de ambos ambientes y el esfuerzo de operación dual.

La sensibilidad mínima debe variar registros anuales (2.500 y 10.000 frente al escenario base de 5.000), reentrenamientos (4 frente a 2 por año), usuarios cuando corresponda y el componente dominante de costo de cada arquitectura.

22.2. Fórmula y reglas de costeo

La estructura común es $TCO_{36\text{ meses}} = \text{CAPEX}$ o costos iniciales + implementación + suma de OPEX recurrente del horizonte + costos periódicos + RRHH + contingencia justificada. Cada partida debe respetar su periodicidad real para evitar multiplicaciones incorrectas o doble conteo.

Cloud debe dimensionarse para 20, 25 y 30 usuarios; 5, 6 y 8 usuarios concurrentes; 10.000 registros históricos más el crecimiento definido; batch diario; y los RTO/RPO comunes. Local debe soportar al menos el escenario del año 3 sin una sustitución completa por el crecimiento base. Híbrida debe incluir el costo y el impacto de seguridad y sincronización entre ambos ambientes.

22.3. Handoff para planificación, riesgos e integración

La EDT y carta Gantt deben orientarse a entregables: inicio y alcance, datos, preparación, análisis y modelo, validación técnica y ética, infraestructura o piloto, documentación y cierre. Deben incluir backup, monitoreo, recuperación y mantenimiento como trabajo gestionable, y separar la duración de implementación de los 36 meses financieros.

La matriz de riesgos debe consolidar los riesgos técnicos expuestos en la Sección 20 con los riesgos financieros, éticos, legales y de planificación. Para la integración ética, debe mantenerse que el sistema no reemplaza al profesional, que el dataset actual es un prototipo y que Cloud e Híbrida tratan datos sensibles fuera del entorno local. La recomendación final no debe decidirse solo por precio.

22.4. Handoffs nominales y matriz de riesgos semilla

Ignacio recibe los componentes, supuestos y fórmulas para la evaluación financiera. El responsable de EDT o Carta Gantt recibe D1 como línea base de alcance, usuarios y límites, junto con la necesidad de una EDT orientada a entregables. Vicente recibe los riesgos técnicos preliminares para consolidarlos con riesgos financieros, éticos, legales y de planificación. César recibe las restricciones para la integración ética y la recomendación final.

Transversal

Calidad de datos, duplicados, cambios de esquema, datos retrasados, fallos del pipeline, drift, degradación del modelo, baja explicabilidad y fallo de backup.

Cloud

Dependencia de GCP, pérdida de conectividad, costos variables, error IAM, exposición de datos, indisponibilidad del proveedor y lock-in.

Local

Ransomware, software desactualizado, fallo de servidor o UPS, backup comprometido, falta de personal especializado, escalabilidad lenta y mala segmentación.

Híbrida

Fallo de sincronización, inconsistencia entre entornos, exposición durante transferencia, mayor complejidad, dependencia de Internet para inferencia y doble operación.

Continuidad

RTO superior a 8 horas, RPO superior a 24 horas, restauración fallida y pérdida de datos analíticos.

Mantenimiento ML

Reentrenar con datos defectuosos, nueva versión peor, incremento de sesgos, pérdida de trazabilidad o publicación sin aprobación.

22.5. Matriz de trazabilidad de decisiones

Apoyo preventivo

Se fundamenta en el caso y EA1; se usa para ética y para delimitar el alcance de planificación.

Tres alternativas con mismo alcance

Se fundamenta en el Plan Maestro; permite comparación financiera y análisis de riesgos equivalentes.

GCP como referencia Cloud

Se fundamenta en la decisión de diseño, región de Santiago y simplicidad; permite tarifar Cloud y revisar sus riesgos.

Stack portable y open source

Se fundamenta en costo-beneficio y comparabilidad; sirve para licencias y planificación de recursos.

Sin Vertex AI inicial

Evita sobrearquitectura a la escala actual; define el costo base y los gatillos de escalamiento futuro.

Local con seguridad reforzada

Se fundamenta en EA1 y contexto MINSAL; alimenta ciberseguridad, costos de seguridad y continuidad.

Híbrida con minimización y pseudonimización

Se fundamenta en privacidad y diseño del caso; alimenta ética, legalidad, riesgos e integración.

Metodología adaptativa

Se fundamenta en incertidumbre; define ciclos, hitos y revisiones de EDT o Gantt.

Horizonte de 36 meses

Hace comparables CAPEX y OPEX para el TCO.

Piloto controlado

Evita comparar un notebook trivial con una producción ficticia y delimita el alcance de todos los análisis.

Crecimiento de usuarios, volumen, batch y reentrenamiento

Entregan bases comunes para sizing, costos, operación, riesgos y validación.

99 %, RTO 8 h y RPO 24 h

Definen respaldo, pruebas, planificación y riesgos de continuidad.

22.6. Auditoría de aceptación D1 a D6

La línea base cumple con que las tres alternativas resuelven el mismo problema y alcance; cada herramienta tiene una función y motivo; y la metodología está argumentada, no solo nombrada. También permite a Ignacio costear sin inventar componentes mediante los supuestos y el handoff, aunque aún faltan precios y sizing exactos. Permite construir EDT y Gantt sin reinterpretar el alcance; distingue proyecto conceptual de ejecución real; mantiene fuentes y supuestos trazables; y prohíbe declarar una alternativa ganadora antes de integrar finanzas, riesgos y ética.

22.7. Checklist de integración

- Mantener D1 a D6 como línea base y comunicar cualquier cambio a finanzas, planificación, riesgos e integración.
- No declarar una alternativa ganadora antes de terminar los análisis financiero, de riesgos y ético.
- Usar los mismos supuestos para Cloud, Local e Híbrida.
- Distinguir datos reales, referencias externas y supuestos de planificación.
- Respalda cada cifra de costos con tarifario, cotización o supuesto reproducible.

- Conservar el carácter de apoyo preventivo y no diagnóstico autónomo.
- Sintetizar el informe final EP1 a 4–6 páginas, con letra 11, interlineado simple y estilo APA; este documento maestro puede ser más extenso.
- Corregir la consistencia del responsable de EDT o Gantt antes de la entrega final, si existen nombres distintos en los documentos del equipo.

23. Referencias

- Equipo de proyecto. (2026). Plan Maestro del Encargo Heart Disease Dataset equipo de 5 [Documento interno].
- Google Cloud. (2026a). *Resource location restrictions*. Consultado el 10 de septiembre de 2026, desde <https://docs.cloud.google.com/organization-policy/restrict-locations?hl=es>
- Google Cloud. (2026b). *What is Cloud Run*. Consultado el 10 de septiembre de 2026, desde <https://docs.cloud.google.com/run/docs/overview/what-is-cloud-run>
- Hormazábal, V. (2026). *Matriz de Riesgos, Priorización y Mitigaciones* (Documento interno de proyecto, versión 2).
- Hospital Dr. Sótero del Río. (2017). *El valioso trabajo de la Unidad de Cardiología Infantil*. Consultado el 10 de septiembre de 2026, desde <https://www.hospitalsoterodelrio.cl/web/el-valioso-trabajo-de-la-unidad-de-cardiologia-infantil/>
- Hospital Dr. Sótero del Río. (s.f.). *Quiénes somos*. Consultado el 10 de septiembre de 2026, desde <https://www.hospitalsoterodelrio.cl/web/quienessomos/>
- Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). *Heart Disease*. UCI Machine Learning Repository. <https://doi.org/10.24432/C52P4X>
- JohnSmith88. (s.f.). *Heart Disease Dataset*. Consultado el 10 de septiembre de 2026, desde <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>
- Lagos Barrios, R. (2024). Método para medir brechas de consultas médicas de especialidad en la programación de hospitales públicos. *Revista Médica de Chile*, 152(10), 1049-1059. https://www.scielo.cl/scielo.php?pid=S0034-98872024001001049&script=sci_arttext
- Leal, F. (2026). *Planificaci3n del proyecto: Entregables D12 a D14* (Documento interno de proyecto).
- Ministerio de Salud de Chile. (s.f.-a). *Orientaciones para la planificación Programa de Salud Cardiovascular*. Consultado el 10 de septiembre de 2026, desde <https://www.minsal.cl/orientaciones-para-la-planificacion/>
- Ministerio de Salud de Chile. (s.f.-b). *Plan Director Hoja de Ruta de Ciberseguridad y Seguridad de la Información para el Sector Salud*. Consultado el 10 de septiembre de 2026, desde <https://www.minsal.cl/wp-content/uploads/2015/08/PLAN->

[DE-CIBERSEGURIDAD-Y-SEGURIDAD-DE-LA-INFORMACION-SECTOR-SALUD-2024-2025-ITS-NC-03-V1.1.pdf](#)

- Ministerio de Salud de Chile. (s.f.-c). *Seguridad de la Información y Ciberseguridad del MINSAL*. Consultado el 10 de septiembre de 2026, desde https://www.minsal.cl/seguridad_de_la_informacion/
- Moncada, L. (2026). *Informe Maestro D1 a D6 Heart Disease* (Documento interno de proyecto).
- SCY1102 Gestión de Proyectos de Datos. (2025a). Evaluación de Factibilidad Financiera y de Riesgos de Proyectos de Ciencia de Datos [Presentación].
- SCY1102 Gestión de Proyectos de Datos. (2025b). Evaluación de Factibilidad Técnica y Ética de un Proyecto de Ciencia de Datos [Presentación].
- SCY1102 Gestión de Proyectos de Datos. (2025c). Evaluación de Proyectos de Ciencia de Datos [Material docente].
- SCY1102 Gestión de Proyectos de Datos. (2025d). Evaluación Parcial N 1 Instrucciones y pauta de evaluación Estudiante [Documento de evaluación].
- SCY1102 Gestión de Proyectos de Datos. (2025e). Integración y Comunicación de los Resultados de un Proyecto de Ciencia de Datos [Presentación].
- Silva, I. (2026). *Evaluación financiera Cloud, Local e Híbrida: Entregables D7 a D11* (Documento interno de proyecto).
- U.S. Food and Drug Administration. (2024). *Transparency for Machine Learning-Enabled Medical Devices: Guiding Principles*. Consultado el 10 de septiembre de 2026, desde <https://www.fda.gov/medical-devices/software-medical-device-samd/transparency-machine-learning-enabled-medical-devices-guiding-principles>
- World Health Organization. (2021). *Ethics and Governance of Artificial Intelligence for Health: WHO Guidance*. Consultado el 10 de septiembre de 2026, desde <https://www.who.int/publications/i/item/9789240029200>