

Análisis del Dataset Heart Disease

Línea base conceptual D1 a D6 para gestión de proyectos de datos

Lucas Moncada

Septiembre de 2026

Índice

1. Resumen ejecutivo	1
2. Introducción	1
2.1. Estado y trazabilidad documental	2
3. Contexto del problema	3
3.1. Objetivo general	3
3.2. Objetivos específicos	3
3.3. Usuarios y criterios de éxito	3
4. Descripción del dataset	4
4.1. Alcance de los datos	4
5. Metodología	5
5.1. Ciclos de gestión propuestos	5
6. Preparación de datos	6
6.1. Frecuencia operacional de datos y modelo	6
6.2. Validación de duplicados	6
7. Análisis exploratorio	7
7.1. Efecto de la deduplicación	7
7.2. Representación y subgrupos	9
8. Análisis D1	10
8.1. Alcance funcional	10
8.2. Fuera de alcance	10
8.3. Arquitectura lógica común	10
9. Análisis D2	10
9.1. Alternativa Cloud	10
9.2. Decisión sobre Vertex AI	11
9.3. Beneficios, riesgos y componentes costables	11
10. Análisis D3	11
10.1. Alternativa Local u on-premise	11
10.2. Seguridad y continuidad	12

11.Análisis D4	12
11.1. Alternativa Híbrida	12
11.2. Distribución explícita de responsabilidades	13
12.Análisis D5	13
12.1. Herramientas y stack tecnológico	13
12.2. Stack base común	13
13.Análisis D6	14
13.1. Justificación del enfoque adaptativo	14
13.2. Criterios completos de comparación	15
14.Discusión	16
14.1. Supuestos comunes para las tres alternativas	16
14.2. Detalle de supuestos y sensibilidad	16
14.3. Comparación consolidada	17
14.4. Riesgos y elementos pendientes	17
15.Conclusiones	18
16.Recomendaciones	18
16.1. Handoff para evaluación financiera	18
16.2. Fórmula y reglas de costeo	19
16.3. Handoff para planificación, riesgos e integración	19
16.4. Handoffs nominales y matriz de riesgos semilla	19
16.5. Matriz de trazabilidad de decisiones	20
16.6. Auditoría de aceptación D1 a D6	21
16.7. Checklist de integración	21
17.Referencias	22

1. Resumen ejecutivo

Este documento establece la línea base conceptual para una plataforma interna de apoyo a la prevención cardiovascular. La propuesta busca transformar datos disponibles en conocimiento sobre factores asociados a enfermedad cardíaca y, en una etapa posterior, apoyar la priorización de evaluaciones preventivas. No corresponde a un sistema de diagnóstico autónomo ni reemplaza la decisión de los profesionales de salud.

Se comparan tres alternativas técnicamente equivalentes: una implementación Cloud en Google Cloud Platform (GCP), una alternativa Local dentro de la infraestructura hospitalaria y una arquitectura Híbrida. Las tres conservan el mismo alcance funcional, el mismo horizonte de evaluación y los mismos supuestos operacionales; cambian principalmente la ubicación de los componentes, la responsabilidad de operación, el perfil de costos y los riesgos.

La línea base define un stack portable y predominantemente open source, formado por Python, Pandas, Scikit-learn, PostgreSQL, SHAP, FastAPI, Streamlit, Docker y Git. La gestión propuesta es adaptativa, con ciclos incrementales, revisiones, hitos y capacidad de ajuste ante la incertidumbre propia de los datos, el modelamiento, los riesgos y la validación.

El piloto se evalúa a 36 meses, con 20 usuarios autorizados en el primer año, crecimiento a 25 y 30 usuarios, y concurrencia de 5, 6 y 8 usuarios respectivamente. Se asume una carga histórica inicial de 10.000 registros analíticos, 5.000 registros nuevos o actualizados durante el primer año y crecimiento anual de 10 %. La carga se actualiza mediante un proceso batch diario y la inferencia se solicita bajo demanda. La plataforma debe mantener una disponibilidad objetivo de 99 % durante el horario operacional, con RTO máximo de 8 horas, RPO máximo de 24 horas, respaldos diarios y pruebas mensuales de restauración.

La alternativa final no se declara en esta etapa. La recomendación deberá integrar la evaluación financiera, el análisis de riesgos, las restricciones éticas y legales, y la factibilidad técnica.

2. Introducción

El caso aborda la utilización de un dataset de enfermedad cardíaca como base académica y de prototipo para un proyecto de ciencia de datos en salud pública. El documento organiza las decisiones de D1 a D6 y los supuestos comunes que permiten al resto del equipo desarrollar los análisis de finanzas, planificación, riesgos e integración final.

La estructura se apoya en los contenidos docentes de Gestión de Proyectos de Datos, la pauta de la evaluación, el Plan Maestro del equipo y el caso Heart Disease. Para mantener la trazabilidad, se distingue entre contenido respaldado por estos documentos, evidencia externa de contexto, decisiones de diseño y supuestos de planificación. Las decisiones

concretas de arquitectura y los valores de dimensionamiento son adaptaciones para el caso; no se presentan como hechos declarados por una institución hospitalaria real.

El alcance corresponde a un piloto institucional controlado y mantenible. No se dimensiona la infraestructura para las 1.025 filas del dataset académico ni se afirma que este represente la futura población productiva del hospital. El objetivo es disponer de una base seria y comparable para evaluar alternativas, sin simular un despliegue clínico definitivo.

2.1. Estado y trazabilidad documental

El informe maestro identifica a Lucas Moncada como responsable del bloque, declara la línea base conceptual D1 a D6 como cerrada en su versión 1.0 y sitúa la evaluación en septiembre de 2026. Su propósito es habilitar los análisis de finanzas, planificación, riesgos e integración final; se evalúa un piloto institucional controlado y mantenible durante un horizonte de 36 meses.

EA1 1.1

Aporta sesgos, ciclo de vida del dato, justicia, transparencia, privacidad, responsabilidad y mitigación.

EA1 1.2

Aporta viabilidad técnica, datos, seguridad, escalabilidad, riesgos, RBAC, Zero Trust, anonimización y explicabilidad.

EA1 1.3

Aporta costos cloud, licencias, RRHH, servicios, costo-beneficio, ROI, escenarios, riesgos y mitigaciones.

EA1 1.4

Aporta la integración técnica, financiera, ética y de riesgos, además de la comunicación de supuestos y limitaciones.

Rúbrica EP1

Exige ética 30 %, finanzas 30 %, riesgos 40 %, extensión de 4 a 6 páginas y referencias APA.

Plan Maestro

Define responsabilidades D1 a D22, criterios de aceptación, dependencias y handoffs.

Caso y dataset

Fundamentan la necesidad de comprender factores asociados al riesgo y priorizar prevención con un dataset académico de referencia.

3. Contexto del problema

Un hospital público dispone de información obtenida durante controles cardiovasculares preventivos, pero no cuenta con una solución analítica que transforme sistemáticamente esos datos en conocimiento sobre los factores asociados a enfermedad cardíaca ni que apoye la priorización de acciones preventivas.

La solución propuesta es una plataforma interna de apoyo analítico para prevención cardiovascular. Debe procesar información clínica, analizar factores asociados a enfermedad cardíaca y evolucionar hacia estimaciones de riesgo que ayuden a priorizar evaluaciones preventivas. La supervisión de profesionales de salud se mantiene durante todo el proceso.

3.1. Objetivo general

Diseñar y evaluar una solución de ciencia de datos mantenible, segura y explicable para analizar factores asociados a enfermedad cardíaca y apoyar la priorización de pacientes en controles cardiovasculares preventivos. La evaluación compara alternativas Cloud, Local e Híbrida, sin delegar la decisión clínica en el sistema.

3.2. Objetivos específicos

- Preparar y analizar los datos cardiovasculares para determinar su calidad, representatividad y utilidad analítica.
- Identificar variables y patrones asociados con la presencia de enfermedad cardíaca.
- Desarrollar y evaluar progresivamente modelos de apoyo a la estimación de riesgo cardiovascular.
- Incorporar explicabilidad, evaluación de sesgos, privacidad y supervisión humana en el ciclo de la solución.
- Diseñar una arquitectura mantenible que permita incorporar nuevos datos, monitorear la solución y evolucionarla.

3.3. Usuarios y criterios de éxito

Los profesionales clínicos y preventivos consultarán resultados como apoyo; coordinación y gestión cardiovascular utilizarán información agregada para planificar acciones; y los equipos de TI y datos administrarán operación, permisos, monitoreo y soporte bajo el principio de mínimo privilegio. El paciente es un beneficiario indirecto y no se considera una interfaz pública de paciente para el piloto.

El éxito técnico requiere una arquitectura mantenible y trazable; el éxito clínico-operacional exige resultados comprensibles sin bloquear el flujo clínico si la plataforma no está disponible; el éxito ético requiere explicabilidad, supervisión humana, protección de

datos y evaluación por subgrupos; y el éxito financiero y de gestión exige una alternativa sostenible, con alcance, costos, riesgos, recursos y decisiones coherentes.

4. Descripción del dataset

El archivo `heart.csv` utilizado en el caso contiene 1.025 registros y 14 variables, incluida la variable objetivo `target`. No presenta valores nulos y contiene 723 filas duplicadas exactas. La clase objetivo está relativamente equilibrada, con 526 registros cuyo `target` es 1 y 499 cuyo `target` es 0. La variable `sex` presenta 713 registros con valor 1 y 312 con valor 0; la edad observada se encuentra entre 29 y 77 años.

Cuadro 1: Caracterización inicial del dataset original

Indicador	Valor
Registros	1.025
Variables	14
Valores nulos	0
Filas duplicadas exactas	723 (70,54 %)
Registros únicos	302
<code>target=0</code> / <code>target=1</code>	499 / 526
<code>sex=0</code> / <code>sex=1</code>	312 / 713
Rango de edad	29–77 años

Estas características orientan la factibilidad inicial, pero no validan por sí mismas la representatividad del dataset ni la pertinencia de un uso clínico. El dataset de Kaggle se utiliza como referencia académica y de prototipo; no se asume que sea la base productiva definitiva del hospital. Los códigos de `sex` se mantienen sin asignarles una categoría demográfica, ya que la documentación local disponible no define formalmente su significado.

4.1. Alcance de los datos

La preparación debe detectar faltantes, duplicados, valores inválidos y cambios de esquema. El análisis posterior debe evaluar calidad, estabilidad, representatividad, privacidad y posibles sesgos por subgrupos antes de que un modelo pueda considerarse para apoyo operativo.

5. Metodología

La gestión se basa en un enfoque adaptativo. Esta denominación describe la forma de gestionar el proyecto y no un tipo de modelo predictivo. Se elige porque los requisitos, la calidad y representatividad de los datos, el desempeño de las alternativas, los riesgos y las necesidades de validación pueden evolucionar durante el proyecto.

En lugar de asumir una planificación completamente estable, el enfoque adaptativo organiza ciclos incrementales de planificación, análisis, evaluación y ajuste. Cada ciclo mantiene entregables, responsables e hitos definidos, pero permite incorporar evidencia antes de decidir las etapas siguientes.

5.1. Ciclos de gestión propuestos

Ciclo 1

Comprensión del problema, objetivos, actores y criterios de éxito. Hito: alcance inicial aprobado.

Ciclo 2

Comprensión y evaluación de datos: calidad, representatividad y privacidad. Hito: factibilidad inicial de datos validada.

Ciclo 3

Diseño y evaluación de Cloud, Local e Híbrida, herramientas, costos preliminares y riesgos. Hito: alternativas técnicamente viables.

Ciclo 4

Evaluación integral técnica, ética, financiera, legal y de riesgos. Hito: alternativa preferida seleccionada.

Ciclo 5

Planificación de un eventual piloto: recursos, seguridad, operación y mantenimiento. Hito: plan de ejecución aprobado.

Ciclo 6

Evaluación, retroalimentación, ajustes y lecciones aprendidas. Hito: decisión de continuidad o escalamiento.

La planificación debe incluir revisiones, hitos y capacidad de ajuste; las finanzas deben incorporar horas de revisión e iteración; los riesgos deben reevaluarse durante los ciclos; y la ética debe considerar sesgos y explicabilidad de forma continua, no solo al cierre.

6. Preparación de datos

La preparación de datos constituye una capacidad permanente de la plataforma. La ingesta debe ser controlada, con validación de faltantes, duplicados, valores inválidos y cambios de esquema antes de actualizar las vistas analíticas o habilitar nuevos datos para análisis y modelamiento.

Los registros nuevos o modificados se incorporarán mediante un proceso batch incremental diario, preferentemente al cierre de la jornada clínica. No se requiere streaming ni ingestión continua para el piloto. La inferencia se ejecuta bajo demanda y se mantiene separada del proceso de incorporación de datos.

6.1. Frecuencia operacional de datos y modelo

Cada jornada operacional

Validación e incorporación de nuevos registros mediante batch diario.

Posterior a la carga diaria

Actualización de dashboard y estadísticas.

Bajo demanda

Inferencia de riesgo solicitada por el profesional.

Mensual

Revisión de cambios de distribución.

Trimestral

Revisión formal de desempeño, estabilidad, sesgos y explicabilidad.

Semestral

Ventana planificada de reentrenamiento y evaluación, dos veces al año.

Siempre

La sustitución del modelo requiere validación y aprobación; nunca es automática.

6.2. Validación de duplicados

La revisión reproducible confirma que los 723 duplicados son coincidencias exactas al considerar las 14 columnas. El [cuadro 2](#) muestra la frecuencia de repetición de las 302 observaciones distintas: no hay observaciones con una o dos apariciones, 187 se repiten tres veces, 114 cuatro veces y una observación aparece ocho veces. Esta evidencia no permite atribuir la causa a fraude, error de captura o sesgo; sí exige definir y documentar su tratamiento antes de cualquier modelamiento.

Cuadro 2: Frecuencia de repetición de observaciones exactas en el dataset original

Repeticiones	Observaciones distintas	Filas asociadas	% del original
1 vez	0	0	0,00 %
2 veces	0	0	0,00 %
3 veces	187	561	54,73 %
Más de 3 veces (4 u 8)	115	464	45,27 %
Total	302	1.025	100,00 %

Para garantizar trazabilidad, `data/raw/heart.csv` se conserva como fuente primaria inmutable. La versión `data/processed/heart_unique.csv` se deriva exclusivamente mediante `drop_duplicates()` y se utiliza como análisis de sensibilidad; no reemplaza al archivo original.

7. Análisis exploratorio

El análisis exploratorio se orienta a comprender la calidad y utilidad de los datos para el problema, no a producir visualizaciones sin propósito. La línea base identifica ausencia de valores nulos, 723 duplicados exactos, balance relativo de `target`, distribución observada de `sex` y edad entre 29 y 77 años.

7.1. Efecto de la deduplicación

Se comparó el archivo original con la versión deduplicada de 302 registros. El [cuadro 3](#) cuantifica las diferencias en puntos porcentuales, en lugar de asumir que la eliminación de duplicados no afecta las distribuciones. La proporción de `target=1` aumenta 2,99 puntos porcentuales tras deduplicar; la distribución de `sex` cambia 1,35 puntos porcentuales por código.

Cuadro 3: Distribución de `target` y `sex`: original versus deduplicado

Categoría	Original (%)	Deduplicado (%)	Diferencia (pp)
<code>target=0</code>	48,68	45,70	-2,99
<code>target=1</code>	51,32	54,30	+2,99
<code>sex=0</code>	30,44	31,79	+1,35
<code>sex=1</code>	69,56	68,21	-1,35




Figura 1: Comparación de la distribución de **sex** en el dataset original y deduplicado.

Cuadro 4: Distribución por rangos etarios: original versus deduplicado

Rango etario	Original (%)	Deduplicado (%)	Diferencia (pp)
< 40	5,56	4,97	-0,59
40–49	23,12	23,84	+0,72
50–59	41,17	41,39	+0,22
60–69	26,83	26,49	-0,34
70+	3,32	3,31	-0,01




Figura 2: Comparación de los rangos etarios en el dataset original y deduplicado.

7.2. Representación y subgrupos

En la versión deduplicada, **sex**=0 concentra 96 registros (31,79 %) y **sex**=1 concentra 206 (68,21 %). Los rangos < 40 (15 registros; 4,97 %) y 70+ (10; 3,31 %) disponen de menos evidencia que los rangos centrales. La [figura 3](#) presenta los tamaños de las combinaciones **sex**×**rango etario**. Los subgrupos **sex**=0 con < 40 y con 70+ tienen cinco registros únicos cada uno; por ello, sus porcentajes de **target** son descriptivos y no constituyen evidencia de diferencias ni de sesgo demostrado.




Figura 3: Tamaño deduplicado de los subgrupos **sex**×**rango etario**.

La evidencia sugiere posibles limitaciones de cobertura y generalización que deben validarse frente a la población objetivo. No permite afirmar discriminación, ni interpretar los códigos de **sex** sin confirmar su definición en la fuente oficial.

8. Análisis D1

8.1. Alcance funcional

La solución incluye: ingesta controlada de datasets cardiovasculares; validación de calidad; preparación para análisis y modelamiento; análisis exploratorio orientado al problema; comparación conceptual de modelos candidatos; métricas técnicas, estabilidad y evaluación por subgrupos; explicabilidad; una interfaz interna de referencia; versionado y trazabilidad del modelo; monitoreo de degradación, drift y fallos operacionales; y documentación de arquitectura, supuestos, riesgos, procedimientos y operación.

8.2. Fuera de alcance

Quedan expresamente fuera de alcance el diagnóstico médico automático, las recomendaciones automáticas de tratamiento, la negación o asignación automática de atención, la sustitución de personal sanitario, la integración productiva completa con HIS/EHR, el despliegue clínico definitivo y una plataforma nacional o multihospital desde el inicio. Estas exclusiones reducen el riesgo clínico y ético, respetan la información disponible y mantienen el proyecto dentro de un piloto institucional controlado.

8.3. Arquitectura lógica común

Para comparar las tres alternativas de manera justa, todas resuelven el mismo problema y mantienen el mismo alcance funcional. La cadena lógica es: fuente de datos hospitalaria, validación y control de calidad, almacenamiento estructurado o analítico, preparación y procesamiento, modelo o servicio de inferencia, API de aplicación, interfaz de usuario, y monitoreo, trazabilidad y respaldo.

Las diferencias de costo no deben provenir de comparar productos con funcionalidades distintas. Cambia dónde se ejecutan los componentes, quién los administra y cómo se distribuyen los costos y riesgos.

9. Análisis D2

9.1. Alternativa Cloud

La alternativa Cloud utiliza Google Cloud Platform (GCP) como proveedor de referencia. Esta elección no implica que GCP sea un ganador universal frente a AWS o Azure: la pauta exige evaluar infraestructura, almacenamiento, cómputo, redes, costos, escalabilidad y riesgos. GCP se selecciona para contar con un escenario reproducible, por su región en

Santiago (`southamerica-west1`), la posibilidad de restringir ubicaciones de recursos, y la simplicidad de una arquitectura gestionada y portable (Google Cloud, 2026a, 2026b).

La aplicación se ejecuta en Cloud Run mediante contenedores Docker; Cloud SQL for PostgreSQL mantiene la persistencia estructurada; Cloud Storage almacena datasets, respaldos y artefactos; IAM, Secret Manager y Cloud Logging/Monitoring administran permisos, secretos y observabilidad. Python, Scikit-learn y SHAP conservan un stack portable y evitan una dependencia obligatoria de servicios propietarios de ML.

9.2. Decisión sobre Vertex AI

Vertex AI queda como capacidad futura y no como componente obligatorio del piloto. Una plataforma gestionada no sustituye la definición del problema, la validación de datos, la evaluación de sesgos, las métricas ni la operación. Su incorporación se evaluará si aumentan el volumen de datos, la cantidad de modelos, la frecuencia de reentrenamiento, la necesidad de pipelines administrados o el número de equipos trabajando sobre modelos.

9.3. Beneficios, riesgos y componentes costables

Los beneficios principales son elasticidad y pago por uso, menor inversión física inicial, servicios gestionados, escalamiento sin compra de hardware y una ruta de evolución hacia MLOps. Los trade-offs son dependencia de proveedor y conectividad, costos variables si no se controla el consumo, exposición por configuraciones IAM incorrectas, lock-in parcial y la necesidad de gobierno de datos y revisión legal.

Para la evaluación financiera deben considerarse la configuración inicial de GCP, seguridad y despliegue; Cloud Run; Cloud SQL; Cloud Storage y respaldos; red o egress cuando corresponda; monitoreo y logging; Secret Manager e IAM si tienen costo aplicable; RRHH de operación y seguridad; y seis ventanas de evaluación o reentrenamiento durante los 36 meses.

10. Análisis D3

10.1. Alternativa Local u on-premise

En la alternativa Local, los datos, el almacenamiento, el procesamiento, la inferencia y la aplicación permanecen dentro de la infraestructura hospitalaria. Los usuarios acceden por la red institucional a una aplicación interna, compuesta por Streamlit, FastAPI y Docker; PostgreSQL local persiste los datos; y el almacenamiento institucional mantiene los respaldos. El modelo utiliza Scikit-learn y SHAP, sin requerir GPU en la fase inicial.

El dimensionamiento exacto queda para costeo, pero se requiere un servidor físico o virtualizado con CPU multinúcleo, memoria y SSD suficientes; almacenamiento de

respaldo segregado; segmentación de red; RBAC; MFA para administración; cifrado; EDR o antimalware; parcheo; logs y monitoreo; UPS; y un procedimiento probado de recuperación.

10.2. Seguridad y continuidad

Local no equivale a seguro por definición. Una infraestructura local mal mantenida puede exponerse a ransomware, credenciales comprometidas, software legado, ausencia de segmentación o respaldos inutilizables. El control directo de los datos implica transferir gran parte de la responsabilidad operacional al hospital. El contexto de ciberseguridad sectorial debe evaluarse conforme a los lineamientos del MINSAL (Ministerio de Salud de Chile, [s.f.-b](#), [s.f.-c](#)).

Sus beneficios son el control directo de datos e infraestructura, menor dependencia de Internet para uso interno e integración natural con la red institucional. Sus riesgos son mayor CAPEX, mantenimiento y parcheo a cargo de TI, costos de electricidad y respaldo, escalamiento menos elástico y una postura de ciberseguridad deficiente que puede anular la ventaja de control.

La evaluación financiera debe incorporar servidor o virtualización, almacenamiento y medios de respaldo, UPS y red cuando corresponda, implementación y hardening, electricidad, mantenimiento, repuestos o renovación, seguridad y licencias si la institución no las posee, RRHH TI y seguridad, pruebas de recuperación y las seis ventanas de evaluación o reentrenamiento.

11. Análisis D4

11.1. Alternativa Híbrida

La alternativa Híbrida conserva localmente la identidad, el registro maestro y la interfaz clínica; GCP concentra la capacidad analítica, el entrenamiento y la inferencia. Antes de transferir información, se aplican validación, minimización y pseudonimización. El resultado retorna a la aplicación clínica local y es utilizado por el profesional de salud.

La minimización restringe la transferencia a las variables necesarias para el propósito analítico. La pseudonimización mantiene el vínculo con la identidad real dentro del hospital. La solución además requiere TLS en tránsito, cifrado en reposo, IAM de mínimo privilegio, MFA, Secret Manager, auditoría en ambos ambientes y segregación de funciones. Pseudonimizar no convierte automáticamente la información clínica en datos no sensibles; se mantienen controles reforzados.

La inferencia se ejecuta en GCP para diferenciar la alternativa de la modalidad Local y reducir la infraestructura ML que debe operar el hospital. Si GCP o la conectividad no

están disponibles, la atención clínica debe continuar sin el módulo predictivo, porque la plataforma es de apoyo y no es crítica.

11.2. Distribución explícita de responsabilidades

Permanece local

Identificadores directos del paciente, vínculo con la identidad, registro maestro clínico, aplicación o interfaz clínica interna, controles de acceso e integración interna.

Se ejecuta en GCP

Dataset analítico minimizado o pseudonimizado cuando corresponda, procesamiento y entrenamiento seleccionados, servicio de inferencia en Cloud Run, almacenamiento de artefactos y observabilidad cloud.

Los beneficios son el equilibrio entre control de identidad y elasticidad analítica, menor necesidad de comprar capacidad ML local anticipadamente, escalamiento gradual y una ruta futura hacia MLOps gestionado. Los trade-offs incluyen integración y operación dual, dependencia de conectividad para inferencia, riesgos de sincronización y transferencia, y costos operacionales distribuidos entre ambos entornos.

El costeo debe incluir infraestructura local mínima para registro maestro, interfaz e integración; configuración y seguridad de GCP; Cloud Storage y Cloud Run; cómputo temporal de entrenamiento; conectividad; monitoreo y respaldos en ambos ambientes; RRHH de integración, seguridad y operación; y seis ventanas de evaluación o reentrenamiento.

12. Análisis D5

12.1. Herramientas y stack tecnológico

La tecnología se define para evaluar factibilidad, costos, recursos y riesgos; el proyecto no exige construir todos los componentes. Se evita sobrearquitectura y se prioriza la portabilidad.

12.2. Stack base común

Python

Lenguaje principal por su ecosistema amplio de ciencia de datos, su carácter open source y su portabilidad.

Pandas y NumPy

Preparación y transformación de datos tabulares.

Scikit-learn

Modelamiento tradicional de clasificación tabular, sin sobredimensionar la plataforma ML.

PostgreSQL

Persistencia estructurada open source, disponible localmente o como servicio gestionado en GCP.

SHAP

Explicabilidad y análisis de influencia de variables.

FastAPI

Capa de servicio que desacopla el modelo de la interfaz.

Streamlit

Interfaz y dashboard de referencia para un prototipo interno sin licencias comerciales obligatorias.

Docker

Empaquetado consistente entre las tres alternativas.

Git Versionado y trazabilidad de código, configuración y documentación.

Las tecnologías necesarias son Python, Pandas, Scikit-learn y PostgreSQL. Como capacidades operacionales se incorporan SHAP, FastAPI, Streamlit, Docker y Git cuando el proyecto se materializa como aplicación mantenible. MLflow, Vertex AI, orquestación u otros servicios avanzados quedan para una etapa de mayor volumen, más modelos, reentrenamiento frecuente o complejidad operacional.

Para GCP se consideran como servicios mínimos Cloud Run, Cloud SQL for PostgreSQL, Cloud Storage, IAM, Secret Manager y Cloud Logging/Monitoring. No se incorpora inicialmente Vertex AI, BigQuery, GKE/Kubernetes, Dataflow, Dataproc, GPU dedicada ni Cloud Healthcare API.

13. Análisis D6

13.1. Justificación del enfoque adaptativo

Un enfoque predictivo presupone requisitos tempranamente estables, menor incertidumbre, cambios controlados y retroalimentación más tardía. En este caso, los requisitos pueden evolucionar, existe incertidumbre en los datos, riesgos y solución, y se requieren experimentación y revisión continua. Por ello, la adecuación del enfoque predictivo es media y la del enfoque adaptativo es alta.

El enfoque adaptativo no significa improvisación. Conserva una línea base de alcance y objetivos, pero permite ciclos incrementales con entregables, responsables, revisiones y puntos de decisión. Esta modalidad permite ajustar la planificación frente a la evidencia de calidad de datos, desempeño, riesgos, privacidad, sesgos y factibilidad de las alternativas.

13.2. Criterios completos de comparación

Requisitos

En un enfoque predictivo son estables tempranamente; en uno adaptativo pueden evolucionar. En este caso, pueden evolucionar.

Incertidumbre

Es baja en el enfoque predictivo y media o alta en el adaptativo. El caso presenta incertidumbre alta en datos, riesgos y solución.

Cambios

El enfoque predictivo los minimiza o controla; el adaptativo los incorpora de forma planificada. En este proyecto son probables.

Retroalimentación

Es más tardía en el enfoque predictivo y frecuente en el adaptativo. El caso necesita retroalimentación frecuente.

Datos y modelos

El enfoque predictivo requiere mayor previsibilidad; el adaptativo permite experimentar. El caso presenta incertidumbre en esta materia.

Riesgos

En el enfoque predictivo se planifican principalmente al inicio; en el adaptativo se revisan durante los ciclos. El caso requiere revisión continua.

Adecuación

La adecuación predictiva es media y la adaptativa es alta; por ello se selecciona el enfoque adaptativo.

El efecto transversal es claro: la EDT y la carta Gantt deben considerar revisiones y capacidad de ajuste; finanzas debe presupuestar iteración y contingencia; riesgos debe actualizarse al aparecer nueva evidencia; y la evaluación ética debe acompañar el ciclo completo.

14. Discusión

14.1. Supuestos comunes para las tres alternativas

Las tres alternativas se evalúan durante 36 meses. El horizonte permite comparar CAPEX y OPEX sin castigar artificialmente la inversión inicial de la alternativa Local ni proyectar precios y tecnología a un plazo excesivamente incierto. El TCO debe incluir costos iniciales, implementación, OPEX recurrente, costos periódicos, RRHH y contingencia, respetando la periodicidad de cada partida y evitando doble conteo.

La etapa evaluada es un piloto institucional funcional y mantenible. Incluye infraestructura, aplicación, datos, seguridad, respaldo, monitoreo, RRHH y operación; no incluye integración total con los sistemas del hospital, disponibilidad crítica 24/7 ni despliegue nacional. El cronograma de implementación es independiente del horizonte financiero.

Se consideran 20 usuarios autorizados y hasta 5 concurrentes en el año 1; 25 y 6 en el año 2; y 30 y 8 en el año 3. La curva representa adopción gradual del área cardiovascular y preventiva, no crecimiento de la dotación hospitalaria. Se asume una carga histórica de 10.000 registros, 5.000 nuevos o actualizados durante el primer año, crecimiento de 10 % anual y un acumulado aproximado de 15.000, 20.500 y 26.550 registros en los años 1, 2 y 3. Para sensibilidad se proponen escenarios de 2.500, 5.000 y 10.000 registros anuales iniciales. La referencia de demanda de cardiología en hospitales públicos de Santiago se utiliza solo como orden de magnitud, no como dato del hospital ficticio (Hospital Dr. Sótero del Río, 2017, s.f.; Lagos Barrios, 2024).

La continuidad común exige disponibilidad objetivo de 99 % en horario operacional, RTO máximo de 8 horas, RPO máximo de 24 horas, backup operativo diario, backup completo semanal, retención mínima de 30 días y prueba mensual de restauración. La atención debe continuar si la plataforma no está disponible.

14.2. Detalle de supuestos y sensibilidad

La estimación de 20 usuarios autorizados se distribuye aproximadamente entre 15 profesionales del proceso cardiovascular o preventivo, 3 personas de coordinación o gestión y 2 perfiles técnicos. Es un supuesto de dimensionamiento, no una estadística del hospital ficticio. La referencia histórica de una unidad de cardiología infantil con 14 integrantes y el dato institucional de más de 5.000 funcionarios se usan solo para contextualizar el orden de magnitud (Hospital Dr. Sótero del Río, 2017, s.f.).

El escenario de volumen utiliza 10.000 registros históricos al inicio; 5.000 registros nuevos o actualizados en el año 1; 5.500 en el año 2; y 6.050 en el año 3. Los acumulados estimados son 10.000 al inicio, 15.000, 20.500 y 26.550 respectivamente. Los escenarios de sensibilidad son bajo, con 2.500 registros anuales iniciales; base, con 5.000; y alto, con

10.000.

Para la sensibilidad financiera también puede analizarse un escenario de cuatro ciclos de reentrenamiento por año, frente a los dos ciclos semestrales de la línea base. Las alternativas deben costearse para el mismo nivel de continuidad; ninguna puede parecer más barata por ofrecer menor respaldo o recuperación.

14.3. Comparación consolidada

Cloud GCP

Los datos, entrenamiento e inferencia se ejecutan en GCP y Cloud Run; la interfaz es cloud autenticada. Tiene CAPEX bajo, OPEX variable y RRHH, escalabilidad alta y rápida, alta dependencia de Internet, menor control físico y complejidad media. El MLOps avanzado queda para una etapa futura si se justifica.

Local

Los datos, entrenamiento e inferencia permanecen en el hospital y la interfaz opera en la red interna. Tiene CAPEX mayor y costos de operación y mantenimiento local, escalabilidad posible pero menos elástica, baja dependencia de Internet, mayor control físico y complejidad media. El MLOps avanzado es posible, con mayor esfuerzo local.

Híbrida

La identidad, el registro maestro y la interfaz permanecen locales; el dataset analítico controlado, el entrenamiento y la inferencia se ejecutan en GCP. Tiene CAPEX intermedio, operación dual, costos cloud y RRHH, alta escalabilidad analítica, dependencia media o alta de Internet para inferencia, mayor control de identidad y complejidad alta. El MLOps avanzado queda para cloud si se justifica.

14.4. Riesgos y elementos pendientes

Los riesgos transversales incluyen calidad de datos, duplicados, cambios de esquema, retrasos, fallos de pipeline, drift, degradación del modelo, baja explicabilidad y fallos de respaldo. Cloud agrega dependencia de GCP, conectividad, costos variables, errores IAM, exposición y lock-in; Local incorpora ransomware, software desactualizado, fallos de servidor o UPS, respaldo comprometido, falta de personal especializado y segmentación deficiente; Híbrida añade fallos de sincronización, inconsistencias, exposición durante transferencia y doble operación.

No se cierran aún el precio y sizing final de GCP, el hardware local exacto, las horas por rol y duración de implementación, la alternativa financiera preferida, la matriz de riesgos residual, el análisis legal vigente, los sesgos e impactos éticos finales ni la alternativa recomendada. Estas decisiones requieren la integración de los responsables correspondientes.

La auditoría de aceptación concluye que las alternativas comparten problema y alcance, las herramientas tienen función justificada y la metodología está argumentada. Finanzas y planificación pueden trabajar con los supuestos y handoffs definidos, aunque los precios, dimensionamientos y análisis integrales quedan pendientes.

15. Conclusiones

La línea base conceptual D1 a D6 define una plataforma de apoyo a la prevención cardiovascular, no un sistema de diagnóstico autónomo. La comparación entre Cloud, Local e Híbrida es válida porque las tres alternativas conservan el mismo alcance, los mismos supuestos de usuarios, registros, operación, reentrenamiento y continuidad.

El stack propuesto es portable, mantenible y predominantemente open source. GCP se usa como escenario Cloud concreto, sin imponer servicios avanzados de ML antes de que su necesidad esté demostrada. La alternativa Local ofrece control directo, pero exige una operación y postura de seguridad sostenida. La alternativa Híbrida equilibra control de identidad local con elasticidad analítica en cloud, a costa de mayor integración y operación dual.

El enfoque adaptativo es consistente con la incertidumbre de los datos y del proyecto. La elección definitiva entre arquitecturas no puede establecerse con seriedad antes de integrar costos, riesgos, aspectos éticos y restricciones legales.

16. Recomendaciones

16.1. Handoff para evaluación financiera

La evaluación financiera debe costear Cloud, Local e Híbrida con los mismos supuestos de horizonte, piloto, usuarios, volumen, actualización, mantenimiento de modelo y continuidad. Cloud debe considerar configuración, seguridad, despliegue, Cloud Run, Cloud SQL, Storage, red, monitoreo, soporte, RRHH y cómputo temporal; no debe suponer entrenamiento 24/7 ni Vertex AI obligatorio. Local debe incluir CAPEX de infraestructura, hardening, electricidad, mantenimiento, seguridad, backup, soporte y RRHH, dimensionado al menos para el escenario del año 3. Híbrida debe sumar infraestructura local mínima, costos cloud e integración, conectividad, monitoreo de ambos ambientes y el esfuerzo de operación dual.

La sensibilidad mínima debe variar registros anuales (2.500 y 10.000 frente al escenario base de 5.000), reentrenamientos (4 frente a 2 por año), usuarios cuando corresponda y el componente dominante de costo de cada arquitectura.

16.2. Fórmula y reglas de costeo

La estructura común es $TCO_{36\text{ meses}} = \text{CAPEX o costos iniciales} + \text{implementación} + \text{suma de OPEX recurrente del horizonte} + \text{costos periódicos} + \text{RRHH} + \text{contingencia justificada}$. Cada partida debe respetar su periodicidad real para evitar multiplicaciones incorrectas o doble conteo.

Cloud debe dimensionarse para 20, 25 y 30 usuarios; 5, 6 y 8 usuarios concurrentes; 10.000 registros históricos más el crecimiento definido; batch diario; y los RTO/RPO comunes. Local debe soportar al menos el escenario del año 3 sin una sustitución completa por el crecimiento base. Híbrida debe incluir el costo y el impacto de seguridad y sincronización entre ambos ambientes.

16.3. Handoff para planificación, riesgos e integración

La EDT y carta Gantt deben orientarse a entregables: inicio y alcance, datos, preparación, análisis y modelo, validación técnica y ética, infraestructura o piloto, documentación y cierre. Deben incluir backup, monitoreo, recuperación y mantenimiento como trabajo gestionable, y separar la duración de implementación de los 36 meses financieros.

La matriz de riesgos debe consolidar los riesgos técnicos expuestos en la Sección 14 con los riesgos financieros, éticos, legales y de planificación. Para la integración ética, debe mantenerse que el sistema no reemplaza al profesional, que el dataset actual es un prototipo y que Cloud e Híbrida tratan datos sensibles fuera del entorno local. La recomendación final no debe decidirse solo por precio.

16.4. Handoffs nominales y matriz de riesgos semilla

Ignacio recibe los componentes, supuestos y fórmulas para la evaluación financiera. El responsable de EDT o Carta Gantt recibe D1 como línea base de alcance, usuarios y límites, junto con la necesidad de una EDT orientada a entregables. Vicente recibe los riesgos técnicos preliminares para consolidarlos con riesgos financieros, éticos, legales y de planificación. César recibe las restricciones para la integración ética y la recomendación final.

Transversal

Calidad de datos, duplicados, cambios de esquema, datos retrasados, fallos del pipeline, drift, degradación del modelo, baja explicabilidad y fallo de backup.

Cloud

Dependencia de GCP, pérdida de conectividad, costos variables, error IAM, exposición de datos, indisponibilidad del proveedor y lock-in.

Local

Ransomware, software desactualizado, fallo de servidor o UPS, backup comprometido, falta de personal especializado, escalabilidad lenta y mala segmentación.

Híbrida

Fallo de sincronización, inconsistencia entre entornos, exposición durante transferencia, mayor complejidad, dependencia de Internet para inferencia y doble operación.

Continuidad

RTO superior a 8 horas, RPO superior a 24 horas, restauración fallida y pérdida de datos analíticos.

Mantenimiento ML

Reentrenar con datos defectuosos, nueva versión peor, incremento de sesgos, pérdida de trazabilidad o publicación sin aprobación.

16.5. Matriz de trazabilidad de decisiones

Apoyo preventivo

Se fundamenta en el caso y EA1; se usa para ética y para delimitar el alcance de planificación.

Tres alternativas con mismo alcance

Se fundamenta en el Plan Maestro; permite comparación financiera y análisis de riesgos equivalentes.

GCP como referencia Cloud

Se fundamenta en la decisión de diseño, región de Santiago y simplicidad; permite tarifar Cloud y revisar sus riesgos.

Stack portable y open source

Se fundamenta en costo-beneficio y comparabilidad; sirve para licencias y planificación de recursos.

Sin Vertex AI inicial

Evita sobrearquitectura a la escala actual; define el costo base y los gatillos de escalamiento futuro.

Local con seguridad reforzada

Se fundamenta en EA1 y contexto MINSAL; alimenta ciberseguridad, costos de seguridad y continuidad.

Híbrida con minimización y pseudonimización

Se fundamenta en privacidad y diseño del caso; alimenta ética, legalidad, riesgos e integración.

Metodología adaptativa

Se fundamenta en incertidumbre; define ciclos, hitos y revisiones de EDT o Gantt.

Horizonte de 36 meses

Hace comparables CAPEX y OPEX para el TCO.

Piloto controlado

Evita comparar un notebook trivial con una producción ficticia y delimita el alcance de todos los análisis.

Crecimiento de usuarios, volumen, batch y reentrenamiento

Entregan bases comunes para sizing, costos, operación, riesgos y validación.

99 %, RTO 8 h y RPO 24 h

Definen respaldo, pruebas, planificación y riesgos de continuidad.

16.6. Auditoría de aceptación D1 a D6

La línea base cumple con que las tres alternativas resuelven el mismo problema y alcance; cada herramienta tiene una función y motivo; y la metodología está argumentada, no solo nombrada. También permite a Ignacio costear sin inventar componentes mediante los supuestos y el handoff, aunque aún faltan precios y sizing exactos. Permite construir EDT y Gantt sin reinterpretar el alcance; distingue proyecto conceptual de ejecución real; mantiene fuentes y supuestos trazables; y prohíbe declarar una alternativa ganadora antes de integrar finanzas, riesgos y ética.

16.7. Checklist de integración

- Mantener D1 a D6 como línea base y comunicar cualquier cambio a finanzas, planificación, riesgos e integración.
- No declarar una alternativa ganadora antes de terminar los análisis financiero, de riesgos y ético.
- Usar los mismos supuestos para Cloud, Local e Híbrida.
- Distinguir datos reales, referencias externas y supuestos de planificación.
- Respalda cada cifra de costos con tarifario, cotización o supuesto reproducible.
- Conservar el carácter de apoyo preventivo y no diagnóstico autónomo.
- Sintetizar el informe final EP1 a 4-6 páginas, con letra 11, interlineado simple y estilo APA; este documento maestro puede ser más extenso.

- Corregir la consistencia del responsable de EDT o Gantt antes de la entrega final, si existen nombres distintos en los documentos del equipo.

17. Referencias

- Equipo de proyecto. (2026). Plan Maestro del Encargo Heart Disease Dataset equipo de 5 [Documento interno].
- Google Cloud. (2026a). *Resource location restrictions*. Consultado el 10 de septiembre de 2026, desde <https://docs.cloud.google.com/organization-policy/restrict-locations?hl=es>
- Google Cloud. (2026b). *What is Cloud Run*. Consultado el 10 de septiembre de 2026, desde <https://docs.cloud.google.com/run/docs/overview/what-is-cloud-run>
- Hospital Dr. Sótero del Río. (2017). *El valioso trabajo de la Unidad de Cardiología Infantil*. Consultado el 10 de septiembre de 2026, desde <https://www.hospitalsoterodelrio.cl/web/el-valioso-trabajo-de-la-unidad-de-cardiologia-infantil/>
- Hospital Dr. Sótero del Río. (s.f.). *Quiénes somos*. Consultado el 10 de septiembre de 2026, desde <https://www.hospitalsoterodelrio.cl/web/quienessomos/>
- JohnSmith88. (s.f.). *Heart Disease Dataset*. Consultado el 10 de septiembre de 2026, desde <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>
- Lagos Barrios, R. (2024). Método para medir brechas de consultas médicas de especialidad en la programación de hospitales públicos. *Revista Médica de Chile*, 152(10), 1049-1059. https://www.scielo.cl/scielo.php?pid=S0034-98872024001001049&script=sci_arttext
- Ministerio de Salud de Chile. (s.f.-a). *Orientaciones para la planificación Programa de Salud Cardiovascular*. Consultado el 10 de septiembre de 2026, desde <https://www.minsal.cl/orientaciones-para-la-planificacion/>
- Ministerio de Salud de Chile. (s.f.-b). *Plan Director Hoja de Ruta de Ciberseguridad y Seguridad de la Información para el Sector Salud*. Consultado el 10 de septiembre de 2026, desde <https://www.minsal.cl/wp-content/uploads/2015/08/PLAN-DE-CIBERSEGURIDAD-Y-SEGURIDAD-DE-LA-INFORMACION-SECTOR-SALUD-2024-2025-ITS-NC-03-V1.1.pdf>
- Ministerio de Salud de Chile. (s.f.-c). *Seguridad de la Información y Ciberseguridad del MINSAL*. Consultado el 10 de septiembre de 2026, desde https://www.minsal.cl/seguridad_de_la_informacion/
- SCY1102 Gestión de Proyectos de Datos. (2025a). Evaluación de Factibilidad Financiera y de Riesgos de Proyectos de Ciencia de Datos [Presentación].
- SCY1102 Gestión de Proyectos de Datos. (2025b). Evaluación de Factibilidad Técnica y Ética de un Proyecto de Ciencia de Datos [Presentación].

SCY1102 Gestión de Proyectos de Datos. (2025c). Evaluación de Proyectos de Ciencia de Datos [Material docente].

SCY1102 Gestión de Proyectos de Datos. (2025d). Evaluación Parcial N 1 Instrucciones y pauta de evaluación Estudiante [Documento de evaluación].

SCY1102 Gestión de Proyectos de Datos. (2025e). Integración y Comunicación de los Resultados de un Proyecto de Ciencia de Datos [Presentación].