Duoc UC

Documentación técnica del modelo Heart Disease

Datos, preparación, entrenamiento y evaluación experimental

Gestión de Proyectos de Datos — EVA1

Lucas Moncada Ignacio Silva Fabián Leal
Vicente Hormazábal César Rojas

Noviembre de 2026

Índice

1. Propósito y alcance **1**

2. Dataset y variables **1**

3. Auditoría y preparación de datos **2**

3.1. Duplicados, nulos y dominios 2

3.2. Extremos y escalado 2

4. Relaciones exploratorias **3**

5. Diseño experimental **5**

5.1. Partición y validación 5

5.2. Candidatos y configuración 6

6. Resultados **6**

7. Interpretación, limitaciones y uso **8**

8. Reproducción y artefactos **8**

1. Propósito y alcance

Este documento describe exclusivamente el prototipo académico de clasificación construido con el archivo `heart.csv`: composición de los datos, auditoría, transformaciones, entrenamiento, selección, evaluación y artefactos reproducibles. No describe un sistema clínico desplegado. El modelo no está validado en población local chilena y no debe usarse para diagnóstico, tratamiento, priorización asistencial ni decisiones sobre pacientes.

La implementación reproducible está en `notebooks/04_implementacion_tecnica_3_1_2.ipynb` y `src/modeling.py`. La fuente académica se conserva en `data/raw/heart.csv`; el entrenamiento elimina duplicados exactos en memoria y no modifica el original.

2. Dataset y variables

El archivo contiene 1.025 filas, 13 predictores y la variable binaria `target`; se observan 723 filas duplicadas exactas y 302 filas únicas. No se detectaron valores nulos. La etiqueta se conserva como está codificada en el archivo; su significado y su equivalencia clínica no se dan por validados para una población distinta.

Cuadro 1: Diccionario resumido de variables

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
age	Edad del paciente.	Numérica discreta	años	29–77
sex	Sexo del paciente.	Binaria	0=mujer; 1=hombre	0|1
cp	Tipo de dolor torácico.	Categórica	No verificada; ver CSV	0|1|2|3
trestbps	Presión arterial en reposo al ingreso.	Numérica discreta	mmHg	94–200
chol	Colesterol sérico.	Numérica discreta	mg/dL	126–564
fbs	Indicador de glucosa en ayunas superior a 120 mg/dL.	Binaria	0=no; 1=sí (>120 mg/dL)	0|1
restecg	Resultado del electrocardiograma en reposo.	Categórica	0=normal; 1=ST-T; 2=HVI	0|1|2

Cuadro 2: Diccionario resumido de variables (continuación)

Variable	Descripción	Tipo	Unidad / codificación	Dominio observado
thalach	Frecuencia cardíaca máxima alcanzada.	Numérica discreta	bpm	71–202
exang	Angina inducida por ejercicio.	Binaria	0=no; 1=sí	0|1
oldpeak	Depresión del segmento ST inducida por ejercicio respecto del reposo.	Numérica continua	desviación ST	0–6.2
slope	Pendiente del segmento ST durante ejercicio.	Categórica	No verificada; ver CSV	0|1|2
ca	Número de vasos principales coloreados por fluoroscopia.	Numérica discreta	UCI: 0–3; CSV: 0–4	0–4
thal	Resultado de la prueba de talio.	Categórica	No verificada; ver CSV	0|1|2|3
target	Variable objetivo binaria de la versión Kaggle, asociada a la presencia de enfermedad cardíaca.	Binaria	Binaria 0/1; ver CSV	0|1

Las variables numéricas usadas como cuantitativas por el pipeline son `age`, `trestbps`, `chol`, `thalach` y `oldpeak`. Se codifican como categóricas `sex`, `cp`, `fbs`, `restecg`, `exang`, `slope`, `ca` y `thal`. Aunque algunas variables binarias o de conteo están almacenadas como enteros, su tipo estadístico y su tratamiento del modelo no se infieren sólo del dtype.

La copia presenta diferencias de dominio con la documentación de UCI, en particular para `cp`, `slope`, `ca` y `thal`. El caso `ca=4` se conserva como observado. No se inventa una

recodificación semántica cuando la versión concreta del dataset no permite sostenerla (Janosi et al., 1989; JohnSmith88, s.f.).

3. Auditoría y preparación de datos

3.1. Duplicados, nulos y dominios

Se detectaron 723 duplicados exactos al comparar las 14 columnas. El flujo conserva las 302 observaciones distintas y deduplica antes de particionar para impedir que copias idénticas queden simultáneamente en entrenamiento y prueba. También verifica combinaciones repetidas de predictores con etiquetas en conflicto; no se encontraron casos. No hay identificador de paciente, por lo que no se puede determinar si las repeticiones son publicaciones repetidas o mediciones de una misma persona.

No se observaron nulos, de modo que no se imputa. El pipeline valida columnas esperadas, clases binarias de `target` y ausencia de nulos. Los dominios categóricos observados se preservan y se contrastan con la ficha de la fuente; las categorías nuevas se rechazan en la rutina batch y no se asignan silenciosamente.

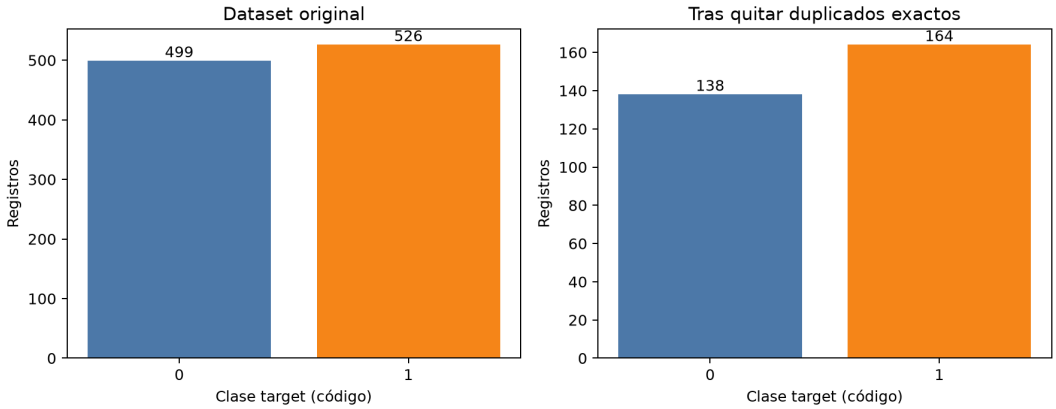


Figura 1: Distribución de clases antes y después de quitar duplicados exactos. La deduplicación cambia el peso relativo de las clases, por lo que se aplica antes de separar los datos.

3.2. Extremos y escalado

La regla exploratoria de 1,5 veces el rango intercuartílico marca 9 valores de `trestbps`, 5 de `chol`, 1 de `thalach` y 5 de `oldpeak`; no marca valores de `age`. Se conservan: la regla señala casos para revisar, pero no demuestra que sean errores. No se aplicó recorte ni winsorización.

No se aplica una normalización uniforme a todos los algoritmos. La regresión logística de referencia usa `RobustScaler` en las variables cuantitativas y one-hot en las categóricas. XGBoost recibe las cuantitativas en escala original y las categóricas one-hot, porque el modelo de árboles divide mediante umbrales y no requiere estandarización como la

regresión logística. Los transformadores se ajustan dentro de cada pipeline/fold, evitando que estadísticas del conjunto de prueba entren en el preprocesamiento.

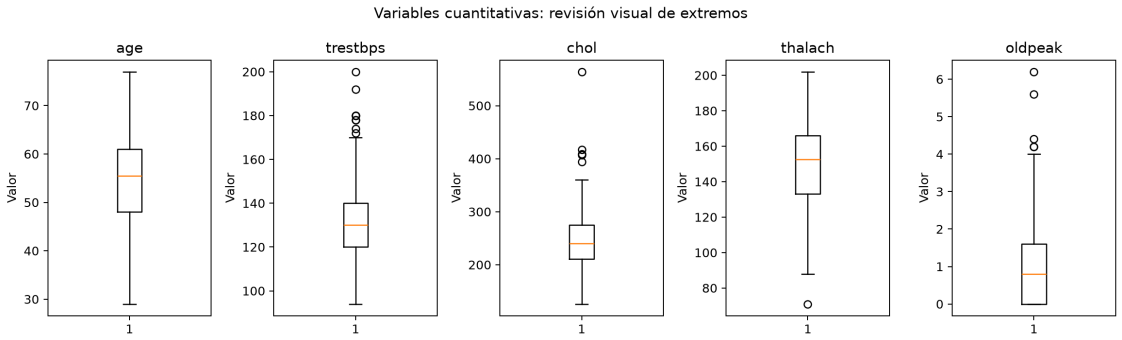


Figura 2: Distribuciones de variables cuantitativas y candidatos a revisión según el criterio IQR.

4. Relaciones exploratorias

La correlación de Pearson se calcula entre variables cuantitativas y la etiqueta binaria. Para variables categóricas se representa por separado la correlación de cada indicador de nivel con `target`. Estos gráficos describen asociaciones en esta muestra; no muestran causalidad ni bastan para excluir predictores. Los códigos categóricos no se interpretan como magnitudes continuas.

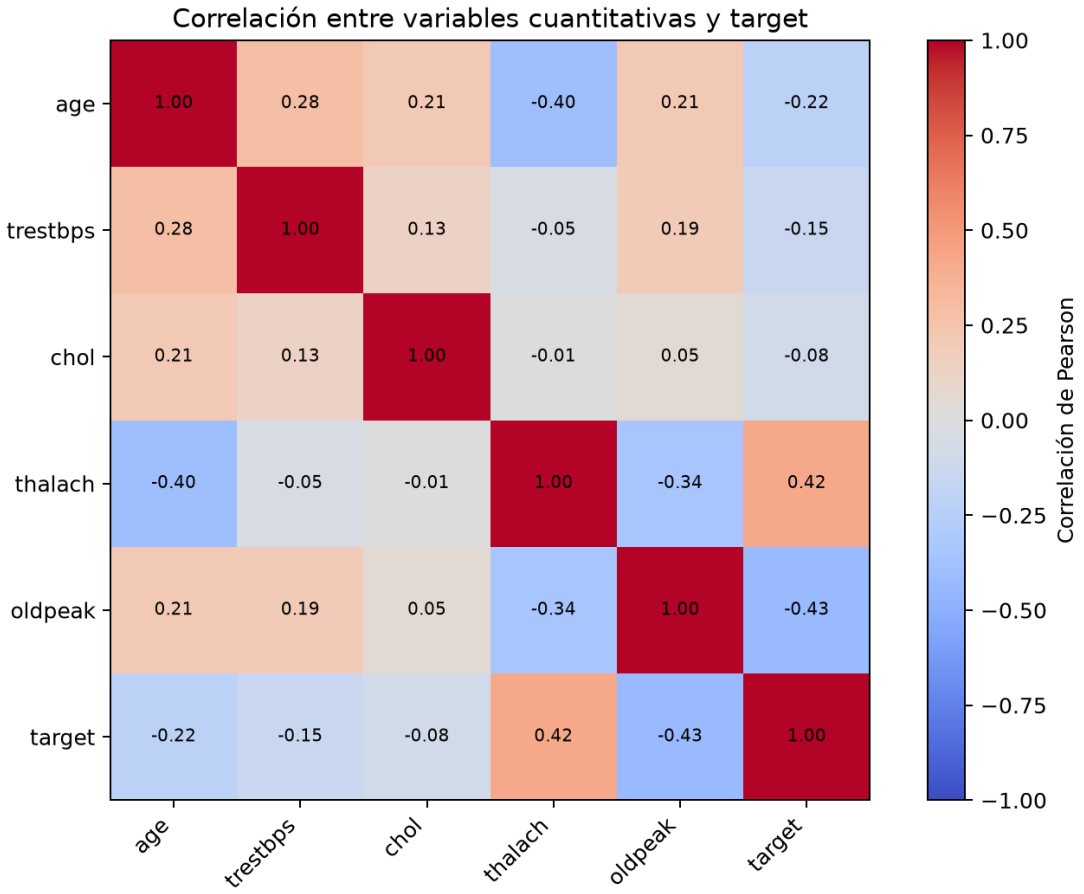


Figura 3: Correlación de Pearson de predictores cuantitativos y `target`.

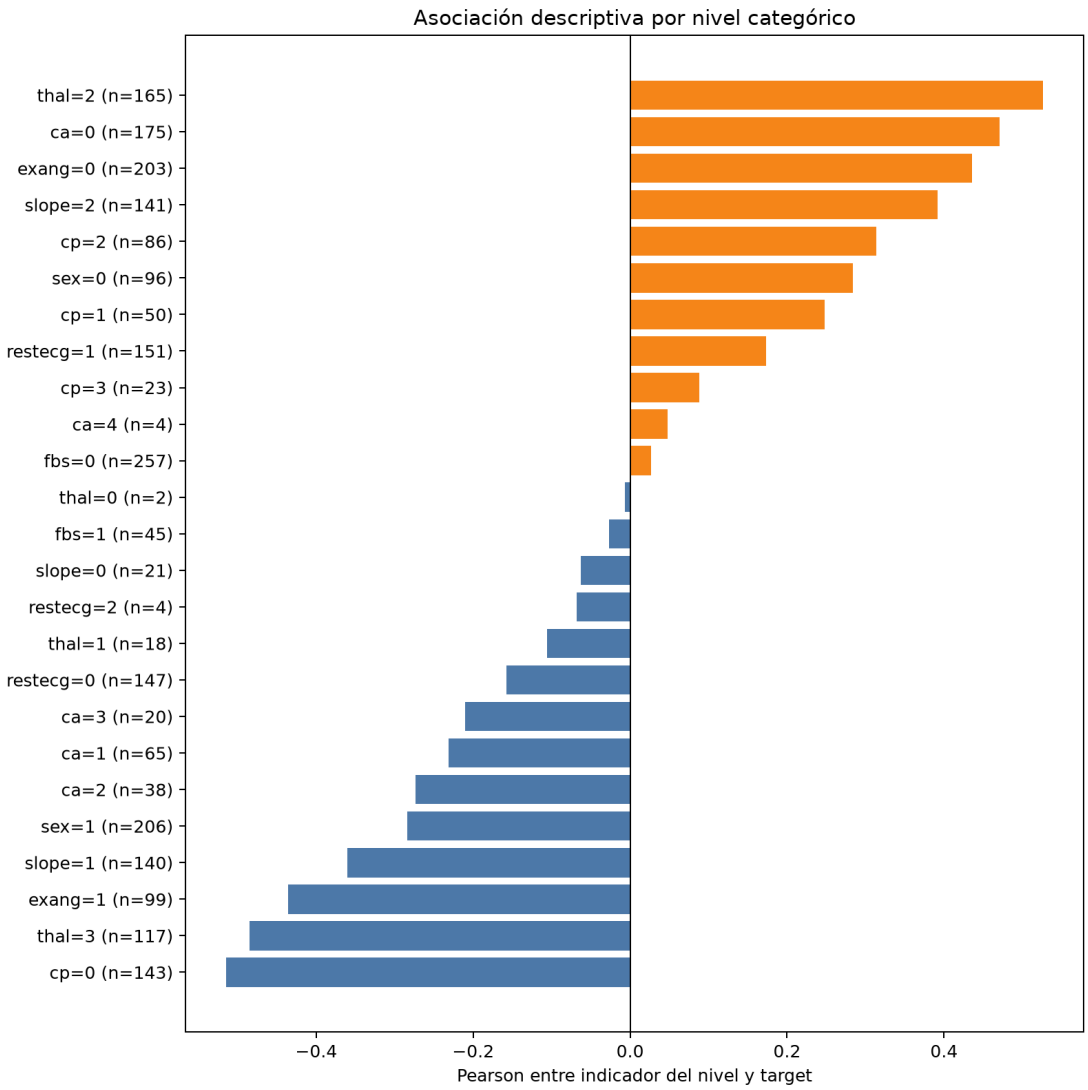


Figura 4: Asociación descriptiva entre niveles categóricos y `target`; el tamaño muestral varía por nivel.

5. Diseño experimental

5.1. Partición y validación

Tras deduplicar, se separa 75 % para entrenamiento y 25 % para prueba mediante partición estratificada con semilla 42: 226 registros de entrenamiento y 76 de prueba. En entrenamiento se comparan candidatos con validación cruzada estratificada de cinco folds, aleatorizada con la misma semilla. La selección se basa en el promedio de ROC-AUC de validación cruzada entre candidatos XGBoost one-hot que entrenan con CUDA. El conjunto de prueba retenido se usa para la comparación final reportada.

5.2. Candidatos y configuración

Se evaluaron una regresión logística de referencia (CPU, one-hot y RobustScaler), un XGBoost ordinal previo y dos XGBoost CUDA con variables categóricas one-hot. El XGBoost one-hot somero usa 250 estimadores, profundidad máxima 2, tasa de aprendizaje 0,04, `min_child_weight=3`, `subsample=0,9`, `colsample_bytree=0,9` y regularización L2 de 2. El candidato one-hot regularizado usa 200 estimadores, profundidad 3, tasa 0,03, `min_child_weight=5`, subsampling y muestreo de columnas 0,85, L2 de 5. Ambos configuran objetivo binario logístico, métrica de entrenamiento logloss, método hist y dispositivo CUDA. La semilla es 42.

El artefacto final es el XGBoost one-hot somero, entrenado localmente con CUDA en la NVIDIA GeForce RTX 4060 Laptop GPU. Se eligió entre los candidatos GPU one-hot por ROC-AUC promedio de validación cruzada; la regresión logística obtuvo el promedio numérico más alto, pero es una referencia CPU y no el artefacto final seleccionado para este ejercicio.

6. Resultados

Cuadro 3: ROC-AUC medio (desviación estándar) en validación cruzada de entrenamiento

Candidato	Dispositivo	ROC-AUC CV
Regresión logística (one-hot + RobustScaler)	CPU	0,919 (0,052)
XGBoost ordinal previo	CUDA	0,917 (0,062)
XGBoost one-hot somero, seleccionado	CUDA	0,914 (0,055)
XGBoost one-hot regularizado	CUDA	0,913 (0,061)

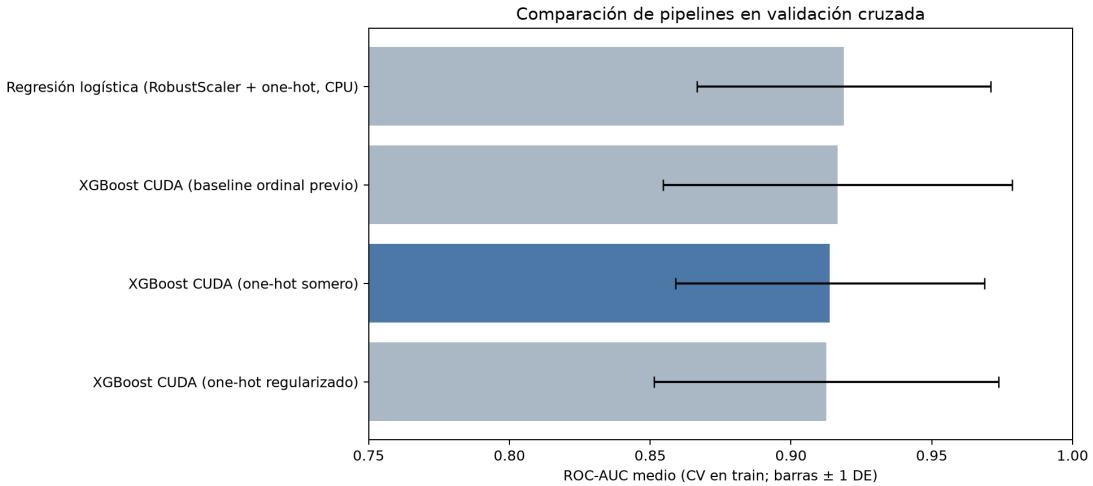


Figura 5: Comparación del ROC-AUC medio y su dispersión entre folds. La variabilidad es apreciable dada la muestra pequeña.

En los 76 registros de prueba, el XGBoost one-hot seleccionado obtuvo accuracy 0,776, precisión de clase 1 de 0,786, recall 0,805, F1 0,795 y ROC-AUC 0,875. El baseline ordinal previo obtuvo 0,789, 0,791, 0,829, 0,810 y 0,875, respectivamente. Por tanto, el cambio a one-hot no mejoró estas métricas en esta partición y ambos modelos empataron en ROC-AUC. La comparación de un único conjunto pequeño no demuestra equivalencia ni diferencia estadística.

Cuadro 4: Métricas en el mismo conjunto de prueba retenido

Métrica	XGBoost ordinal previo	XGBoost one-hot seleccionado
Accuracy	0,789	0,776
Precisión (clase 1)	0,791	0,786
Recall (clase 1)	0,829	0,805
F1 (clase 1)	0,810	0,795
ROC-AUC	0,875	0,875

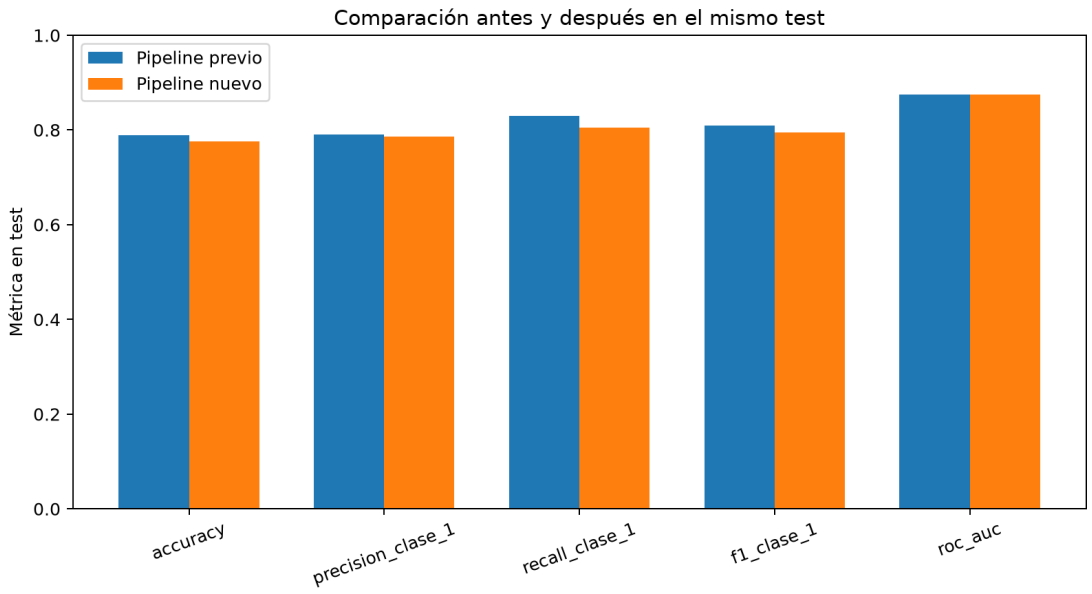


Figura 6: Métricas de ambos pipelines sobre la misma partición retenida.

7. Interpretación, limitaciones y uso

Los valores son resultados experimentales de un conjunto académico con 302 observaciones únicas. La copia de datos contiene duplicación extensa, hay diferencias de dominio pendientes de aclarar, no se conoce población de referencia ni existe validación externa. El ROC-AUC de prueba de 0,875 y las demás métricas describen sólo esta partición; no constituyen desempeño clínico esperado. Los scores de clase 1 no están calibrados como probabilidades clínicas.

No se presenta análisis de explicabilidad SHAP ni auditoría robusta de desempeño por subgrupos como resultado completado. No hay datos hospitalarios, aprobación institucional, revisión clínica, servicio/API, despliegue productivo ni monitoreo. La inferencia batch local está demostrada sólo con cinco casos sintéticos y no modifica ni reentrena el artefacto.

8. Reproducción y artefactos

El código fuente de entrenamiento se encuentra en `src/modeling.py`; el desarrollo y las figuras se documentan en el notebook técnico. El entorno de dependencias está fijado mediante `uv.lock`. El modelo serializado está en `outputs/models/heart_disease_pipeline.joblib`; su uso requiere las dependencias y el esquema de entrada documentado. Los gráficos incluidos en este informe se generan bajo `outputs/figures/`; las tablas de auditoría y métricas, bajo `outputs/tables/`.

Para instalar el entorno y ejecutar el análisis desde la raíz del repositorio:

```
uv sync
```

```
uv run jupyter lab notebooks/04_implementacion_tecnica_3_1_2.
   ipynb
```

La documentación del preprocesamiento sigue prácticas de ajuste de transformadores dentro de los datos de entrenamiento para evitar fuga de información (scikit-learn developers, s.f.). La documentación del conjunto de origen está referenciada como contexto de procedencia, no como validación de esta copia (Janosi et al., 1989; JohnSmith88, s.f.).

Referencias

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). *Heart Disease*. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

JohnSmith88. (s.f.). *Heart Disease Dataset*. Consultado el 10 de septiembre de 2026, desde https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset

scikit-learn developers. (s.f.). *Common pitfalls and recommended practices*. Consultado el 3 de noviembre de 2026, desde https://scikit-learn.org/stable/common_pitfalls.html